수집 데이터 보고서
— 수집·전처리 증빙

CopyLane · 데이터 수집·저장 산출물 · 2026-10-21 개정

작성자 **권소라**

원 작성 **2026-09-17 (v3.0)**

개정 **2026-10-21 · 기준 커밋 ksr b54246d · 10-22 확인 반영**

수치 출처 **data_sources.yaml · data/manifest.jsonl · data/derived_manifest.jsonl · docs/00_사실원장.md**

목차

1. 요약 — 무엇을 받아 무엇을 만들었고, 증거는 어디 있나 3

1.1 한눈에 — 원천에서 학습·평가 데이터까지 3

1.2 09-17 제출본 대비 달라진 것 4

1.3 강사 피드백 반영표 4

1.4 핵심 발견 5

2. 데이터 출처와 수집량 6

2.1 수집 대상 선정 — 등록부(레지스트리) 현황 6

2.2 원장에 오른 36종 — 출처 · 방식 · 수집량 6

2.3 아직 받지 않은 등재 소스 — 34종 9

2.4 재배포 · 이용 제한 10

2.5 쓰임 — 원천이 어디에 들어가나 10

2.6 09-17 이후 새로 들어온 원천 12

3. 정제 결과 — 결측 · 중복 제거 전후 건수 14

3.1 지금 판(2026-10-21) — 원래 → 제거 · 처리 → 최종 14

3.2 결측 · 중복 처리 원칙 15

3.3 09-17 판의 단계별 기록(참고) 15

4. pandas 통계 실행 결과 17

5. 이 PC 에 없는 데이터와 골든셋 구성 19

5.1 이 PC 보유 현황 — 원문 · 파생물 (2026-10-21) 19

5.2 골든셋 구성 — 판 94a79fe34363 19

5.3 이 PC 에서 증빙을 채우는 방법 20

6. 한계와 근거 문서 21

6.1 한계 · 남은 과제 21

6.2 근거 문서 21

1. 요약 — 무엇을 받아 무엇을 만들었고, 증거는 어디 있나

> **작성자** 권소라 · 원 작성 2026-09-17(v3.0) · **개정 2026-10-21**(2026-10-22 확인 반영) · 기준 커밋 `ksr b54246d`
>
> **이 판에서 고친 것** — 소스 목록 · 상태별 개수 · 수집량 · 재배포 제한 · 쓰임을 2026-10-21 의 등록부(레지스트리)와 원장 기준으로 다시 셌다. 09-17 이후 들어온 원천 23종과 건강기능식품 고시형 기능성 문구를 넣었다. pandas 통계는 2026-10-21 에 다시 돌렸다.
>
> **수치는 두 종류다.** ① **팀 축** — `data_sources.yaml`(등록부) · `data/manifest.jsonl`(수집 원장) · `data/derived_manifest.jsonl`(파생물 원장)은 git 으로 공유되므로 어느 기기에서 세어도 같다. ② **이 PC 실측** — 원문 파일과 DB 는 기기마다 다르다. 이 보고서의 기기 값은 권소라 PC(`KSR_SKNPC` · 데이터 역할 `replica` = 복제본)에서 2026-10-21 에 잰 것이다. 두 종류를 한 칸에서 더하지 않는다.

1.1 한눈에 — 원천에서 학습·평가 데이터까지



레지스트리·수집 원장·파생물 원장은 git 이 나르는 「팀 축」 값이다(어느 기기에서 세도 같다).
골든셋 · 사전 · 청크는 파생물 원장 sha256 기준(골든 94a79fe34363 · 사전 2ff0168c4a28 · 청크 e99bd36afc3e).
원문 파일은 저장소에 올리지 않는다 — 기기마다 보유량이 다르다(§5.1).

항목	값	어느 축 · 출처
심사한 후보 소스	**97** = 등재 70 + 배제 13 + 미채택 14	팀 축 · `data_sources.yaml` 직접 셈
등재 소스(상태별)	**70** = 수집 `collect` 45 · 수기 `manual` 10 · 보류 `hold` 15	팀 축 · 같은 파일
등재 소스(등급별)	G3 56 · G2 10 · G0 4	팀 축
수집 원장에 오른 소스	**36** (수집 29 + 수기 7)	팀 축 · `data/manifest.jsonl`
수집 원장 줄 / 고유 원문 파일	**28,277 줄 / 18,300 파일**(고유 sha256 19,123)	팀 축 · 마지막 기록 2026-10-14
원장 크기	줄 크기 합 약 3.97 GB · 경로별 최신 파일 합 약 3.58 GB	팀 축
파생물	**245 개 · 약 77.7 MB**(생성물 89 · 원천 46 · 표본 5 · 원문캐시 105)	팀 축 · `data/derived_manifest.jsonl`(기록 2026-10-18)
DB 에 적재된 소스	**53**(건너뜀 17)	이 PC DB(`source`) · 사실원장 10-06 클론 A 와 같은 수

항목	값	어느 축 · 출처
골든셋	**8,383 행**(train 5,894 · 평가 분할 test_sentence 2,489 — 재분할 뒤 봉인 시험지는 그중 1,141 행 · §5.2) · 판 `94a79fe34363`	파생물 원장 · 이 PC DB
금지 표현 사전	**4,342 항목**(단독판정 4,189) · 판 `2ff0168c4a28`	파생물 원장 · 이 PC DB
법령 청크 · 임베딩	**6,686 / 6,686**	파생물 원장 · 이 PC DB

1.2 09-17 제출본 대비 달라진 것

항목	09-17 제출본	2026-10-21	바뀐 이유
등록부 등재 소스	46	**70**	새 원천 등재(권소라 수집분 · 식약처 안내서 · 공정위·경기도 보도자료 · 대법원 주요판결 · 인터넷신문 광고심의결정문 등)
배제(G1) · 미채택	10 · 13	**13 · 14**	배제: 기관 회신(서면 2 · 전화 1)으로 거절된 3건 추가(§2.1) · 미채택 1 증가
수집 원장에 오른 소스	13	**36**	09-17 뒤 23종이 원장에 올랐다(§2.6)
수집 원장 줄	29,675(클론 A · 미커밋 포함) / 커밋본 20,123	**28,277**(커밋본)	새 원천 수집 · 09-22 정리
고유 원문 파일	10,163(클론 A)	**18,300**	같음
DB 적재 소스	32(09-13)	**53**	등재 소스 증가(등재 70 중 적재 CHECK 를 지난 것)
골든셋	1,910 행	**8,383 행**	새 1층 원천 판독 · 재판독(전처리 결과서 참고)
금지 표현 사전	536 종	**4,342 항목**	조문 꼴 항목 · 화장품 낱말 추가
법령 청크	2,400(팀) / 2,022(클론 A)	**6,686**	행정규칙 · 별표 확대
건기식 기능성 문구 목록	개별인정형만	**+ 고시형 169 문구 (원료 93)**	카피 생성의 인정 문구 대조용(§2.6)

1.3 강사 피드백 반영표

요구 사항	이 보고서의 위치
데이터 출처 기재	§2.1 등록부 현황 · §2.2 원장에 오른 36종의 제공기관 · 수집 방식 · 층 · 상태
수집량 기재	§2.2 소스별 원장 줄 · 고유 파일 · 크기 · 마지막 수집일
결측치·중복 제거 전후 건수 명시	§3 「원래 → 제거 사유 · 건수 → 최종」
pandas 통계(최대·최소, null, 중복)	§4 — shape · `isnull().sum()` · `duplicated().sum()` · `describe()` · 글자 수 min/max 실행 결과 6묶음
(추가) 재배포 제한과 실제 쓰임	§2.4 · §2.5

1.4 핵심 발견

- **중복은 대부분 「재수집 이력」이다.** 원장 28,277 줄 중 9,977 줄이 같은 경로를 다시 적은 것이고, 그중 9,148 줄은 내용(sha256)까지 같다. 원장은 이력이라 지우지 않고, 쓸 때 경로별 최신 판(18,300 파일)을 고른다.
- **원장에 오른 36종 중 골든셋 · 사전 · 근거 검색 · 화면에 실제로 들어가는 것은 16종이다.** 3종(`cosmetic_restricted` · `mfds_press` · `mfds_hf_ingredient`)은 파생물만 있고 읽는 곳이 없으며, 17종은 원문만 보관하고 있다(후순위 원천 · 판독 대기 · 변경금지 원천 · §2.5).
- **골든셋의 대부분은 재배포할 수 없다.** 8,383 행 중 7,019 행은 기관 문서가 인용한 제3자 광고 문구라 `redistributable=false` 로 표시된다(계보 표 `preprocess/lineage.py`). 재배포 가능(`true`)으로 표시된 것은 인정 문구 계열 1,364 행뿐이다(실제로 공개하게 되면 법률 확인 뒤 다시 판정한다 · D-249).
- **근거 검색(RAG)은 법제처 원천 하나로만 선다.** 청크 6,686 개가 모두 `law_go_kr` 의 조문(2,943) · 별표(3,743)다. 해설서 · 질의응답집은 근거 조문 자리에 들어가지 않는다.
- **고시형 기능성 문구 목록이 파생물 원장에 아직 없다.** 2026-10-14 에 이 PC 에서 만든 `hf_gosi_claims.jsonl`(169 행)은 원본 ZIP 이 수집 원장에 있으나 파생물 원장 245 줄에는 없어 다른 기기로 전달되지 않는다. 이 파일이 없는 기기에서는 고시형에만 있는 공식 문구 47개가 「목록에 없음」 · 「비슷함」으로 나온다. 이 대조는 카피 생성 · AI 광고 생성 화면의 안내에만 쓰이고 검수 판정에는 쓰이지 않는다(§2.6 · §6.1).

2. 데이터 출처와 수집량

2.1 수집 대상 선정 — 등록부(레지스트리) 현황

모든 수집기는 `collect/registry.py` 의 `require(source_id, use=…)` 로 시작한다. 등록부에 없거나, 이용조건 등급(G0~G3) × 용도(U1 학습 · U2 원문 색인 · U3 화면 인용 · U4 배포)가 허용하지 않으면 첫 줄에서 거부한다(D-15). 등급이 허용하는 용도 상한은 다음과 같다(`data_sources.yaml` 머리 · `tests/test_governance_layout.py` 가 검사).

등급	U1 학습	U2 원문 색인	U3 화면 인용	U4 배포
G3 원문 자유	가능	가능	가능	가능
G2 사실만 추출	가능	닫힘	닫힘	가능
G1 배제	닫힘	닫힘	닫힘	닫힘
G0 미확인	닫힘	닫힘	닫힘	닫힘

등록부 갈래별 수 (`data_sources.yaml` 을 2026-10-21 에 직접 셈 · 마지막 수정 커밋 `1b0af13`)

갈래	수	뜻	수집 원장에 오름
수집 `collect`	45	자동 수집기가 실행한다	29
수기 `manual`	10	자동 접근이 약관·robots 위반이라 사람이 받는다	7
보류 `hold`	15	판정이 안 끝났거나 이번 범위 밖 — 지금은 받지 않는다	0
(등재 계)	**70**	등급 G3 56 · G2 10 · G0 4	**36**
배제 `blocked` (G1)	13	법적·윤리적으로 막힘 — 탐침도 하지 않는다	—
미채택 `not_adopted`	14	조건·도메인·대체재 때문에 안 쓰기로 함	—
모델 가중치 `models`	8	qwen3_4b · kure_v1 · bge_reranker_v2_m3 · bge_reranker_base · kcbert_base · kcelectra_base · koelectra_base_v3(G3) · klue_roberta(G1)	—

09-17 뒤 **배제에 오른 3건**은 모두 기관의 서면·전화 회신으로 거절된 것이다 — 한국광고자율심의기구 심의결정자료(09-28 한국언론진흥재단 회신) · 한국제약바이오협회 광고심의 자료(09-29 협회 회신) · 특수용도식품 자율심의 심의사례(09-21 협회 전화 회신). 판정 매트릭스(근거 단위)는 105 판정이다(사실원장 「레지스트리 현황」 · 10-06).

2.2 원장에 오른 36종 — 출처 · 방식 · 수집량

원장 줄 = 받은 기록 수(같은 파일을 다시 받으면 줄이 늘어난다) · 고유 파일 = 경로 기준 · 크기 = 원장 줄의 bytes 합 · 마지막 수집 = 등록부 `collected_at` . 모두 팀 축 값이다.

소스 id	제공기관 · 자료	방식	층	상태 · 등급	원장 줄	고유 파일	크기 (MB)	마지막 수집
ftc_decisions_body	공정거래위원회 결정문 본문 조회 API	OpenAPI	1층 판정라벨	수집 · G3	16,525	8,272	389.8	09-20
mfds_cgm_expc	법제처 경유 식약처 1차 법령해석(질의회신·FAQ)	OpenAPI	1층	수집 · G3	5,129	5,129	11.5	09-20
mfds_cosmetic_func_report	식약처 기능성화장품 보고품목 API	OpenAPI	표시 문구 관측	수집 · G3	1,961	1,961	326.1	09-28
mfds_hf_ingredient_board	식품안전나라 건강기능식품 원료별 정보	게시판 HTML	2층 적법라벨	수집 · G3	1,334	672	116.0	09-09
law_go_kr	법제처 국가법령정보 OPEN API(법령·행정규칙·별표·판례·재결례)	OpenAPI	3·4·5층	수집 · G3	805	562	23.7	10-14
cosmetic_restricted	식약처 화장품 사용제한 원료정보 API	OpenAPI	제품 사실	수집 · G3	624	312	38.8	09-07
cosmetic_ingredient	식약처 화장품 원료성분정보 API	OpenAPI	제품 사실	수집 · G3	438	219	12.8	09-07
mfds_press	식약처 부당광고 점검 보도자료	게시판	1층	수집 · G3	424	214	147.0	09-09
inc_ad_decisions	인터넷신문윤리위원회 광고심의결정문	게시판 첨부(수기)	1층	수기 · G3	336	336	2,452.0	10-01
mfds_sanctions	식약처 행정처분결과 API(I0470)	OpenAPI	1층	수집 · G3	217	162	12.9	09-14
mfds_cosmetic_func_review	식약처(평가원) 기능성화장품 심사품목 API	OpenAPI	표시 문구 관측	수집 · G3	208	208	73.2	09-28
ftc_press	공정거래위원회 보도자료	게시판(수기)	1층	수기 · G3	147	147	76.9	09-28
gg_press	경기도 보도자료(부당광고 수사 결과)	게시판(수기)	1층	수기 · G3	23	23	8.9	09-28
kca_ad_survey	한국소비자원 표시·광고 실태조사	게시물 첨부(수기)	1층	수기 · G3	23	23	29.7	09-22
mfds_hf_ingredient	건기식 기능성 원료인정 현황 API(I-0040)	OpenAPI	표시 문구 관측	수집 · G3	20	12	0.9	09-14
mfds_hf_individual	건기식 개별인정형 정보 API(I-0050)	OpenAPI	2층 적법라벨	수집 · G3	18	11	0.9	09-14
scourt_major	법원행정처 · 대법원 누리집 「전국법원 주요판결」 게시판	게시판(수기)	1층	수기 · G3	12	12	0.7	09-28
foodsafety_penalty_std	식품안전나라 과징금 부과기준(I1660)	OpenAPI	4층 위험도	수집 · G3	12	6	0.4	09-10
mfds_casebook	식약처 식품 등 온라인 부당광고 사례집(2026)	자료실 PDF	1층	수집 · G3	2	1	11.4	09-09

소스 id	제공기관 · 자료	방식	층	상태 · 등급	원장 줄	고유 파일	크기 (MB)	마지막 수집
mfds_special_use_guide	식약처 특수용도식품 표시·광고 해설서	자료실 HWP	1층	수집 · G3	2	1	31.0	09-09
mfds_online_guideline	식약처 온라인 자율관리 가이드라인	자료실 PDF	3층 판단규범	수집 · G3	2	2	144.8	09-10
mfds_casebook_2021	식약처 온라인 부당광고 사례집 (2021)	자료실 PDF	1층	수집 · G3	1	1	23.8	09-18
mfds_ad_judge_manual_2015	식약처 허위·과대광고 판별 매뉴얼 (2015)	자료실 PDF	1층	수집 · G3	1	1	7.3	09-28
mfds_cosmetic_ad_qa	식약처 화장품 등 허위과대광고 질의응답집	자료실 PDF	1층	수집 · G3	1	1	6.1	09-25
mfds_cosmetic_ad_qa_2012	식약처 2012 화장품·의약외품 표시·광고 질의·응답집	자료실 PDF	1층	수집 · G3	1	1	1.1	09-28
mfds_cosmetic_faq_2020	식약처 화장품 분야 자주하는 질문집(2020)	자료실 PDF	1층	수집 · G3	1	1	2.6	09-28
mfds_cosmetic_func_qa_2023	식약처 기능성화장품 심사 질의응답집	자료실 PDF	1층	수집 · G3	1	1	1.1	09-28
mfds_food_func_claim_qa_2021	식약처 일반식품 기능성 표시제도 질의응답집	자료실 PDF	1층	수집 · G3	1	1	2.5	09-28
mfds_daegu_ad_cases_2013	식약처 대구지방청 허위과대광고 사례	자료실 PDF	1층	수집 · G3	1	1	4.2	09-28
mfds_hf_trial_ad_guide	식약처 건기식 인체적용시험 표시·광고 가이드라인	자료실 PDF	1층	수집 · G3	1	1	3.3	09-25
mfds_quasi_drug_ad_guide	식약처 의약외품 표시 광고 가이드라인	자료실 PDF	1층	수집 · G3	1	1	1.5	09-25
mfds_cosmetic_sanction	의약품안전나라 화장품 행정처분	엑셀 내려받기(수기)	1층	수기 · G3	1	1	0.0	09-22
mfds_cosmetic_ad_guideline	식약처 화장품 표시·광고 관리 지침	자료실 PDF	3층	수집 · G3	1	1	0.4	09-25
mfds_cosmetic_claim_test_guide	식약처 화장품 표시·광고 실증 시험방법 가이드라인	자료실 PDF	3층	수집 · G3	1	1	2.2	09-25
mfds_cosmetic_faq_2025	식약처 2025 자주하는 질문집(화장품)	자료실 PDF	3층	수집 · G3	1	1	2.5	09-26
easylaw_ad	법제처 찾기쉬운 생활법령정보(뒷광고 규제)	웹 본문(수기)	3층	수기 · G3	1	1	0.1	09-28
계					**28,277**	**18,300**	**약 3,968**	

- 「원장에 있다」는 팀의 누군가가 받았다는 뜻이지 모든 기기에 파일이 있다는 뜻이 아니다. 이 PC 의 보유량은 §5.1 에 있다.
- `law_go_kr` 는 이용조건이 같아 한 소스로 묶었다. 법령 · 행정규칙(고시 · 심사지침) · 별표 · 판례 · 재결례가 들어 있다. 2026-10-14 에 「건강기능식품의 기준 및 규격」 고시전문 첨부(`admrul_34650_20260611_attach.zip`)가 한 줄 더해졌다(§2.6).
- 크기는 `inc_ad_decisions` 하나가 약 2.45 GB 로 전체의 대부분이다(2015~2018 은 차수별 zip · 2016~2019 결정문은 글자 층이 없는 이미지 PDF — 등록부 `scale`).

2.3 아직 받지 않은 등재 소스 — 34종

갈래	소스	왜 아직인가
수집 · 1층	`ftc_decisions` · `ftc_decisions_api`	같은 결정문을 `ftc_decisions_body` 로 받았다 — 본문 수집기(`collect/ftc_body.py`)가 목록 → 본문을 차례로 불러 XML 로 받는다. 파일데이터(`ftc_decisions`)는 실물 PDF 의 일괄 다운로드가 없어 이 경로로 대신했고, 목록 API(`ftc_decisions_api`)는 증분 갱신용이다(등록부 `scale` · `collect/endpoints.yaml`)
수집 · 5층 코퍼스	`aihub_558` · `aihub_71486` · `aihub_71694` · `aihub_71723` · `bab2min_shopping` · `klue_dataset` · `nsmc`	판정 코어(1~4층)를 먼저 세웠다 — 등록부 게이트(2인 확인 · AI Hub 승인)는 열려 있으나 수집 원장 기록 없음
수집 · 6층 세그먼트	`aihub_review_corpus` · `kcc_media` · `kobaco_mcr` · `kosis` · `krei_food`	같음
수집 · 경제성 근거	`mfds_production` · `self_sanction_stat`	같음
수기	`mfds_cosmetic_ad_guide_2013` · `meta_adlibrary` · `google_atc`	`mfds_cosmetic_ad_guide_2013` (2013 화장품 공무원 지침서)은 PDF 에 글자 층이 없어 손으로 전사만 했다(전사본 89 행 · 원장 · 골든 밖 · 옛 판이라 후순위 — `docs/ohb/원천점검_2026-10-02.md` §3-3). `meta_adlibrary` · `google_atc` 는 화면 열람만 되는 G2 라 네 용도가 모두 닫혀 있다(약관)
보류	15종(`aihub_71843` · `apeach` · `foodsafety_faq` · `ftc_noviolation` · `google_trends` · `k_mhas` · `kcia_guideline` · `khff_survey` · `kisdi_panel` · `knhanes` · `kobaco_mcr_report` · `kocsc_ad_review` · `korean_hatespeech` · `platform_guide` · `youtube_api`)	이번 범위 밖 — 이용조건 미확인 · 도메인 불일치 · 다음 단계 안건 · 우선순위 낮음 등(등록부 `status: hold` · 각 `caution`). 수집기는 `hold` 를 거부한다(`collect/registry.py` `require`). `kocsc_ad_review` (방송 광고심의 자료)는 10-06 이용 가능 회신을 받았으나 골든셋 동결(10-05) 뒤라 예비 원천으로 두었다(등록부 `note`)

2.4 재배포 · 이용 제한

제한	해당 소스	무엇을 막나	근거
공개 배포 금지 `NOREDIST` · `redistributable: false`	**8**: AI Hub 6(`aihub_558` · `aihub_71486` · `aihub_71694` · `aihub_71723` · `aihub_71843` · `aihub_review_corpus`) · `inc_ad_decisions` · `kocsc_ad_review`	데이터셋 자체의 공개 배포. 모델 배포(U4)는 막지 않는다. 수집 원장에 오른 것은 `inc_ad_decisions` 하나다	`data_sources.yaml` · D-71
팀 내부 공유 칸 `internal_share`	`inc_ad_decisions`	공개는 막고 팀 비공개 저장소 안의 개발용 공유만 연다. 근거는 위원회 서면 회신(09-30)	등록부 `internal_share_basis` · D-303
비영리 `NC`	`inc_ad_decisions` (영리 활용은 재문의 전 불가) · `kobaco_mcr_report` · `knhanes` · `kisdi_panel` (뒤 셋은 보류)	상업 활용	등록부 `constraints`
변경금지 `ND`	`mfds_cosmetic_faq_2025` (공공누리 제3유형)	라벨 · 사전 · 학습 · 평가셋 등 파생 데이터셋. 원문 그대로 색인 · 인용만. 파생 산출물을 쓰기 직전에 `collect.registry.assert_derivable` 이 막는다	등록부 머리 · D-110
개인정보 `PII`	`inc_ad_decisions` · `scourt_major` · `kocsc_ad_review`	성명 등 직접 식별자는 파생물에서 마스킹한다. 마스킹 전 원문은 받은 기기 · 원문 받은편지함 · 팀장 전용 원문 거울에만 있고, git 저장소 · 파생물 공유 저장소 · 배포물에는 두지 않는다	D-17 · D-257(D-17 개정)
학습 용도 닫힘 `U1: deny`	원장에 오른 4종: `mfds_press` · `mfds_casebook` · `mfds_cosmetic_faq_2025` · `mfds_casebook_2021` (U2 도 닫힘). 그 밖에 아직 받지 않은 보류 13 · 수기 2 도 닫혀 있다(등재 19종)	수집기 게이트(`require`)에서 학습 용도를 막는다. 다만 이 칸은 「평가 전용」 표기로도 쓰였다 — 사례집(`mfds_casebook`)은 금지 표현 사전 원천이 되었고(D-155) 그 낱말 327 행이 골든 학습 쪽에 있다. 파생 데이터셋 게이트(`assert_derivable`)는 이 칸을 보지 않고, 법적 금지는 ND 로 따로 적는다. 보도자료(`mfds_press`)는 지금 골든 · 사전에 쓰지 않는다(§ 2.5)	등록부 머리 · `use` · `collect/registry.py` `assert_derivable`
원문 저장소 미커밋	`data/**` 전체	원문 · 파생물은 git 에 올리지 않는다. 저장소에는 원장(무엇을 언제 받았고 sha256 이 무엇인가)만 남긴다	D-19

골든셋의 행 단위 재배포 표시 (이 PC DB `golden_sample` · 2026-10-21)

묶음	행	`redistributable`	까닭
기관 문서가 인용한 광고 문구(11개 원천)	7,019	false	제3자 광고 문구 — 공개 배포 불가(D-249 · `preprocess/lineage.py`)
인정 문구 계열(`mfds_hf_ingredient_board` 1,232 · `mfds_hf_individual` 132)	1,364	true	식약처가 인정한 기능성 문구와 그 주입 문장

2.5 쓰임 — 원천이 어디에 들어가나

코드 · 파생물 원장 · 이 PC DB 로 확인한 실제 쓰임이다(2026-10-21 · `b54246d`).

원천	골든셋(행)	사전(항목)	근거 검색 · 판정 자료	카피 생성 화면
`ftc_decisions_body`	2,606	282	—	—
`mfds_special_use_guide`	2,526	—	—	—
`mfds_hf_ingredient_board`	1,232	(적법 겹침 표시 재료)	—	인정 문구 대조 목록 `mfds_hf_labels.jsonl` 465 행
`mfds_cgm_expc`	541	—	—	—
`mfds_casebook`	327(낱말 단위)	214	—	—
`mfds_cosmetic_ad_qa_2012`	201	—	—	—
`mfds_daegu_ad_cases_2013`	192	—	—	—
`mfds_ad_judge_manual_2015`	182	—	—	—
`mfds_cosmetic_ad_qa`	174(모두 평가 분할)	—	—	—
`mfds_hf_individual`	132	—	제품 사실 `product_fact` 447 행	인정 문구 대조 목록 `hf_api_labels.jsonl` 447 행
`ftc_press`	118(모두 평가 분할)	—	—	—
`mfds_casebook_2021`	83(모두 평가 분할)	—	—	—
`mfds_cosmetic_faq_2020`	69	—	—	—
`law_go_kr`	—	3,817(조문 꼴)	청크 6,686 · 제재표 `sanction_rule` 38 행 · 조문 표시(`law_article.jsonl` 3,798 행)	고시형 인정 문구 대조 목록 `hf_gosi_claims.jsonl` 169 행
`mfds_cosmetic_ad_guideline`	—	30(화장품 낱말)	—	—
`cosmetic_ingredient`	—	—	—	생성 후보 필터의 화장품 원료명 (`app/routers/copygen/filters.py`)
`mfds_hf_ingredient` (I-0040)	—	—	파생물 `hf_display_claims.jsonl` 773 행(업체 신고 표시 문구 · 관측 축)	대조 목록에 넣지 않는다(정본과 같은 것이 일부뿐 · `app/claim_match.py` 머리)
`mfds_press`	—	—	파생물(색인 4,344 · 라벨 135)	—
`cosmetic_restricted`	—	—	파생물 31,191 행(앱 · 학습에서 읽는 곳 없음)	—

- 골든셋 행 수는 13개 원천의 합 8,383 이다(이 PC DB `golden_sample.provenance`). 사전 4,342 항목의 출처 합은 4,343 이다 — 한 항목이 `ftc_decisions_body` 와 `mfds_casebook` 두 출처를 함께 가진다.
- 위 「카피 생성 화면」은 2026-10-21 기준 화면의 인정 문구 안내(건기식 분기)와 생성 후보 거름이다. 인정 문구 대조는 「이 문구가 식약처가 인정 · 고시한 문구와 글자가 같은가」만 본다 — 그 제품이 인정을 받았는지는 보지 않는다 (`app/claim_match.py`).

원장에 올랐지만 아직 파생물이 없는 원천 — 17종 (파생물 원장 · DB · 골든셋 어디에도 없다)

무리	소스	상태
후순위 원천	`inc_ad_decisions`	판단 근거가 4법이 아니라 위원회 심의규정이라 4법 조문으로 옮기는 판독이 따로 들고(등록부 `caution`), 영리 활용이 재문의 전까지 닫혀 있다(NC). 2026-10-03 팀장 지시로 데이터 작업 순서의 맨 뒤에 두었다 (`docs/ohb/원천점검_2026-10-02.md` §3-6)
판독 대기 1층	`gg_press` · `scourt_major` · `kca_ad_survey` · `mfds_cosmetic_sanction` · `mfds_sanctions` · `mfds_hf_trial_ad_guide` · `mfds_quasi_drug_ad_guide` · `mfds_cosmetic_func_qa_2023` · `mfds_food_func_claim_qa_2021`	원문만 보관
표시문구 관측	`mfds_cosmetic_func_report` · `mfds_cosmetic_func_review`	원문만 보관
3층 해설 · 규범	`mfds_online_guideline` · `mfds_cosmetic_claim_test_guide` · `easylaw_ad` · `mfds_cosmetic_faq_2025` (변경금지라 파생 데이터셋 불가)	원문만 보관 · 근거 조문 자리에 들어가지 않는다
4층 위험도	`foodsafety_penalty_std`	원문만 보관 · 제재표 38 행은 `law_go_kr` 별표에서 만들었다

2.6 09-17 이후 새로 들어온 원천

원장에 새로 오른 23종 — 09-17 판의 13종 밖에서 원장에 오른 것이다(마지막 수집일 기준).

- **09-18 ~ 09-22** — `mfds_casebook_2021` · `mfds_cgm_expc` · `kca_ad_survey` · `mfds_cosmetic_sanction`
- **09-25 ~ 09-26** — `mfds_cosmetic_ad_qa` · `mfds_cosmetic_ad_guideline` · `mfds_cosmetic_claim_test_guide` · `mfds_hf_trial_ad_guide` · `mfds_quasi_drug_ad_guide` · `mfds_cosmetic_faq_2025`
- **09-28** — `mfds_cosmetic_func_report` · `mfds_cosmetic_func_review` · `ftc_press` · `gg_press` · `scourt_major` · `easylaw_ad` · `mfds_cosmetic_ad_qa_2012` · `mfds_cosmetic_faq_2020` · `mfds_cosmetic_func_qa_2023` · `mfds_food_func_claim_qa_2021` · `mfds_ad_judge_manual_2015` · `mfds_daegu_ad_cases_2013`
- **10-01** — `inc_ad_decisions` (원문 336건 · 팀 받은편지함 전달 · 커밋 `190d180`)

건강기능식품 고시형 기능성 문구(`hf_gosi`) — 새 원천이 아니라 `law_go_kr` 의 새 파생물이다.

항목	값	근거
원문	법제처 API 가 준 「건강기능식품의 기준 및 규격」 고시(행정규칙 34650)의 첨부 「고시전문」 ZIP — 고시 제2026-43호 · 고시일 2026-06-11	원장 `law_go_kr` 10-14 줄 · `preprocess/hf_gosi.py` 머리

항목	값	근거
왜 따로 뽑았나	고시 본문 XML 에는 조문만 있고 원료별 기능성 내용은 첨부(HWPX)에만 있다. 그래서 종전 인정 문구 목록에는 개별인정형만 있고 고시형(비타민 · 칼슘 등)이 없었다	`preprocess/hf_gosi.py` 머리 · 사실원장 `product_fact` 「고시형은 0」
이용 조건	고시라 저작권법 제7조 보호 대상이 아님 — `law_go_kr` 등록 조건(G3) 그대로	등록부 `law_go_kr` `license`
파생물	`data/derived/hf_gosi_claims.jsonl` **169 행 · 원료 93** — 영양성분 48 · 기능성 원료 121 · 현행 166 · 2027-01-01 시행 개정 문구 3	§4 ⑥
실제 쓰임	카피 생성 · AI 광고 생성 화면의 인정 문구가 공식 문구와 같은지 개별인정형 두 목록과 함께 대조한다 · 시행 전 개정 문구 3 행은 뺀다	`app/claim_match.py` · `app/routers/user.py` `_fixed_match_notes`
남은 일	파생물 원장에 기록되지 않았다 — 파생물 원장 등재(팀장 · 정본 기기). 파일이 없는 기기의 결과는 아래	파생물 원장 · `docs/ksr/인정문구_경고대조_효과비교_ksr_2026-10-15.md` 「남은 일」

- **만든 곳 · 원장** — 2026-10-14 이 PC(`KSR_SKNPC`)에서 `python -m preprocess.hf_gosi --dump` 로 만들었다. 원본 ZIP(`admrul_34650_20260611_attach.zip`)은 수집 원장 마지막 줄(28,277 번째)에 있으나, 파생물 원장 `data/derived_manifest.jsonl` 에는 `ksr` · `main` 모두 이 파일이 없다.
- **파일이 없는 기기에서** — 「확인 못 함」이 아니다. 대조 코드는 없는 목록 파일만 건너뛰고(`app/claim_match.py` `_rows`), 「확인 못 함」(`no_data`)은 목록 파일 셋이 모두 없을 때만 낸다(`match`). 그래서 고시형 공식 문구 79개 중 개별인정형 목록에도 있는 32개는 「같음」, 고시형에만 있는 47개는 「목록에 없음」 38 · 「비슷함」 9 로 나온다(2026-10-22 이 PC 에서 고시형 목록만 뺀 채 대조를 다시 셈 · 파일은 읽기만). 이 대조는 카피 생성 · AI 광고 생성 화면의 안내(`app/routers/user.py` `_fixed_match_notes`)에만 쓰이고 검수 판정에는 쓰이지 않는다. 권소라 10-15 문서(`docs/ksr/인정문구_경고대조_효과비교_ksr_2026-10-15.md:134`)의 「확인 못 함이 뜬다」는 코드와 다르다.

3. 정제 결과 — 결측 · 중복 제거 전후 건수

3.1 지금 판(2026-10-21) — 원래 → 제거 · 처리 → 최종

「검사했고 0이었다」도 증빙이므로 적었다. 실측 번호는 §4 의 실행 결과 묶음이다.

단계	원래	제거 · 처리(사유)	최종	근거
A. 수집 원장 원장 줄 → 파일	28,277	같은 경로 재기록 −9,977(그중 내용까지 같은 것 9,148) · 행 전체 중복 0 · 필수 열(source_id · fetched_at · url · sha256 · bytes · path) 결측 0	18,300	실측 ①
원장 → DB `collect_manifest`	고유 sha256 19,123	`mfds_cosmetic_sanction` 1 — 그 소스가 DB `source` 에 없어 적재 안 됨(출처 표기 빈칸)	19,122	이 PC DB · 사실 원장 10-02 ⑤ 같은 규칙
B. 등재 → DB 적재 소스	70	보류 13 · 수기 4 — 2인 확인 미완 11 · 출처 표기(attribution) 빈칸 6 (적재 CHECK)	53	이 PC DB `source`
C. 공정위 의결서 원문 → 단계 파일	8,272 파일	의결서 1건 = XML 1파일	`ftc_stage` 8,272 행	파생물 원장
D. 화장품 원료 사용제한	31,191	행 전체 중복 1 — 원천의 서로 다른 두 레코드가 칸 끝 공백만 달라 전처리 뒤 같아짐(표 아래 ①) — 지우지 않음 · 성분명 결측 0 · 한도조건 빈칸 24,658 중 23,446 은 「금지」 원료라 한도가 원래 없다 — 보존	31,191	실측 ⑤
원료성분	21,897	행 전체 중복 0 · 성분명 중복 0 · CAS 번호 빈칸 92.8 % — 선택 필드라 보존	21,897	실측 ⑤
E. 건기식 인정 문구 개별인정형 I-0050	447	인정번호 고유 445(원문 그대로) · 444(정규화 · 표 아래 ②) — 같은 번호의 서로 다른 원료라 지우지 않고 (인정번호, 원료명) 쌍을 키로 씀 · 쌍 중복 0	447	실측 ⑥
원료별 정보 게시판	게시글 672 파일	게시물 중복 0 · 기능성 문구를 목록으로 정리	465 행	실측 ⑥ · 파생물 원장
고시형(고시 34650 첨부)	첨부 ZIP 1	원료 × 문구 하나로 나눔 · (번호, 문구) 겹침 2 = 같은 원료의 현행 문구와 2027 시행 개정 문구 — 보존하고 `시행` 칸으로 가름	169 행 (원료 93)	실측 ⑥
기능성 원료인정 I-0040	773	업체 신고 표시 문구라 정본이 아닌 관측 축으로 분리(D-185)	773	파생물 원장
F. 법령 · 별표 · 청크 조문	—	법령 · 행정규칙 조문 추출	3,798 행	파생물 원장 `law_article.jsonl`
별표 파싱	별표 5 파일	광고 판정과 무관한 법령 서식은 기본으로 받지 않음(D-220 · `collect/law_annex.py`)	243 행	파생물 원장 `law_annex/`
청크	—	chunk_id 중복 0 · 본문 결측 0 · 같은 본문 204 — 다른 법령 · 조문의 공통 문구라 보존 · 글자 수 2 ~ 700	6,686	실측 ④
G. 골든셋 · 사전 골든셋	—	id 중복 0 · 본문 결측 0 · 인용 상한을 넘는 재배포 불가 인용은 자르지 않고 버림 · 새 학습 행이 평가 행과 겹치면 학습 쪽을 뺌(D-316)	8,383	실측 ② · `preprocess/golden.py`

단계	원래	제거 · 처리(사유)	최종	근거
금지 표현 사전	—	term 중복 0 · term 결측 0 · 단독판정 4,189 / 후보 153	4,342	실측 ③

① **화장품 사용제한 중복 1**(에치씨청색5호 · EU · 금지) — 원천 응답의 서로 다른 두 레코드 (`data/raw/cosmetic_restricted/page_0255.json` 79번째 · `page_0295.json` 10번째)가 `CAS_NO` 끝 공백 · `INGR_ENG_NAME` 끝 줄바꿈만 달랐는데, 전처리(`preprocess/cosmetic.py`)가 칸 앞뒤 공백을 지우며 같아졌다. 09-17 판의 0 은 원문 기준이고 지금의 1 은 파생물 기준이다. 지우지 않았다.

② **I-0050 인정번호 고유 445 · 444** — 445 는 `인정번호` 칸을 원문 그대로 센 값이고, 444 는 정규화한 값이다 (`preprocess/hf_api.py` `rcogn_key` 가 「제」 「호」 「New」를 떼고 연도-번호로 맞춤). 차이 1 은 `New제2007-15호` 와 `제2007-15호` (바이오게르마늄 효모)다. 09-17 판의 444 와 「중복 3」(2007-15 · 2013-5 · 2021-5)은 정규화 기준이다. (정규화 번호, 원료명) 쌍 중복도 0 이다.

3.2 결측 · 중복 처리 원칙

경우	처리	예
키 열 결측	행 제외. 이번 실측에서는 모두 0	원장 필수 열 · 성분명 · chunk_id · 골든 id
선택 필드 결측(「해당 없음」)	보존 — 지우면 그 원료가 사라진다	한도조건 빈칸 24,658 중 「금지」 23,446 · CAS 번호 빈칸
모든 행이 빈 열	열을 쓰지 않는다	행정처분 대표자명 · 전화번호(09-17 기록)
결측을 문자열로 준 응답	저장 단계에서 거른다 — 문자열 "null" 은 `isnull` 로 잡히지 않는다	의결서 본문 미제공 4(09-17 기록 · §3.3)
원장(이력) 중복	지우지 않는다 — 언제 무엇을 받았는지가 증빙. 쓸 때 경로별 최신 판 선택	원장 같은 경로 9,977 줄
키는 같고 내용이 다름	지우지 않고 키를 넓힌다	인정번호 → (인정번호, 원료명)
같은 문장 · 다른 출처	보존 — 인용 근거가 다르다	청크 같은 본문 204
같은 원료 · 다른 시행일	보존하고 시행일 칸으로 가른다 · 대조에는 현행만	고시형 키토산 개정 문구
재배포 불가 인용이 상한을 넘음	버린다 — 자르면 문장이 끊겨 라벨이 안 맞는다	골든셋 생성 단계
평가와 겹치는 학습 행	학습 쪽을 뺀다 — 평가 행을 줄이지 않는다	골든셋 생성 단계(D-316)

3.3 09-17 판의 단계별 기록(참고)

09-17 제출본이 적은 단계별 전후 건수다. **행정처분(I0470)만 2026-09-17 클론 A 실측이고, 나머지 넷은 그 판이 사실원장(09-06 ~ 09-09 기록)에서 옮긴 값이다. 그 뒤 다시 재지 않았다** — 원문이 그 뒤 바뀐 원천(공정위 의결서는 09-19~20 에 다시 받아 8,272 파일)은 지금 값과 다르다.

단계	원래 → 최종	제거 사유
공정위 의결서 원천 → 저장	8,257 → 8,253	본문 미제공 4(모든 값이 문자열 "null")
식약처 행정처분 I0470	5,408 → 5,274	같은 처분 행이 두 번 이상 옴 134 — 합계가 원천 신고와 맞아도 서로 다른 행을 따로 센다(D-149). 09-17 판은 원인을 「offset 페이징 경계」로 적었으나, D-149 의 덧 기록은 장별 합계로 경계 겹침을 부정하고 원천 응답 자체의 겹침으로 적었다
과징금 부과기준 I1660	520 → 511	행 단위 중복 9(같은 계측 · D-149)
건기식 원료별 게시판	660 파일 → 419 레코드	기능성 내용이 없는 게시글 241
식약처 보도자료 문구	410 회 → 359 종	같은 문구 반복 51

09-17 표의 나머지 행 — 공정위 의결서 선별(8,268 → 856 → 285 문서 · 629 문구), 평가 누수 제외(사전 669 → 536 종 · 결함 주입 1,375 → 902 · 시험지 214 → 206 행), DB `golden_sample` 2,812 → 1,910 행, DB 적재 소스 47 → 32, 제품 사실 1,220 → 1,077 → 447 — 은 그 뒤 골든셋 · 사전 · DB 를 새 판으로 다시 만들었으므로 지금 판(§3.1)으로 대신했다. 평가와 겹치는 학습 행을 빼는 원칙은 지금 판에도 그대로다(§3.2).

4. pandas 통계 실행 결과

> 2026-10-21 · 이 PC(`KSR_SKNPC` · Windows 11 · 복제본) · Python 3.13.9 · pandas 2.2.3. 읽기만 한다 — 저장소 파일을 쓰지 않는다. 대상은 수집 원장(팀 축)과 파생물 원장 sha256 과 일치하는 파생물 파일이다(이 PC 에 있는 파생물 140개 모두 sha256 일치 · §5.1). 스크립트와 전체 출력은 작업 폴더의 `pandas_통계_스크립트.py` · `pandas_통계_출력_2026-10-21.txt` 에 있다. 09-17 판이 쓰던 `scripts/data_stats.py` 는 지금 저장소에 없다. 그래서 같은 항목을 위 스크립트로 다시 쟀다.

실측 ① 수집 원장 — shape · 중복 3축 · isnull · bytes describe(최소 · 최대)

```
>>> m = pd.read_json('data/manifest.jsonl', lines=True)
df.shape (28277, 9)
행 전체 중복 0
같은 path·sha256 9148
같은 path 9977
고유 path 18300 · 고유 sha256 19123
source_id 0 · fetched_at 0 · url 0 · sha256 0 · bytes 0 · path 0   (isnull().sum())
bytes  count 28277 · mean 140,339 · min 146 · 25% 5,386 · 50% 14,635 · 75% 44,292 · max 102,631,973
```

행 전체 중복이 0 인 것은 같은 파일을 다시 받아도 `fetched_at` 이 달라서다. 그래서 중복은 경로로 본다. 소스별 원장 줄 · 고유 경로 · 크기는 §2.2 표와 같다.

실측 ② 골든셋 — `data/derived/golden/golden.jsonl` (판 `94a79fe34363`)

```
df.shape (8383, 18)
id 중복 0 · text 결측 0
unit            낱말    문장    All
test_sentence      0   2489   2489
train            327   5567   5894
위반 라벨         없음    있음    All
test_sentence    775   1714   2489
train            905   4989   5894
origin      approved  injected  real    All
test_sentence     42         0  2447   2489
train            538       784  4572   5894
redistributable {False: 7019, True: 1364}
글자수 min 1 · max 195 · median 18
```

실측 ③ 금지 표현 사전 — `data/derived/banned_terms.jsonl` (판 `2ff0168c4a28`)

df.shape (4342, 11) · term 중복 0 · term 결측 0

단독판정 {True: 4189, False: 153}

출처 law_go_kr 3817 · ftc_decisions_body 282 · mfds_casebook 214 · mfds_cosmetic_ad_guideline 30

실측 ④ 청크 — `data/derived/chunks.jsonl`

df.shape (6686, 19) · chunk_id 중복 0 · text 결측 0 · 같은 text 204

law	doc_type			
건강기능식품법	법령	478	별표	45
식품표시광고법	법령	1,019	별표	1,072
표시광고법	법령	589		
화장품법	법령	857	별표	2,626

글자수 min 2 · max 700

실측 ⑤ 화장품 원료 — 사용제한 · 성분

사용제한 shape (31191, 12) · 행 전체 중복 1 · 성분명 결측 0

LIMIT_COND 빈칸 24658 · 그중 금지 23446

성분 shape (21897, 8) · 행 전체 중복 0 · 성분명 중복 0 · CAS_NO 빈칸 % 92.8

실측 ⑥ 건강기능식품 기능성 문구 — 고시형 · 개별인정형

고시형 shape (169, 16) · 원료(번호) 고유 93 · (번호,문구) 중복 2

구분 {'기능성 원료': 121, '영양성분': 48} · 시행 {'현행': 166, '2027-01-01': 3}

고시 건강기능식품의 기준 및 규격 제2026-43호 2026-06-11

I-0050 shape (447, 15) · 인정번호 고유 445 · (인정번호,원료명) 중복 0

원료 게시판 shape (465, 13) · 게시물 중복 0

5. 이 PC 에 없는 데이터와 골든셋 구성

5.1 이 PC 보유 현황 — 원문 · 파생물 (2026-10-21)

원문은 저장소에 올리지 않으므로(D-19) 기기마다 보유량이 다르다. 아래는 수집 원장의 경로별 최신 파일이 이 PC 에 있는지 직접 대조한 값이다.

무엇	이 PC	팀 원장
원문 파일	**10,539** 파일 · 약 3.12 GB	18,300 파일 · 약 3.58 GB
파생물	**140** 개(모두 파생물 원장 sha256 과 일치)	245 개 — 없는 105 개는 모두 보도자료 PDF 표 캐시(원문캐시 — 마스킹 전 원문이라 팀 공유 묶음에 넣지 않는다 · D-244 · D-257)

원문이 이 PC 에 없거나 일부만 있는 소스

소스	이 PC / 원장 고유 파일	이 보고서에 미치는 영향
`mfds_cgm_expc`	0 / 5,129	없음 — 쓰는 것은 파생물(골든 541 행)
`mfds_cosmetic_func_report`	0 / 1,961	없음 — 파생물 없음
`mfds_cosmetic_func_review`	0 / 208	같음
`law_go_kr`	242 / 562	없음 — 조문 · 별표 · 청크 파생물은 있다
`mfds_sanctions`	54 / 162	09-17 의 정제 기록(§3.3)은 다시 재지 않았다
`mfds_hf_individual` · `mfds_hf_ingredient` · `mfds_hf_ingredient_board`	5 / 11 · 8 / 12 · 662 / 672	없음 — 파생물이 있다
`mfds_press` · `ftc_decisions_body`	210 / 214 · 8,268 / 8,272	없음
PDF 1개짜리 7종	0 / 1 씩	`mfds_casebook_2021` · `mfds_cosmetic_ad_qa` · `mfds_hf_trial_ad_guide` · `mfds_cosmetic_claim_test_guide` · `mfds_quasi_drug_ad_guide` · `mfds_cosmetic_ad_guideline` · `mfds_cosmetic_faq_2025`

나머지 19종(`inc_ad_decisions` 336 파일 포함)은 원장의 고유 파일이 모두 이 PC 에 있다.

5.2 골든셋 구성 — 판 `94a79fe34363`

	train	test_sentence(평가 분할)	계
행	5,894	2,489	**8,383**
위반 라벨 있음	4,989	1,714(채점 행)	6,703
위반 라벨 없음	905	775	1,680

	train	test_sentence(평가 분할)	계
단위	문장 5,567 · 낱말 327	문장 2,489	
출처 종류	실제 문구 4,572 · 주입 784 · 인정 문구 538	실제 문구 2,447 · 인정 문구 42	

- **봉인 평가셋은 두 가지로 구분해 적는다.** 위 test_sentence 2,489 행은 골든의 평가 분할(그대로)이고, 2026-10-15 재분할(D-347) 뒤 인코더 · 판정 그래프 평가 도구가 쓰는 봉인 시험지는 그중 옮기지 않은 1,141 행(지문 `74e37657d39ec325`)이다. 옛 봉인 2,489 행은 2026-10-14 에 인코더 단독으로 한 번 잰 기록(보고 전용 · 판과 문턱을 고르는 데 쓰지 않음 · `docs/psj/reports/D4-T_봉인_test_20261014.md`)이 있고, 새 봉인 1,141 행은 아직 열지 않았다(D-339 · D-347). 그래서 이 보고서는 봉인 쪽의 행 수와 채점 행 수만 적는다. 모델 개발용 dev 749 행은 train 에서 떼어 낸 것이다(사실원장 · 지문 `4ebfcb231da703b5`).
- **조건 라벨**(이 PC DB `golden_sample.cond`): C 절대형 1,584 · B 실증형 2,764 · A 자격형 973 · M 모호 913 · D 판정 대상 아님 960 · L 적법 78 · 없음 1,111.
- **train 의 위반 유형 분포**(행 · 유형 쌍 · 한 행에 유형이 여럿일 수 있음 · 실측 ② 같은 파일)

유형	train	유형	train
거짓_과장	2,754	비방광고	308
소비자_기만	797	후기_체험기_기만	228
건강기능식품_오인	495	부당_비교광고	192
질병_예방치료_표방	460	기능성화장품_오인	28
의약품_오인	391		

- 09-17 판의 「8개 유형 중 문장 단위로 평가 가능한 것은 2개뿐」이라는 쏠림은 새 1층 원천 판독으로 줄었다. 다만 기능성화장품_오인은 아직 적다(train 28 · 확장 dev 양성 5 라 측정 불가로 둔다 — 채택 인코더 D4-20 의 `label_scheme.json` `waiting_note` · 박수진 D4 실험기록).

5.3 이 PC 에서 증빙을 채우는 방법

순서	무엇	명령
1	파생물 받기(정본이 올린 동결판)	`python launcher.py data-sync` (런처 메뉴 44 데이터 받기)
2	원문은 팀원 기기로 나누지 않는다(마스킹 전 원문 · D-257). 원문이 필요한 확인은 정본 기기(팀장)에 맡긴다	원문 거울 받기 `python launcher.py raw-mirror-sync` (런처 메뉴 51)는 팀장 계정에만 공유된 거울을 팀장의 다른 기기로 받는 명령이다(D-256)
3	팀 축 현황 다시 보기	`python -m scripts.data_status` (화면에만 낸다 — `--write` 와 런처 메뉴 14 는 현황판 파일을 덮어쓴다)
4	통계 다시 재기	작업 폴더의 `pandas_통계_스크립트.py`

6. 한계와 근거 문서

6.1 한계 · 남은 과제

- **5층 코퍼스 · 6층 세그먼트 · 경제성 근거는 여전히 원장에 0건이다**(등재 수집 소스 14종). 판정 코어(1~4층)를 먼저 세웠다.
- **원장에 오른 36종 중 17종은 파생물이 없다**(§2.5). 특히 `inc_ad_decisions`(약 2.45 GB)는 4법 조문으로 옮기는 판독이 들고 영리 활용이 닫혀 있어 데이터 작업 순서의 맨 뒤로 두었다(2026-10-03 팀장 지시).
- **2인 확인 · 출처 표기 미완 17종은 DB 에 적재되지 않는다**(2인 확인 미완 11 · 출처 표기 빈칸 6). 보류 13 · 수기 4 다.
- **고시형 기능성 문구 파일이 파생물 원장에 없다.** 파일이 없는 기기에서는 고시형에만 있는 공식 문구 47개가 「확인 못 함」이 아니라 「목록에 없음」(38) · 「비슷함」(9)으로 나온다(`app/claim_match.py` `_rows` · `match` · §2.6). 카피 생성 · AI 광고 생성 화면의 안내에만 영향이 있고 검수 판정에는 영향이 없다. 파생물 원장 등재가 남았다(팀장 · 정본 기기).
- **파생물 원장의 기록 시각은 모두 2026-10-18 이다.** 그 뒤에 바뀐 파생물이 있는지는 이 보고서에서 다시 확인하지 않았다.
- **새 봉인 평가셋(재분할 뒤 1,141 행)은 열지 않았다.** 옛 봉인 2,489 행은 10-14 인코더 단독 한 회차 기록(보고 전용)만 있다. 이 보고서의 평가 관련 수는 모두 행 수 셈이고 성능 수치가 아니다.
- **`data/**` 는 커밋되지 않는다** — 재배포 제한 자료가 섞여 있어 저장소에는 원장만 남긴다. 파생물은 팀 비공개 저장소(Google Drive)로 나른다(D-247 · D-249).

6.2 근거 문서

문서 · 파일	무엇인가
`data_sources.yaml`	등록부(레지스트리) — 등재 · 배제 · 미채택 · 모델과 이용조건 · 재배포 표시의 단일 출처(생성물)
`data/manifest.jsonl`	수집 원장 — 무엇을 언제 받았고 sha256 · 크기 · 경로가 무엇인가
`data/derived_manifest.jsonl`	파생물 원장 — 파생물의 부류 · 행 수 · sha256
`docs/00_사실원장.md`	수치의 단일 출처(D-54) — 「레지스트리 현황」 · 10-06 클론 A 적재 절
`docs/03_데이터/수집_데이터_보고서_2차.md`	09-28 판(10-06 갱신 · 팀장 작성) — 이 개정의 중간 판. 문서 안에 「09-28 제출본」이라 적혀 있으나 4주차 제출 묶음(전처리 결과서 2차 · 학습결과서 2차)에 없어 제출 여부는 확인되지 않았다. 이 개정은 마지막으로 제출이 확인된 09-17 수정본 PDF 의 구조를 따른다
`docs/03_데이터/데이터현황판.md`	현황 생성기의 저장본 — 지금 파일보다 2026-10-21 화면 출력(`python -m scripts.data_status`)이 새것이다
`preprocess/hf_gosi.py` · `app/claim_match.py`	고시형 기능성 문구 추출 · 인정 문구 대조
`collect/registry.py`	수집 게이트(`require` · `assert_derivable` · `team_shareable`)

주요 결정 — D-15(등급 × 용도 게이트) · D-17 · D-257(마스킹은 파생물에 · 마스킹 전 원문은 공유하지 않음) · D-19(등급 디렉터리 분리 · 원문 미커밋) · D-54(수치 단일 출처) · D-71(공개 배포 금지와 모델 배포는 다른 축) · D-220(fail-closed — 없음 · 모름을 통과로 세지 않는다 · 법령 서식은 기본으로 닫음) · D-110(공공누리 유형 · ND 게이트) · D-149(행 수가 맞아도 서로 다른 행을 센다) · D-155(사례집 = 사전) · D-185(정본 · 관측 축) · D-244(파생물 원장 · 원문캐시는 공유하지 않음) · D-249(인용 광고 문구는 재배포 불가 · 120자 상한 · 공개와 팀 내부 공유는 다르다) · D-303(팀 내부 공유 칸) · D-316(겹치면 학습 쪽을 뺀다) · D-347(인코더 재분할 · 봉인 시험지 1,141 행).