

멀티 에이전트 테스트 계획 및 결과 보고서

SKN Final Project 최종 산출물 — CopyLane

팀장 **오한빈**

팀원 **박수진 · 권소라 · 소성민 · 이서은**

작성자 **오한빈** (팀장 · §1 ~ §5) · **이서은** (§6)

도메인 제안 **권소라**

개정 **2026-10-21 · 기준 커밋 ksr b54246d · 10-22 확인 반영**

최종 산출물 · 개정 2026-10-21

목차

1. 테스트 계획 4

1-1. 네 층으로 가른다 4

1-2. 게이트 시험 — 판정 그래프 쪽 파일 4

1-3. 그래프 평가 — 시험지와 채점 규칙 6

1-4. 누수를 막는 규칙 7

1-5. 소스코드 8

2. 결과 ① — 게이트 시험 11

3. 결과 ② — 그래프 평가 13

3-1. 지금 판 (10-21) 13

3-2. 바뀌어 온 길 14

3-3. 인코더 판 대조 — D4-10 대 D4-20 15

3-4. 데이터 밖 적법 카피 — 처음 보는 문구에서 오판하지 않나 17

3-5. 응답 시간 18

3-6. 불변식 · 경로 동치 · 답 경로 18

3-7. 화면 왕복 (E2E) 19

4. 결과가 말하는 것 21

5. 한계 — 이 보고서가 말하지 못하는 것 22

6. sLLM(재생성 에이전트) 평가 결과 — 이서은 작성분 23

6-1. 시험 대상 23

6-2. 합격 기준 대비 결과 23

6-3. 앱 연결 · 화면 흐름 24

6-4. 한계와 상태 25

> **개정에서 바뀐 것** — 10-06 판은 인코더가 붙기 전의 기준선(사전만 쓰는 판정 그래프 · 봉인 평가셋)이었다. 이 판은 그 기준선을 그대로 남기고, 그 뒤 인코더를 판정 그래프에 배선한 결과(카드 17 → D4-10 → **D4-20**)와 게이트 시험 수, 불변식 · 경로 동치 검사, 화면 왕복(E2E), 응답 시간, sLLM 평가(§6)를 더했다.

이 문서가 다루는 것 — ① 판정 그래프(멀티 에이전트)를 무엇으로 어떻게 시험하나(계획) ② 게이트 시험 결과 ③ 그래프 평가 결과(10-06 기준선 → 인코더 배선 뒤 10-21) ④ 결과로 드러난 문제와 다음 ⑤ 한계 ⑥ sLLM(재생성 에이전트) 평가.

다루지 않는 것 — 판정 인코더 단독의 학습 · 평가(PR-AUC 등)는 학습결과서 · 박수진 보고서가 정본이다. 화면 자체의 시험은 서비스 테스트 보고서가 다룬다(여기서는 판정 응답이 화면까지 닿는지만 본다).

수치를 읽는 법 — 모든 측정값의 정본은 `docs/00_사실원장.md` (이하 「원장」)이고, 원장 날짜와 절 번호(예: 원장 10-21 ⑤)를 붙인다. 10-21 에는 클론 B 절과 클론 A 절이 따로 있어 클론 A 절은 「원장 10-21(A) ⑤」처럼 적는다 — 둘의 ⑤ 는 다른 측정이다. 측정마다 **기기 · 커밋 · 판(인코더 · 사전 · 골든)** 을 적는다. 기기 이름은 클론 B(팀장 집 기기 · 정본 측정 기기)와 클론 A(회사 기기)다. 그래프 평가는 게이트가 아니라 보고용 측정이다. 정답이 30 행 미만인 묶음은 「측정 불가」로 적는다.

---

1. 테스트 계획

1-1. 네 층으로 가른다

층	무엇을 보나	도구	언제	통과 기준
① 게이트 시험	구조와 계약이 깨지지 않았나 — 라우팅 · 리듀서 · 계약 · 문안 글자 · 누수 방지 · 기록 · 분기 불변식	`pytest -m gate` (`launcher.py check` = ruff → `pytest -m gate`)	커밋마다	전부 통과
② 그래프 평가	판정이 정답과 얼마나 맞나 · 처음 보는 적법 문구에 오판이 없나 · 경로가 달라도 판정이 같은가	`scripts/eval_graph.py` · `scripts/eval_diff.py` · `scripts/eval_rule.py`	판정 규칙 · 사전 · 골든 · 인코더 판이 바뀔 때	게이트가 아니다 — 보고용
③ 응답 시간	판정 한 번의 시간이 어디에 쓰이나 · 문장 수별 시간	`scripts/latency_probe.py` · `scripts/time_graph.py`	구조 · 기기 설정이 바뀔 때	판정 p95 3 초 미만(D-77)
④ 화면 왕복 (E2E)	판정 응답이 검수 화면까지 빠짐없이 그려지는가 · 답하면 다시 판정되는가	`scripts/e2e_review.py` (지은 문구 12)	판정 응답 꼴이 바뀔 때	보고용(실패 검사 수를 적는다)

- ①은 **답이 기기마다 같아야 하는 것**만 본다. ② ~ ④는 데이터와 기기에 따라 답이 달라 게이트로 두지 않고, 원장에 기기 · 커밋 · 판 지문과 함께 적는다(D-178).

1-2. 게이트 시험 — 판정 그래프 쪽 파일

건수 칸이 둘이다. 「10-06」은 그때 파일의 `def test_` 를 센 수이고, 「b54246d 수집」은 2026-10-21 이 PC에서 기준 커밋 사본에 `pytest -m gate --collect-only` 로 센 **게이트 표시 시험 항목 수**(매개변수로 펼친 수)다. 단위가 달라 두 칸을 바로 견주지 않는다. 수집만 했고 **실행하지 않았다**.

파일	10-06	b54246d 수집	무엇을 지키나
`tests/test_graph_routers.py`	46	106	라우터 함수를 그래프 없이 단독으로 · 컴파일본이 스텁과 같은 길을 간다 · 누적 키가 두 번 쌓이지 않는다 · 빈 팬아웃에서 멈춘다 · 병렬 법 노드의 결과가 다 쌓인다 · 스텁이 통과를 지어내지 않는다
`tests/test_contracts.py`	44	105	판정 계약 — 위반을 확정하면 근거 조문이 붙는다 · 통과는 확정이고 위험도가 가장 낮을 때만 · 확정 위반에는 불가 사유가 붙는다 · 픽스처 전부가 계약으로 파싱된다
`tests/test_contract_surface.py`	3	3	계약이 조용히 바뀌면 잡는다
`tests/test_judge_rule.py`	22	32	판정 규칙 · 평가 도구의 채점 · 불가 사유 진단 · 보수 기록 지표
`tests/test_judge_route.py`	4	4	검수 종착 라우팅
`tests/test_premise_branches.py`	15	23	품목 분기 — 전제 표 · 기록 규칙 · 기준 문안이 승인본과 글자가 같다
`tests/test_certificate.py`	7	7	증명서 조립기 — 사유 문안이 승인본과 글자가 같다 · 문안 없는 조합은 증명서를 내지 않는다

파일	10-06	b54246d 수집	무엇을 지키나
`tests/test_retrieve.py`	33	69	검색 코어 — 모든 질의가 거버넌스 조인을 든다 · 저장된 벡터의 모델과 대조한다 · 순위 융합이 한쪽에만 있는 것을 버리지 않는다
`tests/test_dictmatch.py`	6	17	사전 매칭 — 좌표 · 정규화가 사전 빌더 · 판정기 B 와 같다
`tests/test_dictionary_leak.py`	7	23	**평가셋이 판정 규칙을 고르지 못하게**(D-175)
`tests/test_sanction_rule.py`	16	25	제재표 · 위험도 하한

10-06 뒤 새로 생긴 게이트 파일(판정 그래프 쪽 · b54246d 수집)

파일	수집	무엇을 지키나
`tests/test_encode_node.py`	36	`encode` 노드 — 모델이 없으면 인코더를 올리지 않는다 · 인코더 후보는 후보 칸에만 실리고 위반 칸 · 분기 열쇠에 들지 않는다 · 품목 입력 판 계약
`tests/test_model_lock.py`	17	앱은 잠금(`models.lock.json`)의 채택 · 되돌림 판만 올린다
`tests/test_encoder_floor.py` · `test_encoder_estimate.py`	25 · 14	인코더 하한은 사전 하한과 칸을 갈라 보류 문장에만 · 추정 위험도는 표시 전용(판정 칸은 바뀌지 않는다)
`tests/test_absolute_tau.py`	19	인코더 쪽 절대형 확정의 세 거름(기능성 정형 낱말 · 옮긴 근거 · 확신 기준 τ)
`tests/test_substantiation.py` · `test_reference_articles.py`	6 · 8	실증 분기 문안이 승인본과 같다 · 참조 조항은 근거에 섞이지 않고 판정을 바꾸지 않는다
`tests/test_fold_invariant.py`	33	분기를 접든 펼치든 기록은 같다 · 두 하위 전제가 같은 위반으로 확정하면 기록도 확정 · 한 전제만 확정하면 기록은 확정하지 않는다 · 품목을 모르면 기록 문장에는 질문을 싣지 않고 고르기 대기로 둔다(분기 미리보기의 질문은 그대로 · D-348 보충 37 결정 2)
`tests/test_invariant.py`	8	기록 · 분기 불변식(`app.graph._invariant`) — 기록 확정 ⇒ 모든 분기가 같은 위반으로 확정 · 어긋나면 전제 보류로 내린다(운영) · 시험 환경은 거부
`tests/test_premise_known.py`	4	품목을 모르면 전제가 답인 확정(답 없이)도 하지 않는다
`tests/test_eval_answers.py` · `test_eval_diff.py`	8 · 8	평가 도구 — 답 경로 · 불변식 표시 · 품목만 넘기기 · 보류 종류를 행과 요약에 싣기 · 결과 파일 대조 · 경로 동치
`tests/test_hold_kind.py` (10-21 새로)	6	보류의 종류(계약의 계산 칸 `hold_kind`) — 답 대기 → 고르기 대기 → 확인 못 함 → 걸린 것 없음 → 그 밖 순서 · 응답에는 실리지만 저장 칸이 아니다 · 어느 종류도 통과가 아니다(D-348 보충 36 결정 4)
`tests/test_rejudge_premise.py` (10-21 새로)	3	고쳐 쓴 문구의 재판정(`_rejudge`)이 고른 전제를 입력으로 넘긴다 · 없으면 원문 품목 · 앞서 한 답(사실 · 실증)을 주면 같이 넘긴다(함수를 직접 부르는 시험 — 기준 커밋에서는 화면에서 답을 이 함수로 넘기는 배선이 없었다 · D-348 보충 37 결정 5 · 배선은 기준 커밋 뒤 2026-10-22 `ksr 6fec0bc` — §6-2 T9)
`tests/test_judgment_store_ssm.py` · `test_user_history_save.py`	38 · 38	판정 저장 · 검수 이력 저장
`tests/test_user_answer.py`	13	조건부 위반 질문에 답하면 다시 판정한다 · 꼴이 틀린 답은 거부

- 게이트 표시 시험 전체: **2,213 항목 · 139 파일**(b54246d 수집 · 1차 개정 때 `f8ebb09` 는 2,197 · 137) · 시험 전체 수집 3,382 항목 · 180 파일. 게이트 파일의 전체 목록은 `docs/00_거버넌스_집행계약.md` §1-3 이 정본이다.
- 이 보고서의 시험 수는 **게이트 표시 시험**(`launcher.py check` 가 돌리는 것)이다. 서비스 테스트 보고서가 적는 수(예: `b54246d` 3,368 passed)는 저장소 시험 **전체**를 한 번 돌린 결과라 셈 대상이 다르다(§2).
- 한 파일 안의 시험이 다 게이트인 것은 아니다 — 수집 수로 `test_contracts.py` 107 중 105 · `test_judge_rule.py` 38 중 32 · `test_retrieve.py` 94 중 69 · `test_user_rewrite.py` 74 중 4 · `test_copygen.py` 41 중 17 이 게이트다. `check` 는 게이트 표시가 없는 시험을 돌리지 않는다.

게이트 표시가 없는 판정 쪽 시험 — `launcher.py check` 가 돌리지 않는다

파일	b54246d 수집	무엇을 보나	실행 기록
`tests/test_api_judge.py`	1	판정 API 가 검수 그래프를 부르고 응답을 계약으로 감싼다	원장에 따로 적힌 실행 기록을 찾지 못했다
`tests/test_encoder.py`	11	인코더 추론 모듈(`app/encoder.py`) — 라벨 틀의 순서 · 문턱 읽기(모델 파일 없이 돈다)	원장에 따로 적힌 실행 기록을 찾지 못했다
`tests/test_user_rewrite.py` (게이트 밖 70)	74	검수 화면의 고쳐 쓰기 — sLLM 서버와 판정 코어를 가짜로 끼운다 · 서버가 없으면 후보를 그리지 않는다 · 고친 문구에 위반이 붙으면 후보가 아니다	이서은 실행 70 / 70(10-16 ~ 19 · §6)
`tests/test_copygen.py` (게이트 밖 24)	41	카피 생성 엔진 — 생성 모델 · 인코더를 대역으로 끼워 흐름만 본다(문구 품질은 재지 않는다)	—

- **픽스처** — `tests/fixtures/judge/` **28 건**(10-06 판 15 건에서 늘었다): 통과 · 보류 사유별 · 증명서 A · C · 지시 · 근거 없음 · 미판정 · 품목 분기 · 일반상품 · 사용자가 고른 품목 등 16 건 + 실제 DB · 잠금 채택 인코더(D4-20)로 받은 화면용 응답 12 건(`30_live_*` ~ `41_live_*` , `scripts/e2e_review.py --save-fixtures`). 계약 게이트가 이 픽스처를 전부 파싱한다.
- **게이트를 고치면 일부러 깨뜨려 본다** — 항상 통과하는 단언은 검사가 아니다(D-170). 10-21 의 기록 확정 결함에서도 새 시험을 고치기 전 동작에서 실패하는 것을 먼저 확인했다(원장 10-21 ② ③).

1-3. 그래프 평가 — 시험지와 채점 규칙

항목	값
판 · 규칙을 고르는 시험지	**dev**(학습 분할에서 뗀 749 행) · **확장 dev**(dev + 해설서 dev 398 = 1,147 행 · 10-21 에 일반상품 389 를 더해 조건부 1,132 행 · 채점 783)
봉인 평가셋	골든 `split` 칸의 `test_sentence` 는 2,489 행(채점 1,714)이다. 10-15 인코더 재분할(D-347) 뒤 평가 도구(`eval_graph` · `eval_rule`)가 봉인 회차에 쓰는 봉인 평가셋은 그중 인코더 학습 · dev 로 옮기지 않은 **1,141 행**(지문 `74e37657d39ec325` · D-347 결정 2)이다. 10-06 기준선(§3-2)은 재분할 전 골든(`529c970556d7`)의 당시 봉인 분할 2,489 행으로 쟀다. 골든 평가 분할 2,489 행은 10-14 에 판정 인코더 **단독**으로 한 번 쟀다(보고 전용 · 학습결과서 소관). **인코더를 단 판정 그래프의 봉인 회차(1,141 행)는 아직 돌리지 않았다** — 측정 방법과 문구로 끝나는 판정의 남은 문제를 고친 뒤 한 번 연다(D-339 결정 7 · D-348 보충 32 결정 4 · 범위와 조건은 보충 36 결정 1 · §3-6)
두 번 잰다	**무조건부**(품목을 모른다 · 세 법 전부) · **조건부**(골든의 품목 · 전제를 제품 정보로 넘긴다)(D-306)

항목	값
예측으로 세는 것	**확정 문장의 위반만** — 보류 · 근거 없음 · 미판정은 예측이 아니다
채점에서 빼는 행	조건 D(판정 대상 아님) · M(맥락이 있어야 판단)(D-286)
셈 단위	행 · 유형 · 호 — 정답 30 미만은 「측정 불가」(D-40 · D-282)
채점 규칙	판정기 B(`scripts/eval_rule.py`)와 **한 곳** — 같은 자로 잰다(D-99)

용어 — 「확정위반」 행: 판정 그래프가 위반을 확정한 행 · 「확정무위반」 행: 위반이 없다고 확정한 행(지금은 판정 대상 아님 문장) · 「보류」: 확정하지 않은 행 · 「종착」: 검수 그래프의 끝(**보류 > 증명서 > 지시 > 통과** 순서) · 「통과」는 법령 위반 소지가 검출되지 않았다는 뜻이지 안전 보장이 아니다.

지표는 열이다(①~⑦은 10-06 판, ⑧~⑩은 10-15 ~ 21 에 더함).

#	지표	뜻
1	응답 분포 · 보류율	종착과 문장 판정 상태 — 보류는 **사유별로** 센다(D-269). 10-21 부터 보류 **종류**(답 대기 · 고르기 대기 · 확인 못 함 · 걸린 것 없음 · 그 밖)도 함께 센다(D-348 보충 36 결정 4)
2	유형 · 호별 정밀도 · 재현율	확정한 위반이 정답 유형 · 호와 맞나
3	coverage · selective risk	판정을 내린 행의 비율 · 그중 틀린 비율(95 % 구간을 함께) — 둘을 쌍으로 본다(D-77)
4	확정 재현율 · 탐지 재현율	위반 행 중 확정한 비율 · 확정하거나 후보(사전 · 인코더)로 실은 비율
5	적법 문장 오탐	적법 문장을 위반으로 확정한 수 — 내역(주장 있음 · 없음)과 함께만(D-301)
6	보수 기록	확정 ∪ 전제를 몰라 멈춘 문장에 실린 위반을 「기록된 판정」으로 센다(D-263 ①). 10-21 보충 37 결정 2 뒤에는 고르기 대기로 바뀐 기록 문장의 사전 후보 유형도 이 셈에 들어가 수가 늘었다 — 판정이 아니라 셈법 몫이고, 셈법을 고칠지는 정하지 않았다(§ 3-6 · 원장 10-21(A) ⑥)
7	불가 사유 진단	확정 위반의 사유(A · B · C)를 라벨의 조건과 대조 — 게이트 아님
8	데이터 밖 적법	사람이 적법으로 판독한 처음 보는 카피(GPT 생성 · 정상 카피 네 묶음 1,160 행)를 품목 입력 · 모름 입력 두 번 넣어 확정위반 · 조건부위반 · 계약 위반을 센다
9	불변식 · 경로 동치	기록과 분기가 어긋난 행 수 · 「전제를 고른 판정 = 품목만 넘긴 판정의 그 전제 분기」가 어긋난 행 수(D-348 보충 35)
10	답 경로	질문이 선 행을 「모두 예 · 모두 아니오」로 다시 판정해 정답 유형에 닿는 비율(보고 지표 · 게이트 아님)

1-4. 누수를 막는 규칙

1. **봉인 평가셋으로 규칙 · 문턱을 고르지 않는다**(D-175) — 판 · 문턱 · 규칙은 dev 에서 고른다. 그래서 dev 수는 **낙관 쪽**이다.
2. 봉인은 저절로 열리지 않는다(10-15 · 작업 트리 검사는 10-20) — `eval_graph.py` 는 `--dev` · `--sealed` 를 꼭 받아야 돌고, 봉인 기록 도구(`scripts/sealed_log.py`)는 커밋 안 된 추적 변경이 있으면 봉인을 열지 않는다. 판정기 B(`eval_rule.py --sealed`)도 돌기 전에 봉인 기록에 한 줄을 남긴다(D-344 ⑧).

3. 사전의 단독 판정 자격 심사에는 학습 쪽 자료만 쓴다 — 게이트가 본다(`tests/test_dictionary_leak.py`).
4. 평가 결과 파일을 읽어 원인을 볼 때는 「진단」이라 적고 그것으로 규칙을 바꾸지 않는다.
5. 실행하지 않은 것은 「미실행」으로 적는다 — 예측은 예측이라 적고 재실행으로 확인한다(10-21 ⑤ 에서 43 행 중 41 행 예측 일치).

1-5. 소스코드

무엇	어디
판정 그래프	`app/graph.py` · `app/premise.py` · `app/reasons.py` · `app/dictmatch.py` · `app/retrieve.py` · `app/sanction.py` · `app/encoder.py` · `app/claimscope.py`
계약	`app/contracts.py`
평가 도구	`scripts/eval_graph.py` · `scripts/eval_diff.py` · `scripts/eval_rule.py` · `scripts/e2e_review.py` · `scripts/latency_probe.py` · `scripts/time_graph.py`
게이트	`tests/` — §1-2
실행	`uv run python launcher.py check` · `uv run python scripts/eval_graph.py --dev --guide-dev --conditional --out <파일>` · … `--conditional --answers` (답 경로) · … `--conditional --category-only` (품목만) → `uv run python scripts/eval_diff.py equiv <품목만> <고른 전제>`

- 평가 결과 파일은 `build/eval/` 에 쓴다(git 밖 생성물). 골든셋은 재배포 제약이 있어 공개 git 에 없다 — 공유 저장소로 받는다(D-249).

저장소 — https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN32-FINAL-3TEAM (이 절의 발췌는 브랜치 `ksr` 커밋 `b54246d`). 아래는 발췌이고 전문은 위 표의 경로에 있다.

코어의 순서는 표 하나가 정한다 — 컴파일한 그래프와 시험이 같은 표를 읽는다(`app/graph.py` `build_core`). 10-19 에 참고 조문을 판정 뒤에 고르는 `references` 노드가 끝에 붙었다. 법별 노드 셋(표시광고법 · 식품표시광고법 · 화장품법)은 `encode` 뒤에서 나란히 나뉘어 돌고 `merge_laws` 에서 합쳐진다. 10-21 에 `doc_rules` 가 품목을 모를 때 기록 문장의 질문을 걷는 일(`_pick_first` · 보충 37 결정 2)을 더했지만 노드 순서 · 수는 그대로다.

```
CORE_BEFORE_LAWS = ("split", "classify", "retrieve", "match_dict", "encode")
CORE_AFTER_LAWS = (
    "merge_laws",
    "judge",
    "assess_risk",
    "premise_branches",
    "doc_rules",
    "references",
)
```

검수의 종착은 우선순위 **보류 > 증명서 > 지시 > 통과**다. 10-21(D-348 보충 33)부터 답하기 전의 조건부 위반도 보류(답 대기)다 — 사용자가 답하지 않은 사실을 가장 나쁜 쪽으로 가정해 판정하지 않는다(`app/graph.py` `route_review` · 주석은 줄였다).

```
def route_review(state: ReviewState) -> str:
    sents = state.get("sentences", [])
    if not sents:
        return "hold"
    if any(s.verdict is not Verdict.confirmed for s in sents):
        return "hold"          # 답하기 전은 답 대기 — 조건부 위반도 보류
    if any(s.violations and s.risk.final is None for s in sents):
        return "hold"          # 위험도 없는 확정 위반은 증명서 · 지시로 못 간다
    reasons = {s.infeasibility for s in sents if s.infeasibility}
    if reasons & {Infeasibility.A, Infeasibility.C}:
        return "certificate"
    if Infeasibility.B in reasons:
        return "guidance"
    ...  # 통과는 확정 ∧ RO 일 때만 · 품목 미확정에는 맨 위 통과가 없다
```

10-21 에 더한 기록 · 분기 불변식 — 기록 문장이 분기 문장들과 어긋나면 바로잡고(운영) 로그를 남긴다. 시험 환경에서는 거부한다(`app/graph.py` `_invariant` · 주석은 줄였다).

```
def _invariant(rec, per, reason):
    if not per or rec.not_claim:
        return None
    same = _all_same_confirmed(per)
    if rec.verdict is Verdict.confirmed:
        if same is not None and same == frozenset(rec.violations):
            return None
        _breach("①", rec, per, fixed=True)      # 기록 확정 ⇒ 모든 분기가 같은 위반으로 확정
        return _premise_hold({k: getattr(rec, k) for k in type(rec).model_fields}, reason)
    if same:
        _breach("②", rec, per, fixed=False)     # 모든 분기가 확정인데 기록이 아니면 로그만
    return None
```

게이트 시험은 이 규칙들을 고정한다 — 「사전에 안 걸렸다」가 통과가 아니라 보류라는 것(`tests/test_judge_rule.py`), 분기 노드가 위험도 뒤에 서고 그 출력이 코어 밖으로 나간다는 것(`tests/test_premise_branches.py`).

```
@pytest.mark.gate
def test_사전에_안_걸리면_보류다() -> None:
    s = _one(_state("하루 한 포", []))
    assert s.verdict is Verdict.hold and s.hold_reason is HoldReason.low_conf
    assert not s.violations


def test_분기_노드가_코어_순서와_출력에_들어_있다() -> None:
    assert "premise_branches" in CORE_AFTER_LAWS, "분기 노드가 코어 순서에 없다 (D-319)"
    assert CORE_AFTER_LAWS.index("assess_risk") < CORE_AFTER_LAWS.index("premise_branches"), (
        "분기는 위험도 뒤에 선다 — 같은 문장을 바꿔 끼운다"
    )
    assert "branches" in CORE_OUT, (
        "`branches` 가 코어 출력에 없으면 검수 그래프가 분기를 못 받는다 (오류 없이 빈 목록)"
    )
```

2. 결과 ① — 게이트 시험

마지막 줄(이 PC 수집)을 빼면 모두 팀장 실행 출력 · `launcher.py check` 다. 「passed」만 세고 skipped · xfailed 는 따로 적는다. 커밋 칸은 원장 표기를 따른다 — 10-20 · 10-21 의 수는 원장에 「그 커밋 전 작업 트리」로 적혀 있다.

시점 · 기기	커밋	결과	무엇이 들어온 뒤인가 · 출처
10-05 · 클론 B	`d592072` 직전	1,355 passed · 2 skipped	품목 분기 1 판 · 사유 진단 칸 — 출처는 10-06 판 보고서(원장에는 이 수가 없다)
10-06 · 클론 B	`6d84bc0`	1,356 passed · 2 skipped	기준 문안 승인 · 분기 켬
10-06 · 클론 B	`8dff824`	1,363 passed · 2 skipped	증명서 조립기 · 보수 기록 지표
10-06 · 클론 A	`9943002` · `68ae677` 뒤	1,363 passed · 2 skipped	재동결 10-05 판 받기 · 팀원(ssm · lse) 흡수 뒤(원장 10-06 ① ②)
10-14 · 클론 A	ohb `19d6f54` 기준	1,650 passed · 2 skipped	인코더 배선(카드 17) 뒤 — 출처는 원장이 아니라 저장소 보고서 10-14 갱신 절
10-15 · 클론 B	`a66c2f7`	1,747 passed · 2 skipped	인코더 D4-10 · 판정 대상 아님(L0)(원장 10-15 ④)
10-16 · 클론 B	`861c002`	1,803 passed · 2 skipped	인코더 하한 · 조건부 위반(원장 10-16 ④)
10-18 · 클론 B	`ff45313` 위 작업 트리	1,911 passed · 4 skipped	사전 쪽 분기 경로 걷음(원장 10-18 ⑫)
10-19 · 클론 B	`62d8b1a` 작업 트리	1,976 passed · 4 skipped	**D4-20 잠금 채택** · 인증 · 실증 거름(원장 10-19 ②)
10-19 · 클론 B	`cfa398d` 작업 트리	2,094 passed · 4 skipped · 1 xfailed	참고 조문을 판정 뒤에(원장 10-19 ⑬) · xfailed 1 은 화면 결함(`일반식품_기능성` 분기 미표시)
10-20 · 클론 B	`7847a55`	2,104 passed · 4 skipped · 1 xfailed	품목을 모르면 전제 확정 없음(원장 10-20 ③)
10-21 · 클론 B	`e6d442c` · `34a0eb4` · `0d29d12`	2,131 → 2,133 → 2,135 passed · 4 skipped · 1 xfailed	보충 32 · 기록 확정 결함 고침 · 보충 33(원장 10-21 ① ③ ④)
10-21 · 클론 B	**`01287d6`**	**2,160 passed** · 4 skipped · 1 xfailed	보충 34(이어 묻기 · 고른 전제는 입력)(원장 10-21 ⑤)
10-21 · 클론 A	`87506a9`	2,160 passed · 4 skipped · 1 xfailed	클론 B 와 같은 수(원장 10-21(A) ①)
10-21 · 클론 A	`04b34cf` 작업 트리	2,189 passed · 4 skipped · 1 xfailed	보충 35(불변식 검사 · 답 경로 · 경로 동치)(원장 10-21(A) ③)
10-21 · 클론 A	**`49aafce`**	**2,204 passed** · 4 skipped · 1 xfailed	보충 36(보류 종류) · 보충 37 결정 2 · 5(품목 모름 기록 질문 걷기 · 재판정에 고른 전제)(원장 10-21(A) ⑥ · 예측 2,204 맞음) — **원장에 적힌 마지막 `check`**

시점 · 기기	커밋	결과	무엇이 들어온 뒤인가 · 출처
10-21 · 이 PC	`ksr b54246d`	게이트 표시 시험 **2,213 수집** (139 파일) · **`check` 실행 기록 없음**	`pytest -m gate --collect-only` (이 문서 작성 중 기준 커밋 사본에서 확인)

- 원장 10-21(A) 는 클론 A(회사 기기)에서 팀장이 돌린 절이다(①~⑥). 10-21 ⑤(클론 B)와 절 이름이 다르니 구분해 읽는다.
- 2,213 은 수집 수이고 통과 수가 아니다. 기준 커밋 `b54246d` 에서 `check` 를 돌린 원장 기록은 없다. 수의 짜임 — `49aafce` 의 2,204 passed · 4 skipped · 1 xfailed = 2,209 항목 + 두 겹 안내 시험 1(`ba257fd` · `tests/test_guide.py`) + ksr 쪽에만 있는 3 항목(`tests/test_user_answer.py` 11 → 13 · `tests/test_user_history_owner.py` 7 → 8) = 2,213. 1차 개정 때(`f8ebb09` · 2,197)와 견주면 새 시험 파일 2 개(`test_hold_kind.py` 6 · `test_rejudge_premise.py` 3)와 고친 파일(`test_fold_invariant.py` 28 → 33 · `test_eval_answers.py` 7 → 8 · `test_guide.py` 8 → 9)이 +16 이다.
- **서비스 테스트 보고서의 pytest 수와 다른 셈이다** — 그 보고서는 같은 날 이 PC 에서 저장소 시험 **전체**(`pytest -q` · 게이트 표시 없는 시험 포함)를 돌린 결과를 적는다: `f8ebb09` 3,344 passed · 8 failed · 8 skipped · 6 xfailed(수집 3,366) → `b54246d` 3,368 passed · 0 failed · 8 skipped · 6 xfailed(수집 3,382). 위 표는 `launcher.py check` (ruff → `pytest -m gate`)의 **게이트 표시 시험만** 센 수다. `f8ebb09` 의 실패 8 건은 모두 게이트 표시가 없는 화면 시험이었다. `b54246d` 의 전체 실행에서 실패가 0 이었으니 그 안에 든 게이트 시험 2,213 항목도 실패하지 않았다고 읽을 수 있지만, 이는 서비스 테스트 담당의 실행 로그이지 `check` (ruff 포함)나 원장 기록이 아니라서 위 표에 넣지 않았다.
- skipped 는 10-18 부터 4(정본 판 · DB 시험 조건)이고, xfailed 1 은 10-19 부터 화면 결함 하나를 표시한다(§3-7).
- **시험이 잡아 낸 것** — 10-06: 분기를 켜자 `tests/test_graph_routers.py` 9 건이 실패했다(분기 노드가 걸린 낱말이 없을 때도 제재표를 읽으려 함 → 고침). 10-21: 기록을 분기에서 모으는 규칙이 「두 하위 전제가 같은 위반으로 확정」을 기록에 올리지 못한 결함(확정 7 행이 보류로 되돌아감)과, 고치는 중 「한 전제만 확정해도 기록이 확정」되는 결함이 차례로 드러났다. 두 경우 모두 되돌림 막이 시험을 먼저 넣고(고치기 전 동작에서 실패 확인) 고쳤다(원장 10-21 ② ③).

3. 결과 ② — 그래프 평가

3-1. 지금 판 (10-21)

커밋 `01287d6` · 원장 10-21 ⑤ · 클론 B · 확장 dev.

판 표지 — 인코더 **D4-20**(`copylane-encoder-kcbert-D4-20-기능성편입` · 판 지문 `c451942436f0` · 잠금 채택) · 사전 `2ff0168c4a28` (4,342 종 · 단독판정 4,189) · 골든 `94a79fe34363` . 게이트 아님.

	조건부	무조건부
평가 행(채점 행)	1,132 (783)	1,147
확정위반 행	**75**	0
조건별 확정위반	A 24 · B 2 · C 46 · D 1 · M 2 · L 0	—
확정무위반 행	53	53
보류 행 · 종착 보류	1,004 · 1,011	1,094 · 1,147
종착 증명서 · 통과	68 · 53	0 · 0
보류 사유(행)	확신 부족 1,006 · 전제 미정 6	확신 부족 987 · 품목 선택 필요 122(`49aafce` 재측정에서 825 · 296 — 아래)
selective risk	**1.5 % [0.3 %, 8.1 %]**	—
coverage	8.4 %(판정을 내린 행 66 / 783)	—
적법 문장 오탐	0 / 38(10-21 ④ 값 · ⑤ 에는 따로 적히지 않았다)	0 / 38(④ 와 바이트 같음)
데이터 밖 적법(네 묶음 × 두 입력)	확정위반 0 · 조건부위반 0 · 계약 위반 0	
실행 시간	479 초	544 초

- **판정을 내린 행이 처음으로 30 을 넘었다(66)** — 그래서 selective risk 를 「측정 가능」으로 적는 첫 측정이다. 그 앞 측정(10-21 ④ · 26 행)은 n < 30 이라 측정 불가였다.
- 직전(10-21 ④ · `0d29d12`) 대비 조건부 확정위반 32 → 75 · 바뀐 43 행은 모두 보류 → 확정위반이고 확정이 보류로 간 행은 0 이다. 새 확정 43 중 정답 유형 40 · 틀림 3 — 틀린 셋은 모두 식품 전제의 건강기능식품 오인(라벨 B 유형 틀림 1 · D 적법 1 · M 모호 1)이다. D · M 행은 채점 밖이다(§ 1-3).
- 무조건부는 직전과 행 · 요약 모두 바이트까지 같다 — **품목을 모르면 기록에 확정위반이 없다**(설계대로 · D-348 보충 8 · 18 · 31). 대신 「품목 선택 필요」 122 행으로 사용자에게 품목을 묻는다. 무조건부 보수 기록은 기록이 있는 채점 행 55 · 그중 틀림 14 · 인코더 후보까지 탐지 645 행(원장 10-20 ③ · 10-21 ④ 와 같음).
- **무조건부는 그 뒤 한 번 더 쟀다**(원장 10-21(A) ⑥ · 클론 A · `49aafce`) — 품목을 모르면 기록 문장에 질문을 싣지 않게 한 뒤(보충 37 결정 2) 확정위반 0 · 확정무위반 53 · 보류 1,094 · 종착 보류 1,147 은 그대로이고(분류 이동 0), 바뀐 행은 기록에 질문이 달렸던 178 행이다(예측과 같음). 보류 사유(행 · 한 행에 여럿이면 각각 셈)는 확신 부족 987 → **825** · 품목 선택 필요 122 → **296** 이 됐다. 보수 기록은 55 → 87 행(틀림 14 → 15 · 17.2 %)으로 늘었는데 판정 · 위험도가 바뀐 것이

아니라 지표 셈법 묶이다(§3-6). **조건부 수(위 왼쪽 칸)는 이 코드로 다시 재지 않았다** — 조건부의 정본은 여전히 10-21 ⑤ 다.

- 확정무위반 53 · 통과 53 은 모두 판정 대상 아님(조건 D · 주의 · 상담 문구) 행이다 — 품목을 알 때만 통과로 간다(D-319 결정 2).
- 같은 측정 블록이 한 번 더 돌았다 — 위 대조는 첫 실행 파일이다. 클론 A 가 조건부의 같은 수를 재현했다(원장 10-21(A) ① · `87506a9`).

3-2. 바뀌어 온 길

(가) 10-06 기준선 — 봉인 평가셋 · 인코더 없음 (커밋 `8dff824` · 원장 10-03 ㊿-39 · ㊿-40 보충 1 · 클론 B · 판정 `rule-0.3.0-dict` · 골든 `529c970556d7` · 사전 `455f8d7ea5c2`)

	무조건부	조건부
평가 행(채점 행)	2,489 (1,819)	2,225 (1,599)
종착 — 증명서 · 보류	0 · 2,489	21 · 2,204
확정 위반 행	6	56
전제를 몰라 멈춘 행	`cat_unknown` 89	`premise_unknown` 27
coverage	0.3%	2.8% (44 / 1,599)
selective risk	83.3% (6 행 중 5)	22.7%
확정 재현율	0.1%	2.5%
탐지 재현율(확정 ∪ 후보)	16.1%	17.0%
적법 문장 오탐	0 / 143	0 / 133
보수 기록 — 기록 행 중 틀림	25 / 86 (29.1%)	18 / 75 (24.0%)

- 조건부는 승인 문구 규칙으로 만든 행 42 를 뺀 수다. 무조건부의 확정 6 행은 수로 말하기에 작다. 실행 시간 — 무조건부 815 초(행당 328 ms) · 조건부 749 초(337 ms).
- 10-06 안에서 바뀐 길 — 기준선(㊿-30 · `8a5e9a7`) 확정 위반 무조건부 95 · 조건부 86 · 전부 보류 → 분기 켬(㊿-39 · `6d84bc0`) 6 + `cat_unknown` 89 · 58 + `premise_unknown` 28 → 조립기(㊿-40 보충 1 · `8dff824`) 6 · 56 · 조건부 증명서 21. 분기는 판정의 상태만 바꿨다(탐지 재현율 · 적법 오탐은 세 판에서 그대로). 분기를 켜기 전 「95 → 6 + 89」, 조립기 전 「증명서 21」을 예측해 적어 두고 재실행으로 확인했다.

(나) 인코더 배선 뒤 — dev · 확장 dev (모두 팀장 실행 · 게이트 아님)

날짜 · 원장 · 기기	인코더 · 시험지	주요 수
10-14(A) ⑧ · 클론 A	카드 17 · dev 749 무조건부	종착 보류 686 · 지시 63 · 보류율 91.6 % · 확정 재현율 12.7 % · 탐지 20.8 % · 인코더 후보까지 83.1 % · 무엇이든 걸린 위반 행 94.3 %
10-14(A) ⑦ · 클론 A	카드 17 · 배선 회귀	배선이 만든 차이 0(10-13 결과 파일과의 차이는 모두 그 뒤 결정 몫)

날짜 · 원장 · 기기	인코더 · 시험지	주요 수
10-15 ① · 클론 B	D4-10 · dev 749 무조건부	종착 · 확정 · 탐지는 카드 17 과 같음 · 인코더 후보까지 84.1 % · selective risk 0.0 % · coverage 12.2 %
10-15 ② · 클론 B	D4-10 · 확장 dev 1,147 무조건부 · 조건부 743	무조건부 보류율 94.5 % · 탐지 19.9 % · 인코더 후보까지 74.9 % · 무엇이든 91.3 % · selective risk 0.0 % · coverage 8.0 % / 조건부 사전 확정 칸 selective risk 18.2 %(n = 11 · 측정 불가)
10-15 ④ · 클론 B	판정 대상 아님(L0) 집행	바뀐 행 53 = 모두 라벨 D · 보류 → 확정무위반(위반 행 변화 0)
10-16 ④ · 클론 B	조건부 위반 집행	확정위반 65 → 조건부위반 65(종착 그대로)
10-19 ① · 클론 B	**D4-10 → D4-20** · dev 조건부 345	아래 §3-3
10-19 ⑫ · 10-20 ③ · 클론 B	D4-20 · 확장 dev 무조건부 1,147	확정위반 0 · 확정무위반 53 · 품목 선택 필요 122 · 적법 문장 오탐 0 / 38 · 품목을 모르면 전제 확정도 하지 않음(분기의 식품 3호 확정 53 → 0)
10-21 ① ~ ④ · 클론 B	D4-20 · 확장 dev 조건부 1,132	결함 발견과 고침(§2) · ④ 확정위반 32 · selective risk 0.0 % [0.0 %, 12.9 %](판정 행 26 · 측정 불가)
10-21 ⑤ · 클론 B	D4-20 · 확장 dev 조건부 1,132	**확정위반 75 · selective risk 1.5 % [0.3 %, 8.1 %] · 판정 행 66** (§3-1)
10-21(A) ② ~ ④ · 클론 A	D4-20 · 확장 dev 무조건부 · 조건부 · 품목만	불변식 0 · 경로 동치 어긋남 0 / 668 · 답 경로 첫 측정(§3-6)
10-21(A) ⑥ · 클론 A	D4-20 · 확장 dev 무조건부 1,147 · `49aafce`	분류 그대로 · 바뀐 행 178 · 확신 부족 987 → 825 · 품목 선택 필요 122 → 296 · 보수 기록 55 → 87 행(셈법 몫)(§3-6)

- 시험지가 바뀌어 왔다 — 10-06 은 봉인 평가셋, 10-14 부터는 dev, 10-15 부터 확장 dev, 10-21 부터 일반상품 389 행을 더한 확장 dev 다. **행 수 · 정의가 달라 같은 지표라도 시험지가 다른 수를 바로 견주지 않는다.**
- 인코더는 10-16 ② 측정까지는 판정에 들지 않았다(후보 칸에만 실림 · D-323). 10-16 ⑧(D-348 보충 5 · 인코더 쪽 판정 1단계)부터 그 뒤의 보충 결정으로 인코더 쪽 판정이 단계마다 들어왔고, 단계마다 위 표처럼 다시 쟀다.

3-3. 인코더 판 대조 — D4-10 대 D4-20

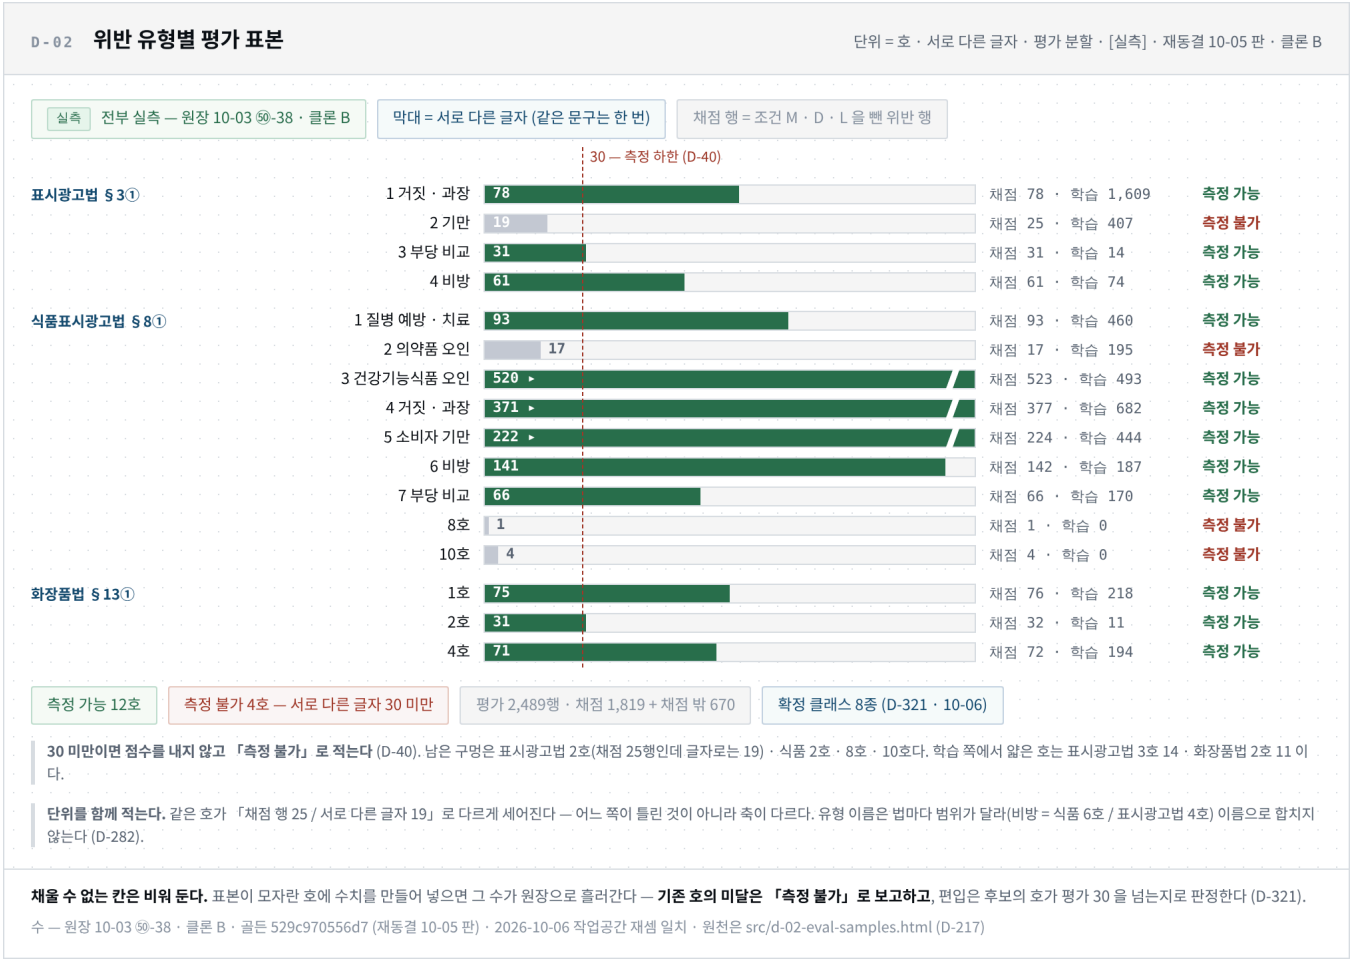
원장 10-19 ① · 클론 B · `ebd284a` · dev 조건부 345 행 · 채점 221.

지표	D4-10	D4-20
확정위반 행	35	32
selective risk	4.0 %(1 / 25)	0.0 %(0 / 24)
보수 기록 틀림	1 / 37	0 / 36
틀린 · 모호 확정(라벨에 없는 유형)	5	3
micro 정밀도 · 재현율	0.969 · 0.128	1.000 · 0.124

지표	D4-10	D4-20
의약품 오인 정밀도 · 재현율(정답 34)	0.875 · 0.206	1.000 · 0.235
질병 표방 재현율(정답 30)	0.467	0.500
후기 재현율(정답 15 · 측정 불가)	0.600	0.400
인코더 후보까지 탐지	78.0 %	81.8 %
적법 행의 인코더 하한	0 / 72	0 / 72

- 바뀐 행 7 — 좋아짐 4(틀린 의약품 오인 확정 2 빠짐 · 맞는 확정 2 더함) · 나빠짐 3(후기 C 행 확정 → 보류). 이 측정 뒤 D4-20 을 잠금 채택했다(판 지문 `c451942436f0` · D-349 · D4-10 은 되돌림 맨 앞).
- 이 표의 selective risk(4.0 % · 0.0 %)는 판정을 내린 행이 25 · 24 로 **30 미만이라 참고값**이다(D-40 · 측정 불가 기준). 10-19 의 dev 345 행 측정이고, 지금 판 · 확장 dev 의 값은 §3-1 의 1.5 %(판정 행 66)다.
- 10-06 기준선의 호별 표(아래 (다))는 인코더 배선 뒤 같은 형식으로 다시 내지 않았다 — 유형별 수는 위 표가 최신이다.

(다) 10-06 기준선의 호별 · 증명서 내역 (기준선 ⑤⓪-30 · 무조건부 · 정답 30 이상 · 분기를 켜기 전의 판)



> 도면 D-02 (2026-10-06 판 · 원장 10-03 ⑤⓪-38 · 클론 B · 재동결 10-05 판 골든) — 호마다 평가 표본이 얼마나 있는지다. 막대는 서로 다른 글자 수다. 30 미만인 네 호는 측정 불가다. 지금 골든(`94a79fe34363`)으로 다시 그리지 않았다.

호	정밀도	재현율
식품표시광고법 제8조① 1호	.909	.213
5호	1.000	.051
3호	.714	.038
4호	.438	.017
표시광고법 제3조① 1호	.500	.013

- 재현율이 0 인 호가 일곱이었다 — 표시광고법 3호 · 4호 · 화장품법 제13조① 1호 · 2호 · 4호 · 식품표시광고법 6호 · 7호. 그때 사전에 화장품법 인용 항목이 0 이었다(원장 10-03 ㊿-31).
- 분기를 켠 뒤(`8dff824`)에는 무조건부에서 0 이 아닌 호가 표시광고법 1호 하나였고, 조건부의 식품 3호는 재현율 0 이 됐다(일반식품 기능성 전제가 3호를 판정하지 못함). 그 뒤 식품 분기 3호 확정 · 전제 확정 확신 기준 τ 0.693 이 들어왔다(D-348 보충 28 · 29 · 원장 10-19 ⑨ ⑩ ⑪).
- 10-06 조건부 증명서 21 행(모두 식품 품목 · 절대형)의 내역 — 유형이 라벨과 맞고 조건도 C 16 · 조건 C 인데 라벨 유형 칸이 빈 행 1 · 증명서가 나가면 안 되는 문장 4(조건 D 2 · M 1 · 라벨이 비방(조건 B)인 행 1 · 원장 10-03 ㊿-40 보충 1). 원인은 사전 낱말이 주장이 아닌 문장에 걸리는 것이었다. 지금 판(§3-1)의 증명서 68 행은 같은 내역으로 다시 세지 않았다.

3-4. 데이터 밖 적법 카피 — 처음 보는 문구에서 오판하지 않나

사람(권소라)이 적법으로 판독한 처음 보는 카피 네 묶음을 판정 그래프 전체에 넣었다. 각 묶음을 품목 입력 · 모름 입력 두 번 넣는다.

묶음	판독	행
GPT 생성 카피	적법	213
GPT 생성 카피	적법(사실 전제)	121
정상 카피 900 판	적법	505
정상 카피 900 판	적법(사실 전제)	321

측정	인코더 · 커밋	확정위반	조건부위반	계약 위반
원장 10-16 ⑤	D4-10 · `861c002`	0	0 / 1,160 행(두 입력)	0
원장 10-19 ⑤	D4-20 · `0c37950` (보충 26 집행 뒤)	4 → **0**	0	0
원장 10-21 ⑤	D4-20 · `01287d6`	**0**	**0**	**0**

- 10-19 ⑤ — 인코더 쪽 절대형 거름(보충 26)을 넣기 전에는 데이터 밖 적법에서 확정 4 가 섰고, 넣은 뒤 0 이 됐다.
- 주의 — GPT 213 묶음은 선택 편향이 있다(182 행은 10-08 에 이전 판 인코더가 후보를 띄워 떨어뜨린 문구) — 판끼리의 비교에만 쓴다(원장 10-16 ③).

3-5. 응답 시간

지금 — 판정 요청 한 번(원장 10-20 ① · 클론 B · `scripts/latency_probe.py` · 지은 문구 한 문장 · 품목 모름 · 예열 뒤 3 번 중앙값 · D4-20)

	고치기 전(DB 호스트 `localhost`)	고친 뒤(`127.0.0.1`)
DB 연결	3,130 ms	15 ms
그래프 한 바퀴	542 ms	522 ms
합계	3,674 ms	**542 ms**

- 노드별(고친 뒤) — 검색 291 · 인코더 115 · 사전 매칭 104 · 참고 조문 15 ms. 예열(첫 번 · 모델 로드)은 26,744 ms 로 따로 보인다.
- 원인 — `localhost` 가 IPv6(`::1`)를 먼저 시도했는데 그 주소를 듣는 프로세스가 없어 연결 대기 상한(3 초)까지 기다렸다. 기본 접속 주소를 `127.0.0.1` 로 바꿨다.
- 평가 실행의 행당 시간(예: 클론 A 10-21(A) ① 716 ms · 다른 측정과 거의 겹치지 않음)은 평가 도구의 실행 시간을 행 수로 나눈 값이라 위 판정 요청 시간과 견주지 않는다. 같은 날 클론 A 에서 다른 측정과 겹쳐 돈 ② ~ ④ 의 실행 시간은 응답 시간으로 쓰지 않는다(원장 10-21(A) 머리 조건).

10-02 기준선 — 문장 수별(원장 10-02 ⑧ · ⑨ · 클론 A · `scripts/time_graph.py` · 품목 미확정 · 인코더 · 리랭커 없음)

원고 문장 수	전체 p50	전체 p95	목표(p95 3 초)
1	347 ms	654 ms	안
5	1,804 ms	2,217 ms	안
10	3,046 ms	4,350 ms	넘음
20	5,966 ms	6,547 ms	넘음

- 그때 시간의 91 ~ 98 % 가 조문 검색이었고 그중 73 % 가 임베딩 계산이었다.
- **인코더를 붙인 뒤 문장 수별 p95 는 다시 재지 않았다.** 10-20 측정은 한 문장 중앙값이라 D-77 의 p95 목표와 바로 견주지 않는다.

3-6. 불변식 · 경로 동치 · 답 경로

D-348 보충 35 · 37 · 클론 A(회사 기기 · 팀장 실행) · 원장 10-21(A) ② ~ ④ · ⑥.

> 측정 커밋은 `04b34cf`(② ~ ④ · 보충 35)와 `49aafce`(⑥ · 보충 37 결정 2)이고 둘 다 기준 커밋 `b54246d` 에 들어 있다. 클론 A 에서 측정 묶음 둘이 겹쳐 돌았다 — 실행 시간은 응답 시간으로 쓰지 않는다. 판 표지는 §3-1 과 같다(D4-20 `c451942436f0` · 사전 `2ff0168c4a28` · 골든 `94a79fe34363`).

측정	결과
불변식 위반 행	**0** — 무조건부 1,147 행 · 조건부 1,132 행(답 경로의 재판정 포함) · 품목만 넘긴 판정

측정	결과
경로 동치(전제를 고른 판정 = 품목만 넘긴 판정의 그 전제 분기)	짝 668 행 중 **어긋난 행 0**(분기가 보인 행 63 · 접힌 행 605)
같은 코드 두 번(무조건부)	바뀐 행 0 / 1,147 — 결정적
품목만 넘긴 판정(`--category-only`)	확정위반 32 · selective risk 0.0 % [0.0 %, 12.9 %](판정 행 26 · 측정 불가)
답 경로 — 질문이 선 행	267 · 이어 묻기 3 회 뒤 남은 질문 0 · 답 경로 계약 오류 0
답 경로 — 조건 B(실증형) 「아니오」 → 정답 유형 확정	**116 / 208 (55.8 % [49.0 %, 62.4 %])**
답 경로 — 조건 A(자격형)	13 / 22(n < 30 · 측정 불가)
답 경로 — 조건 D 「아니오」 → 위반	2 / 2(답에 달린 오탐)
⑥ 무조건부 다시 재기(`49aafce`) — 분류	확정위반 0 · 확정무위반 53 · 보류 1,094 · 종착 보류 1,147 — 분류 이동 0
⑥ — 바뀐 행	**178**(예측과 같음) — 품목을 모르는 기록 문장의 질문 178 → 0 · 분기 미리보기의 질문은 그대로
⑥ — 보류 사유(행)	확신 부족 987 → **825** · 품목 선택 필요 122 → **296**
⑥ — 보류 종류(첫 수 · 행 단위 · 겹침 셈)	고르기 대기 296 · 확인 못 함 706 · 걸린 것 없음 128 · 답 대기 0
⑥ — 보수 기록(예측 밖)	55 → **87** 행 · 틀림 14 → 15(17.2 %) · 위반 행 중 맞음 41 → 72

- 읽는 법 — 「아니오」는 사용자가 「사실이 아니다 · 실증 자료가 없다」고 답한 경우(가장 나쁜 경우) · 「예」는 가장 좋은 경우다. B 의 「아니오」에도 보류로 남는 74 행의 까닭은 아직 보지 않았다.
- ⑥ 의 보수 기록 증가는 판정 · 위험도가 바뀐 것이 아니다 — 고르기 대기로 바뀐 기록 문장에 실린 사전 후보 유형이 「분기 때문에 보류된 유형」으로 세어져 32 행이 바뀐 **지표 셈법** 몫이고, 결정의 대가 줄에 없던 결과다. 셈법을 고칠지는 정하지 않았다. ⑥ 은 무조건부만 다시 쟀고 조건부 · 품목만 판정은 이 코드로 다시 재지 않았다.
- 「보류 종류」는 계약의 계산 칸이다(응답 JSON 에 실리고 DB 에는 저장하지 않는다 · `app/contracts.py` `hold_kind`). 어느 종류도 통과가 아니다. 2026-10-21 기준 화면은 이 칸을 아직 그리지 않는다.
- **봉인 조건** — 「같은 커밋의 dev 에서 불변식 위반 0 ∧ 경로 동치 어긋남 0」(D-348 보충 36 결정 1). 위 측정(`04b34cf` · 클론 A)에서는 두 수가 모두 0 이었다. 같은 결정은 남은 안건을 셋으로 나눴다 — 봉인 **전**에 판정 · 집행할 것(무조건부 측정의 역할 · 근거가 빈 공정위 의결서 15 행 등), 봉인 **뒤** 봉인 보고에 「알려진 한계」로 적을 것(막다른 보류 · 섞인 유형 · 거짓 · 과장 확신 기준 · 품목 판별 · 알려진 오탐 등), 판정과 무관해 **언제든** 할 것(화면 쪽 · 두 겹 안내 문안). 봉인 회차는 아직 열지 않았다.

3-7. 화면 왕복 (E2E)

`scripts/e2e_review.py` · 지은 문구 12.

측정	결과
원장 10-19 ⑬ ~ 10-21 ⑤(클론 B · 매 측정)	**실패 검사 27 그대로** — 모두 `일반식품_기능성` 분기가 화면에 표시되지 않는 화면 결함 하나 · 질문 · 답 흐름은 닿는다
원장 10-19 ⑬	참고 조문을 판정 뒤에 고른 뒤 유형이 없는 분기 문장의 참고 조문 「무첨가」 17 → 0 · 「평생 무료」 10 → 0

측정	결과
원장 10-20 ②	**측정 당시(`7847a55`) 화면 경로는 품목을 받지 않았다** — 조건부 확정위반 32 중 18 이 화면에서 고르는 분기로는 보류(절대형 C · 라벨과 맞음 17) · 분기를 고르면 다시 판정하지 않고 분기를 읽기만 했다

- 게이트의 xfailed 1 이 이 화면 결함을 표시한다(§2).
- 10-20 ② 뒤 바뀐 것(코드 확인 · `ksr b54246d`) — 검수 화면에서 품목 · 전제를 고르면 **그 전제를 입력으로 다시 판정**하고(`app/routers/user.py` `_review_pick` · psj `12acdf5` · D-348 보충 31 결정 1), 질문에 답하면 고른 전제와 답을 함께 넘겨 다시 판정한다(`review_answer`). 고쳐 쓰기도 원문을 고른 전제 · 앞서 한 답으로 다시 판정한 결과로 고쳐 쓴다(`review_rewrite` · `c6eb380`). 다만 기준 커밋에서 **고쳐 쓴 문구의 재판정**(`_rejudge`)은 고른 전제만 넘기고 앞서 한 답은 넘기지 않았다 — 받을 칸은 생겼고(보충 37 결정 5) 화면에서 그 칸으로 넘기는 배선이 남아 있었다. 이 배선은 기준 커밋 뒤 2026-10-22 `ksr 6fec0bc` 에서 들어갔다(§6-2 T9). 이 바뀐 화면 경로로 10-20 ② 의 대조(32 중 18)를 다시 잰 원장 기록은 없다.

4. 결과가 말하는 것

#	드러난 것	근거	다음
1	**사전만으로는 위반의 여섯 중 하나만 건드렸다 → 인코더를 붙이자 탐지 후보가 크게 늘었다**	10-06 탐지 재현율 16 ~ 17 %(봉인) → 인코더 후보까지 탐지 74.9 ~ 84.1 %(dev · 확장 dev · 10-15 ~ 19)	봉인 회차에서 같은 자로 다시 잰다
2	**적법 문장을 위반으로 확정하지 않는다 — 인코더를 붙인 뒤에도**	10-06 오탐 0 / 143 · 0 / 133 → 10-21 ⑤ 0 / 38 · 데이터 밖 적법 1,160 행 × 두 입력 확정위반 0	봉인 회차 · 실제 사용 문구로 유지되는지 본다
3	**확정한 것의 틀린 비율이 내려왔다**	selective risk 22.7 %(10-06 · 봉인 · 인코더 없음) → 1.5 % [0.3 %, 8.1 %](10-21 ⑤ · 확장 dev · 판정 행 66)	dev 는 판 · 규칙을 고른 분할이라 낙관 쪽 — 봉인 회차가 정본이 된다
4	**판정을 내리는 행은 여전히 적다**	coverage 8.4 %(조건부) · 무조건부 확정위반 0	나머지는 보류 · 질문으로 사용자에게 넘긴다(설계) — 답 경로로 B 의 55.8 % 가 정답 유형에 닿는다
5	**품목을 모르면 확정하지 않는다**	무조건부 확정위반 0 · 「품목 선택 필요」 122(10-21 ⑤) → 296(`49aafce` · 기록 문장의 질문을 걸어 고르기 대기로 · 원장 10-21(A) ⑥)	그래프가 품목을 판별하는 일(보충 18 결정 1)은 미집행 — 봉인 뒤 안건(보충 36 결정 1)
6	남은 틀린 확정은 모두 특수용도식품 해설서 묶음에 있다	조건부 틀린 확정 4(알려진 오탐 ③ ⑥ ⑦ ⑧ — 그중 10-21 ⑤ 에서 새로 생긴 ⑥ ⑦ ⑧ 은 식품 전제의 건강기능식품 오인) · 해설서 485 행의 확정위반 24 중 라벨과 맞음 20 · 틀림 4(원장 10-21(A) ⑤) · 규칙은 그대로 두고 알려진 오탐으로 적기로 결정(보충 36 결정 3) · 특수용도식품 전제는 따로 두지 않기로 결정(보충 37 결정 4)	확신 기준 τ 는 봉인 뒤 다시 고를 때 함께 본다
7	주장이 아닌 문장(주의 · 상담 문구)은 판정 대상 아님으로 뺀다	10-15 ④ 바뀐 행 53 = 모두 라벨 D · 위반 행 변화 0 · 질병 합의 관문 ㉠ 넘음 → 그 확정은 접음(10-14(A) ⑥)	다른 출처의 주의 문구에서 같은 비율로 걸린다고 읽지 않는다
8	한 문장 판정은 0.5 초대다	542 ms(10-20 ①) · DB 접속 주소 하나가 3 초를 쓰고 있었다	여러 문장 p95 · 배포 기기 · 동시 요청은 다시 잰다
9	판정 응답이 화면에 다 그려지지 않는 곳이 하나 있다	E2E 실패 검사 27(`일반식품_기능성` 분기 · 10-21 ⑤ 까지) · 10-20 ② 측정 때는 화면 경로가 품목을 넘기지 않았다(그 뒤 ksr 화면은 고른 전제로 다시 판정 · §3-7)	분기 표시 결함 · 고쳐 쓴 문구 재판정에 답 넘기기 · 보류 종류 그리기는 화면 쪽 남은 일

5. 한계 — 이 보고서가 말하지 못하는 것

- **인코더를 단 판정 그래프의 봉인 평가셋 수가 없다** — §3-1 ~ §3-6 의 인코더 배선 뒤 수는 모두 dev · 확장 dev 다. dev 는 판 · 문턱 · 규칙을 고른 분할이라 낙관 쪽이다. 봉인 회차(봉인 평가셋 1,141 행)는 봉인 전 안건을 고친 뒤 한 번 연다(§1-3).
- **생성 경로는 이 보고서가 시험하지 않았다** — 판정 그래프의 생성 그래프(`build_generate`)는 앱에서 부르는 곳이 없는 스텁이고, 코어 `POST /generate` · `/compose` 는 501 이다. 실제 카피 생성은 `app/routers/copygen`(GPT 후보 → 코드 필터 → 판정 그래프 전체)이 맡고, 그 시험(`tests/test_copygen.py` · 41 수집 · 게이트 17)은 대역으로 흐름만 본다. 문구 품질은 재지 않았다.
- 정답이 30 미만인 묶음은 측정 불가다 — 예: 후기 재현율(정답 15) · 답 경로 조건 A(22) · 기능성화장품 오인(확장 dev 양성 5).
- 평가의 원천이 쏠려 있다 — 식품은 해설서 중심이다(골든 식품 행의 81 % 가 특수용도식품 해설서 원천 · 원장 10-19 ⑩).
- 10-06 기준선의 「유형 없는 위반」 131 행(정답 유형이 비어 위반 행 분모에서 빠지는 행)의 채점 규칙은 그 뒤 원장에서 결정된 기록을 찾지 못했다(확인 중).
- 그래프 평가의 정본 수는 한 기기(클론 B)의 실측이다. 클론 A 는 10-21 ⑤ 의 조건부를 같은 수로 재현했다. 불변식 · 경로 동치 · 답 경로(10-21(A) ② ~ ④)와 무조건부 재측정(⑥)은 클론 A 한 기기에서만 쟀다. 기기를 섞어 견주지 않는다.
- 이 보고서의 측정(원장)에는 여러 문장 p95 · 동시 요청 · 배포 기기의 응답 시간이 없다. 배포 담당(소성민)이 10-19 배포 서버(EC2 `g4dn.xlarge` · RDS · 워커 1 · sLLM 없음) 안에서 판정 API 부하를 잰 기록(동시 1 p50 0.52 초 · 동시 10 p95 3.79 초 · 동시 30 p95 11.64 초 · 처리량 초당 약 3.3 건)은 배포 브랜치 작업 기록(`origin/ssm` `docs/ssm/배포/작업기록_1019.md`)에만 있고 원장 절도 기준 커밋 `b54246d` 의 파일도 아니라 이 보고서의 수에 넣지 않았다. sLLM 한 문장 시간 · 부하는 배포 기기에서 재지 않았다.
- 이 PC 의 기준 커밋 `ksr b54246d` 에서는 게이트 시험을 수집만 했다(2,213) — `check` 실행 결과가 아니다. 원장에 적힌 마지막 `check` 는 `49aafce` 의 2,204 passed 다.

6. sLLM(재생성 에이전트) 평가 결과 — 이서은 작성분

> 원천 — `docs/lse/sLLM_테스트_계획_결과_보고서_제출본_2026-10-19.md` (4차) · `docs/lse/자체_sLLM_결과서_제출본_2026-10-19.md` . 측정일 2026-10-16 ~ 19 · 측정 이서은(실행 보조 Claude Code). §1 ~ §5 와 시험지 · 기기가 다르다 — 수를 섞어 견주지 않는다. 예시 문구는 모두 직접 만든 문구이고, 실제 광고 · dev 로 잰 결과는 수로만 적는다.

6-1. 시험 대상

sLLM 은 검수(판정 코어) **뒤에 붙는 재생성 에이전트**다. 검수가 지적한 문장을 검수 화면의 「고쳐 쓰기」(`POST /u/review/rewrite`)에서 고쳐 쓰고, 고친 문장은 판정 코어로 돌아가 다시 판정받는다(D-119) — 분기를 골랐으면 고른 전제를 입력으로 판정한다(`app/routers/user.py` `_rejudge` · D-348 보충 37 결정 5). 서버는 `docs/lse/sllm_service.py --serve --port 8765` (별도 GPU 프로세스)이고 앱은 `app/routers/sllm_client.py` 로 `127.0.0.1:8765` 에 붙는다. 서버가 없으면 후보를 지어내지 않는다.

구성	값
베이스	`Qwen/Qwen3-4B-Instruct-2507` + LoRA(r 8 · α 16 · 3 epoch · lr 2e-4) · 학습 장비 — 서버 판 q4b-v14 는 RTX 3080 · 확장 판(q4b-v15 · v16 · n1 · v17 · n2)은 RunPod RTX PRO 4500
잠금된 판	1단계 `copylane_sllm_lora_adapter_q4b-v14` (지금 서버 판) · 2단계 칸 `copylane_sllm_persona_adapter_q4b_polish` (D-335)
2단계 (다듬기)	기본은 어댑터 없이 도는 **규칙판** 다듬기(`docs/lse/polish_rule.py` · `POLISH_MODE = "rule"` · D-342). 잠금의 `q4b_polish` 어댑터는 모델판 다듬기의 되돌림 · 고객층 말투 전용이다
새 판	**q4b-n2 + 되살리기** — 채택 결정(10-17) · **모델 잠금 등재 대기**(잠금 밖 판이라 서버가 올리지 않는다)
안전장치	되살리기(`rescue_cosmetic`) · 후처리(`label_check`) · 관문(`stage_gate.py`)
추론 · 평가 환경	RTX 3080 10GB · Windows 11 · 인코더 D4-20 · PostgreSQL(Docker)

6-2. 합격 기준 대비 결과

#	확인할 것	합격 기준	q4b-v14(서버 판)	q4b-n2 + 되살리기	판정
T1	위반 포장 없음	실제 광고 · 직접 만든 문제 0 건	87 · 119 모두 0	**87 · 119 모두 0**	충족
T2	고칠 수 없는 문구는 불가로	불가 기대 문구에서 후보 0	실제 광고 55 · 직접 만든 불가 40 / 40	**실제 광고 66** · 40 / 40	충족
T3	살릴 수 있는 문구는 살린다	새 판이 나빠지지 않는다	살림 3 · 지나친 거절 6 · 보류 23	**살림 4 · 거절 6 · 보류 11**	충족(실전 살림은 여전히 낮음)
T4	위험 출력을 막는다	알려진 위험 꼴 전부 보류	27 / 27 · 말투 22 / 22	(규칙은 판과 무관)	충족

#	확인할 것	합격 기준	q4b-v14(서버 판)	q4b-n2 + 되살리기	판정
T5	정상 출력을 지나치게 막지 않는다	정상 출력 통과	21 / 21	(규칙은 판과 무관)	충족
T6	재판정 · dev 511	재판정 탈락 · 새 위반 유형	후보 81(15.9 %) · 탈락 0	후보 27(5.3 %) · 탈락 0 · 불가 450	부분 — n2 는 거절이 많다
T7	서빙 · 판 통제	서버가 없을 때 지어내지 않음 · 잠금 밖 판을 올리지 않음	단위 시험 통과	잠금 등재 전이라 서버가 시작을 거부(설계대로)	충족
T9	사용자 선택 반영	고른 품목 분기 · 질문의 답이 고쳐 쓰기 · 재판정까지	고른 전제는 고쳐 쓰기 · 재판정까지 · 답은 고쳐 쓰기(원문 재판정)까지 이어짐(10-19 고침) · 고쳐 쓴 문구의 세 재판정에도 답을 넘김(10-22 · 아래)	같음(앱 경로)	충족(기준 커밋 뒤 2026-10-22 `ksr 6fec0bc` · 기준 커밋 `b54246d` 에서는 부분)
T10	처음 보는 문장	직접 만든 119 · dev 511 에서 T1 · T3 유지	119 동등 · 포장 0	119 동등 · 포장 0 / dev 는 T6	부분

- 시험 번호는 이서은 보고서를 따른다(그 보고서에도 T8 은 없다).
- 평가셋 — 실제 광고 정답표 105(학습에 없던 **87**) · 직접 만든 문제 119(살리기 40 · 불가 50 · 원료명 14 · 뜻 보존 15) · dev 511(팀 골든의 평가 몫 · 살릴지 정답은 없음) · 관문 회귀(위험 27 · 정상 21 · 말투 22).
- 지연(문장당 중앙) — v14 7.3 초 → n2 3.9 초(dev 511).
- 실제 광고 87 의 판별(v14 → n2 + 되살리기) — 불가를 불가로 55 → 66 · 살림 3 → 4 · 지나친 거절 6 → 6 · 보류 23 → 11 · 위반 포장 0 → 0.
- T9 판정 — 이서은 보고서(10-19)는 「충족」으로 적었다. 기준 커밋 `ksr b54246d` 코드로는 **부분**이었다: 고쳐 쓰기 폼은 앞서 한 답을 싣고 서버가 **원문**을 그 답으로 다시 판정한 뒤 고쳐 쓰지만(`review_rewrite` · `c6eb380`), **고쳐 쓴 문구**의 재판정(`_rejudge`)을 부르는 세 곳(다듬은 안 · 담백한 안 · 조건부 안)은 문구 · 고른 전제 · 품목만 넘겼다(답을 받을 칸은 10-21 에 생겼고 넘기기로 결정됨 · D-348 보충 37 결정 5).
- T9 기준 커밋 뒤(2026-10-22 · `ksr 6fec0bc`) — `_rewrite_sentence` 가 앞서 한 답(`facts` · `substs`)을 받아 세 재판정(다듬은 안 · 담백한 안 · 조건부 후보)에 모두 넘긴다. 시험 `tests/test_user_rewrite.py::test_고친_문구_재판정에_앞서_한_답을_넘긴다` 가 더해졌다. 그래서 이 판에서는 **충족**으로 적는다. 단서 — 답은 문장 글자에 묶여 있어(`app/contracts.py` `UserFact.text`) 글자가 바뀐 고친 문장에는 들지 않는 것이 설계다(D-348 보충 37 결정 5 · `_rejudge` 주석).

6-3. 앱 연결 · 화면 흐름

시험	결과(이서은 실행 · 10-16 ~ 19)
고쳐 쓰기 `tests/test_user_rewrite.py`	70 / 70
질문 답 `tests/test_user_answer.py`	13 / 13 — 고쳐 쓰기도 앞서 한 답으로 원문을 다시 판정한 결과를 쓴다
판 표지 `test_sllm_meta.py` · 잠금 `test_sllm_lock.py`	8 / 8 · 6 / 6
사용자 화면 `tests/test_user_screens.py`	97 / 97

시험	결과(이서은 실행 · 10-16 ~ 19)
화면 흐름 실가동(실제 판정 그래프 · DB · D4-20 · sLLM 서버 · 화면 폼)	직접 만든 문구 4 개 — 검수 → 품목 분기 → 질문 답 → 고쳐 쓰기가 이어짐(넷째 문구는 검수까지 · 고쳐 쓰기 버튼이 분기마다 나옴) · 시간을 적은 세 문구 11 ~ 22 초

- 10-19 에 고친 것 — 질문에 답하면 판정이 바뀌는데 고쳐 쓰기가 답 없이 다시 판정해 **답하기 전 판정으로** 고쳐 쓰고 있었다. 고쳐 쓰기 폼이 앞서 한 답을 싣고 서버가 그 답과 함께 원문을 다시 판정하도록 고쳤다(`c6eb380`). 고쳐 쓴 문구의 재판정에 답을 넘기는 일은 기준 커밋에서는 남아 있었고, 기준 커밋 뒤 2026-10-22 `ksr 6fec0bc` 에서 들어갔다(위 T9).
- 기준 커밋 `ksr b54246d` 의 수집 수는 `test_user_rewrite.py` 74 · `test_user_screens.py` 108 이다(이 문서 작성 중 수집만 · 실행 안 함). 위 표의 70 · 97 은 이서은 측정 때의 수다.

6-4. 한계와 상태

- **잠금 등재 대기** — n2 는 채택 결정이 났지만 `models.lock.json` 에 아직 없다. 지금 서버는 q4b-v14 를 싣는다.
- **dev 오염** — n2 학습 묶음에 dev 511 중 101 이 섞였다. 겹치지 않는 329 로 따로 보면 v14 후보 62 · 보류 210 · 불가 57, n2 후보 10 · 보류 11 · 불가 308 이다. 다음 판부터 dev 문장을 뺀다.
- **낙관 편향** — 되살리기 규칙은 정답표 87 의 거절을 보고 만들었고, 일부 규칙은 직접 만든 문제를 보고 골랐다. 정답표 31 행은 Claude 초안 → 이서은 확인, 정답표 v2 74 행과 dev 표본 30 판정(불가 17 · 애매 8 · 살릴 수 있음 5)은 Claude 초안 — 사람 확인 기록 없음(이서은 확인 대기).
- n2 는 식품 · 건기식 · 화장품 밖 업종(분양 · 학원 · 웨딩 · 가전 등)은 살릴 수 있어도 거절한다(알려진 한계).
- 「위반 못 찾음」은 통과가 아니다. sLLM 고쳐 쓰기의 승인 범위(D-270 「결론 재검 대기」)와 배포 포함 여부는 판정 대기다.

> **근거** — 수치 `docs/00_사실원장.md` 10-02 ⑧ · ⑨ · 10-03 ㊿-30 · ㊿-31 · ㊿-38 · ㊿-39 · ㊿-40 · 10-06 ① ② · 10-14(A) ⑥ ⑦ ⑧ · 10-15 ① ② ④ · 10-16 ③ ④ ⑤ · 10-18 ⑫ · 10-19 ① ② ⑤ ⑨ ⑩ ⑫ ⑬ · 10-20 ① ② ③ · 10-21 ① ~ ⑤ · 10-21(A) ① ~ ⑥ · 시험 수집 `pytest --collect-only` (ksr `b54246d` 사본 · 2026-10-21 · 1차 개정은 `f8ebb09`) · 코드 `app/graph.py` · `app/contracts.py` · `app/routers/user.py` (`_rejudge` · `_review_pick` · `review_answer` · `review_rewrite`) · `scripts/eval_graph.py` · `scripts/eval_diff.py` · `scripts/eval_rule.py` · `scripts/e2e_review.py` · `scripts/latency_probe.py` · `scripts/time_graph.py` · `tests/` · 판정 `docs/00_설계결정기록.md` D-40 · D-77 · D-99 · D-170 · D-175 · D-178 · D-286 · D-306 · D-323 · D-339 · D-348 · D-349 · sLLM `docs/lse/sLLM_테스트_계획_결과_보고서_제출본_2026-10-19.md`