

# sLLM 파인튜닝

## 카피 재작성·생성 모델 / 데이터 선정 및 1 차 프로토타입 결과

**목적** 광고 문구의 위반 소지를 입력받아, 위험도와 소구력의 균형이 다른 재작성 후보를 생성하는 소형 언어모델의 초기 설계와 실행 결과를 정리한다.

|       |                 |
|-------|-----------------|
| 작성    | 이서은             |
| 작성일   | 2026.09.17      |
| 구분    | 개인 프로토타입        |
| 현재 상태 | Colab 1 차 실행 완료 |

팀의 정식 파인튜닝 일정과는 별개로 진행한 개인 검증이다. 모델 선정부터 데이터 구성, LoRA 학습, held-out 생성, RewriteSet 스키마 검증까지 한 사이클을 실제로 끝까지 돌려보는 데 초점을 맞췄다.

## 1. 목표와 출력 정의

새로운 출력 형식을 설계하기보다, 현재 화면과 계약 코드에 이미 정의된 형태를 그대로 학습 목표로 삼는다.

| 구성             | 역할                     |
|----------------|------------------------|
| body           | 사용자에게 보여줄 재작성 본문       |
| mandatory_note | 법적·표시상 필요한 필수 병기 문구    |
| placement      | 필수 문구를 어디에 배치할지에 대한 지시 |

최종 태스크: 위반 소지가 있는 광고 문구와 위반 유형·근거를 입력하면, 보수안·균형안·공격안 3 개 후보를 동일한 RewriteSet 구조로 생성한다.

### 실제 서비스와의 연결

review.html의 '재작성 제안'과 generate.html의 '카피 생성'에서 같은 출력 구조를 사용한다.

단일 정답을 내는 모델이 아니라, residual\_risk와 appeal\_retention이 다른 후보를 제공하는 방향이다.

본문 / 필수병기문구 / 배치지시의 3 분 구조는 현재 계약 코드가 전제로 하는 핵심 형식이다.

### 학습 출력 예시

```
{"body": "...", "mandatory_note": "...", "placement": "..."}

```

## 2. 모델 선정

선정 기준은 세 가지다. ① 한국어 카피 생성 품질, ② 개인 환경에서 반복 실험 가능한 크기, ③ 향후 활용을 막지 않는 라이선스다. 판정용 encoder가 아니라 문장을 직접 생성해야 하므로 1.5B~3B급 instruction 모델을 LoRA/QLoRA로 다루는 방향으로 좁혔다.

| 후보                       | 장점                                        | 이번 단계 판단         |
|--------------------------|-------------------------------------------|------------------|
| Qwen2.5-1.5B-Instruct    | 가볍고 반복 실험이 빠름. 한국어 포함 다국어 instruction 대응. | 1 차 기준 모델        |
| Qwen2.5-3B-Instruct      | 1.5B 대비 품질 향상을 기대할 수 있음.                  | 품질 부족 시 스케일업     |
| EXAONE-3.5-2.4B-Instruct | 한국어 문체 비교군으로 의미가 있음.                      | 라이선스 재확인 후 비교 실험 |

1 차 선택: Qwen2.5-1.5B-Instruct. 작은 데이터로 파이프라인을 빠르게 검증하고, 이후 데이터가 확보되면 3B급 모델과 품질을 비교한다.

## 3. 데이터 전략

### 3.1 원래 계획

가장 먼저 쓰려던 데이터는 **transform\_pair** 다. before\_text → after\_text 구조가 이미 '위반 문구 → 교정 문구' 지도학습 형태와 맞기 때문이다. 두 번째 후보는 ftc\_decisions\_body 등 의결서 원문에서 실제 시정 문구를 추출하는 방식이었다.

| 우선순위 | 데이터            | 활용 방식                    | 장점             |
|------|----------------|--------------------------|----------------|
| 1    | transform_pair | before_text → after_text | 정제된 병렬쌍 형태     |
| 2    | 의결서 원문         | 시정 관련 필드 추출              | 실제 사례 기반       |
| 보조   | 마스킹 전/후 데이터    | 동일 샘플 비교                 | 개인정보 재생산 위험 점검 |

### 3.2 실제 착수 후 변경

계획대로 데이터를 바로 확보할 수 없었다. 로컬 inventory 에서는 13 개 원본 소스가 모두 0 건이었고, LAW\_OC\_KEY 는 인증은 되었지만 target=ftc 조희가 계속 0 건이었다. 그래서 1 차 프로토타입은 '실제 수집 입력 + 직접 작성한 교정 출력'으로 전환했다.

입력: 공공 API 로 수집한 실제 화장품 원료명 300 건을 활용.

위반 유형: 기존 문서의 V0~V8 taxonomy 와 법조문 인용을 사용.

출력: RewriteSet 형식의 교정 문구를 직접 작성. 실제 병렬 말뭉치가 아니므로 합성 데이터라는 점을 명확히 구분.

1 차 15 개에서 35 개로 확장했고, 최종 학습 30 개 / held-out 5 개로 구성.

이 변경은 '좋은 모델을 만들었다'는 결론을 내기 위한 것이 아니라, 데이터가 적어도 전체 학습·생성·검증 흐름이 실제로 동작하는지 확인하기 위한 임시 선택이다.

## 4. 전처리 및 안전성 확인

기존 preprocess/mask.py 의 PII 마스킹 정책을 그대로 재사용한다. 이번 단계에서는 생성 품질 차이보다, 학습 데이터에 포함된 기관명·인명·주소를 모델이 그대로 재생산하는지 확인하는 안전성 실험의 의미가 더 크다.

| 구분     | 처리                             | 확인 포인트           |
|--------|--------------------------------|------------------|
| Raw    | before_text / after_text 원문 유지 | 생성 품질과 원문 재생산 여부 |
| Masked | mask.apply_policy() 적용         | 개인정보 노출 억제 효과    |

### 평가 항목

형식 정확도: 생성 결과가 RewriteSet JSON 으로 정상 파싱되는가.

내용 적합성: 입력의 위반 표현을 줄이면서 핵심 제품 정보는 유지하는가.

복사 여부: 학습 원문을 불필요하게 그대로 재생산하지 않는가.

안전성: 마스킹 전후에 실명·기관명 등 민감 문자열의 재출현 차이가 있는가.

## 5. 1 차 프로토타입 실행

| 항목      | 설정                                                      |
|---------|---------------------------------------------------------|
| 환경      | Google Colab / T4 GPU                                   |
| 기준 모델   | Qwen/Qwen2.5-1.5B-Instruct                              |
| 학습 방식   | LoRA                                                    |
| LoRA 설정 | $r=8$ , $\alpha=16$ / $q \cdot k \cdot v \cdot o\_proj$ |
| 학습 파라미터 | 2,179,072 개 (전체의 약 0.14%)                               |
| 프롬프트    | system + user + assistant 채팅 템플릿                        |
| Loss    | assistant 정답 토큰에만 적용 / 질문 토큰은 -100 마스킹                  |

핵심은 모델 전체를 다시 학습하지 않고, LoRA 어댑터만 업데이트해 작은 데이터에서도 빠르게 반복할 수 있도록 한 것이다. 로컬 노트북은 8GB RAM·GPU 없음으로 실험 효율이 낮아 Colab T4 로 옮겼다.

## 6. 결과

데이터를 15 개에서 35 개로 늘리자 학습 loss 가 1.44 → 0.87 로 낮아졌고, held-out 샘플은 두 실험 모두 RewriteSet 형식의 JSON 을 생성했다.

| 지표             | 1 차   | 2 차   |
|----------------|-------|-------|
| 전체 데이터         | 15 개  | 35 개  |
| 실제 학습          | 13 개  | 30 개  |
| held-out       | 2 개   | 5 개   |
| 학습 loss        | 1.44  | 0.87  |
| held-out 형식 성공 | 2 / 2 | 5 / 5 |
| 학습 스텝          | 30    | 70    |

### held-out 생성 예시

입력 | 목어석가루 함유 치약, 잇몸질환을 치료하는 의약품급 효과

생성 | `{"body": "목어석가루를 담은 치약입니다.",  
"mandatory_note": "본 제품은 잇몸 질환 치료용 의약품이 아닙니다.",  
"placement": "효능 표현 바로 아래"}`

### 결과 해석

확인된 것: 모델 선정 → 데이터 구성 → LoRA 학습 → unseen 입력 생성 → RewriteSet 파싱 검증까지 전체 사이클이 동작한다.

관찰된 것: 데이터가 늘어난 두 번째 실험에서 학습 loss 가 낮아졌다.

아직 말할 수 없는 것: 생성 품질과 일반화 성능. 학습 샘플이 30 개뿐이므로 정식 모델 성능을 판단하기에는 부족하다.

이번 결과의 의미는 '성능 검증 완료'가 아니라 '서비스 계약에 맞는 생성 모델 파이프라인을 실제로 한 번 연결해 봤다'는 데 있다.

## 7. 다음 단계

| 우선 | 할 일             | 완료 기준                              |
|----|-----------------|------------------------------------|
| 1  | 실제 병렬 데이터 확보    | transform_pair 또는 제재·시정 원문 기반 쌍 확보 |
| 2  | N=3 후보 생성       | 보수안·균형안·공격안을 한 입력에서 안정적으로 분리 생성    |
| 3  | Raw / Masked 비교 | 개인정보 재생산 여부를 샘플링해 비교               |
| 4  | 품질 평가 기준 정리     | 형식 정확도 외 내용 보존·위험 감소 지표 정의         |
| 5  | 모델 크기 비교        | 1.5B 결과가 부족할 경우 3B 급과 동일 조건 비교     |

### 현재 확인이 필요한 외부 이슈

LAW\_OC\_KEY의 target=ftc 접근 권한 여부를 키 원소유자에게 확인.

식품안전나라 계열 API는 허용 시간대에 재시도. 특히 mfd\_s\_sanctions의 VILTCN 필드가 실제 위반 문구 확보에 유효한지 확인.

팀 공식 파이프라인과의 결합은 각 담당 구현이 정리된 뒤 인터페이스를 맞춘다.

## 8. 범위와 결론

이번 문서에서 **확정한 것**은 ‘어떤 모델로 시작할지’, ‘어떤 출력 계약을 맞출지’, ‘데이터가 부족한 상황에서 프로토타입을 어떻게 검증했는지’까지다. N=3 생성 방식, residual\_risk·appeal\_retention 산정, 판정 인코더와의 최종 연결 방식은 후속 실험에서 결정한다.

**결론:** Qwen2.5-1.5B-Instruct + LoRA 조합으로 RewriteSet 생성 사이클을 검증했다. 다만 현재 데이터는 소규모 합성 중심이므로, 다음 판단의 기준은 실제 시정·제재 기반 병렬 데이터 확보 후의 재학습 결과가 되어야 한다.

### 부록. 이번 프로토타입에서 남긴 기준

작은 모델로 빠르게 사이클을 돌린 뒤, 데이터와 평가 기준이 준비되면 모델을 키운다.

서비스 계약과 학습 출력 형식을 처음부터 동일하게 유지한다.

합성 데이터와 실제 사례 데이터를 문서에서 명확히 구분한다.

형식 성공률만으로 생성 품질을 과대평가하지 않는다.