

판정 인코더 학습결과서 2 차

CopyLane | 박수진 | 4 주차 제출 초안 | 실험 기준일 2026 년 9 월 22 일

결과 요약

판정 인코더의 8 개 위법 유형 다중 라벨 실험에서 kcbert-base 와 Focal Loss $\gamma=1.5$, 양성 가중치 상한 5 를 채택했다. 기존 분할을 유지한 평가 문구 352 건에서 기본 임계값 0.5 기준 micro F1 은 0.444 였다. $\gamma=1.5$ -상한 1 의 0.409 보다 높았고, 상한 10 의 0.430 보다도 높았다. 무해 문장 60 건의 오판정률은 이 실행에서 0%였다.

이 결과는 유형 전체의 실사용 준비를 뜻하지 않는다. 건강기능식품_오인·의약품_오인·후기_체험기_기만은 기본 임계값에서 F1 이 0 이며, 배포 판단에 쓰는 상대 Recall 기준도 일부 유형에서 미달했다.

1 무엇을 학습했나

문구 한 건에서 여러 위법 유형이 함께 나타날 수 있으므로 8 개 라벨을 독립적으로 예측했다. 거짓_과장과 소비자_기만은 합치지 않았고(D-231), 후기_체험기_기만은 다른 라벨과 공존 가능한 형식 라벨로 두었다(D-255). 문서 수준의 위험도 조합, 근거 조문 제시, 서비스 전체 판정 성능은 이번 실험의 평가 범위 밖이다.

구분	설정
백본	beomi/kcbert-base (D-70)
학습 입력	golden.jsonl 6,741 행 + injected_golden.jsonl 902 행
분할	기존 split 기준 학습 7,291 행 / test_sentence 평가 352 행
학습 조건	3 epoch, 학습률 2e-5, 최대 길이 128, 학습 배치 16
선택한 손실	Focal Loss $\gamma=1.5$, pos_weight 상한 5

노트북은 물질화된 데이터의 split 값을 따라 학습과 평가를 나눴으며 임의 재분할은 하지 않았다. D-174 의 핵심인 분할 선행 원칙과 연결되는 구현이다. 다만 제출 재현성을 위해 입력 파일 해시와 split_manifest.json 의 doc_id 대응 검사를 별도 기록으로 남겨야 한다.

2 설정 비교

γ	상한	micro F1	무해 오판정률	F1 0 개 유형
1.0	1	0.394	1.7%	4
1.5	1	0.409	0.0%	4
2.0	1	0.406	1.7%	4
3.0	1	0.387	0.0%	4
1.5	5	0.444	0.0%	3
1.5	10	0.430	1.7%	3

먼저 상한 1 에서 γ 를 비교하고, 선택한 $\gamma=1.5$ 에서 가중치 상한을 바꿨다. 상한 5 는 micro F1 과 무해 오판정률을 함께 볼 때 이 실험의 최선이었다. 상한을 10 으로 더 높이면 성능은 오히려 감소했다.

3 유형별 결과

위법 유형	평가 양성 수	F1	판독
거짓_과장	108	0.548	상대 Recall 기준 통과
소비자_기만	70	0.502	상대 Recall 기준 통과
건강기능식품_오인	53	0.000	상대 Recall 기준 미달
부당_비교광고	35	0.103	상대 Recall 기준 미달
비방광고	12	0.275	표본 부족, 참고용
의약품_오인	8	0.000	표본 부족, 참고용
질병_예방치료_표방	6	0.250	표본 부족, 참고용
후기_체험기_기만	1	0.000	표본 부족, 참고용

유형별 수치는 동일 평가셋의 기본 임계값 0.5 에서 계산했다. 평가 양성이 30 건 미만인 유형은 F1 의 변동이 크므로 성능 확정값으로 해석하지 않는다. 소비자_기만과 후기_체험기_기만의 5 호 묶음 보조 F1 은 0.510 이지만, 개별 유형 성능을 대신하지 않는다.

4 배포 판단과 한계

사전 매칭 판정기 B 대비 Recall 을 0.15 이상 높인다는 상대 기준에서는 거짓_과장과 소비자_기만만 통과했다. 건강기능식품_오인과 부당_비교광고는 미달했고 나머지 네 유형은 양성 수가 30 건 미만이어서 참고용이다. 따라서 현재 결과로 전체 배포 게이트를 통과했다고 판단할 수 없다.

라벨별 임계값을 평가셋에서 탐색하면 일부 F1 이 올라간다. 그러나 같은 평가셋을 임계값 선택에도 썼으므로 그 수치는 낙관적일 수 있다. 별도 검증셋에서 임계값을 정하고 봉인 평가셋에서 다시 측정해야 한다. 무해 오판정률 0%도 이번 평가의 무해 문장 60 건에 한정된다.

5 다음 실험과 제출 확인

round2 사람 라벨의 비교·판정을 끝내 평가 표본을 보강한 뒤, 채택 설정으로 재학습한다. 새 검증 분할에서 임계값을 정하고 봉인 평가셋으로 유형별 Recall·Precision·F1 과 무해 오판정률을 다시 측정한다. 특히 기본 임계값에서 F1 이 0 인 세 유형을 별도 추적한다.

모델 산출물을 함께 제출할 때는 실제 가중치·tokenizer-config-label_scheme 의 백본, 라벨 순서, γ 와 상한이 보고서와 같은지 확인한다. 제공된 v4 노트북의 마지막 저장 로그는 상한 10 비교 실험이다. 최종 상한 5 모델의 파일 경로와 해시는 아직 이 초안에서 확인하지 못했다.

근거 자료

박수진, 판정_인코더_파인튜닝_결과_0922 최종_박수진.docx (2026-09-22). 실험 로그:

copylane_encoder_finetune_v3_gamma_sweep.ipynb, copylane_encoder_finetune_v4_0_pos_weight_cap_sweep

(1).ipynb. 설계 기준: docs/00_설계결정기록.md 의 D-70, D-174, D-231, D-255. 이 초안은 새 실험을 수행하지 않았으며 해당 실행 기록을 재구성했다.