

# 머신러닝 딥러닝 학습결과서 2 차

CopyLane 판정 인코더 | 작성 박수진 | 초안 2026 년 9 월 28 일 | 실험 기준일 2026 년 9 월 22 일

이 보고서는 판정 인코더의 9 월 22 일 학습 실험을 4 주차 제출용으로 정리한 초안이다. 최종 채택 설정은 kcbert-base, Focal Loss  $\gamma=1.5$ , POS\_WEIGHT\_CAP=5 다. 봉인 평가 문구 352 건에서 기본 임계값 0.5 기준 micro F1 0.444 를 기록했다. 다만 8 개 라벨 중 3 개는 F1 이 0 이고, 배포 판단 기준에 미달한 유형도 있어 전체 판정 성능이 확보됐다고 결론내리지 않는다.

## 1 학습 목표와 범위

문구 단위의 위법 유형 8 종을 다중 라벨로 예측하는 판정 인코더를 학습했다. 백본은 설계결정 D-70 의 beomi/kcbert-base 이며, 거짓\_과장과 소비자\_기만은 D-231 에 따라 합치지 않았다. 후기\_체험기\_기만은 다른 내용 라벨과 함께 붙을 수 있는 형식 라벨로 유지했다. 이 실험은 문서 단위 판정이나 최종 서비스의 종합 성능을 측정한 것이 아니다.

## 2 데이터와 재현 조건

| 항목    | 9 월 22 일 실험 기록                                                |
|-------|---------------------------------------------------------------|
| 입력    | golden.jsonl 6,741 행 + injected_golden.jsonl 902 행 = 7,643 행  |
| 분할    | 기존 split 필드 기준 train 7,291 행 / test_sentence 평가 352 행; 재분할 없음 |
| 평가 구성 | 무해 60 건, 위반 292 건                                             |
| 학습    | 3 epoch, 학습률 2e-5, 최대 길이 128, 학습 배치 16                        |
| 최종 선택 | Focal Loss $\gamma=1.5$ , 양성 가중치 상한 5, 기본 판정 임계값 0.5          |

D-174 의 분할 선행 원칙에 따라 평가 문구를 학습에 섞지 않는 것이 전제다. 노트북은 물질화된 행의 split 필드를 사용한다. 제출 전에는 학습에 사용한 파일의 해시와 split\_manifest.json 대응, 중복 문구 여부를 별도 기록으로 고정해야 한다.

## 3 실험 결과와 선택 근거

| $\gamma$ | 상한 | micro F1 | 무해 오판정률 | F1 0 개 라벨 | 5 호 묶음 F1 |
|----------|----|----------|---------|-----------|-----------|
| 1.0      | 1  | 0.394    | 1.7%    | 4         | 0.326     |
| 1.5      | 1  | 0.409    | 0.0%    | 4         | 0.369     |
| 2.0      | 1  | 0.406    | 1.7%    | 4         | 0.346     |
| 3.0      | 1  | 0.387    | 0.0%    | 4         | 0.283     |
| 1.5      | 5  | 0.444    | 0.0%    | 3         | 0.510     |
| 1.5      | 10 | 0.430    | 1.7%    | 3         | 0.449     |

$\gamma=1.5$ 로 고정한 뒤 상한을 5로 올렸을 때 micro F1이 0.409에서 0.444로 높아졌다. 상한 10에서는 0.430으로 낮아져 상한 5를 채택했다. 이는 해당 데이터와 평가 분할에서의 선택이며, 다른 데이터에서도 같은 순위가 유지된다는 뜻은 아니다.

#### 4 최종 설정의 유형별 결과

| 위법 유형      | 평가 F1 | 해석                |
|------------|-------|-------------------|
| 거짓_과장      | 0.548 | 주요 성능 기여          |
| 소비자_기만     | 0.502 | 상한 1 대비 개선        |
| 비방광고       | 0.275 | 평가 양성 12건으로 참고용   |
| 질병_예방치료_표방 | 0.250 | 평가 양성 6건으로 참고용    |
| 부당_비교광고    | 0.103 | 탐지는 시작했으나 낮음      |
| 건강기능식품_오인  | 0.000 | 기본 임계값에서 탐지 실패    |
| 의약품_오인     | 0.000 | 기본 임계값에서 탐지 실패    |
| 후기_체험기_기만  | 0.000 | 평가 양성 1건으로 측정 불충분 |

라벨별 임계값을 같은 평가셋에서 탐색하면 일부 라벨의 F1이 올라가지만, 그 결과는 임계값 선택에 평가셋을 다시 사용한 수치다. 별도 검증셋에서 임계값을 정하고 봉인 평가셋에서 다시 측정하기 전까지 공식 성능으로 제시하지 않는다.

#### 5 기준선 비교와 남은 문제

사전 매칭 판정기 B의 Recall과 비교한 G1 상대 기준( $B+0.15$ )에서는 거짓\_과장과 소비자\_기만이 통과했고, 건강기능식품\_오인과 부당\_비교광고는 미달했다. 나머지 4개 유형은 평가 정답이 30건 미만이어서 참고용이다. 이 기준으로는 전체 배포 게이트 통과로 볼 수 없다.

다음 작업은 round2 사람 라벨의 검증·판정 완료, 특히 F1=0 유형의 평가 표본 보강, 최종 설정 재학습, 분리된 검증셋에서 임계값 선정, 봉인 평가셋 재측정이다. 학습 결과와 실제 전달할 모델 파일의 백본· $\gamma$ ·상한·라벨 순서·임계값이 일치하는지도 확인해야 한다.

#### 6 제출 근거와 확인 사항

근거 자료: 「판정\_인코더\_파인튜닝\_결과\_0922 최종\_박수진.docx」, 「copylane\_encoder\_finetune\_v3\_gamma\_sweep.ipynb」, 「copylane\_encoder\_finetune\_v4\_0\_pos\_weight\_cap\_sweep (1).ipynb」, 설계결정기록 D-70·D-174·D-231·D-255. 수치는 이 자료의 9월 22일 실행 기록을 옮겼다.

제출 전 확인: 최종 CAP=5 모델 압축본의 실제 경로와 내용, 원본 데이터 해시, 보고서에 넣을 실행 환경 및 모델 파일 해시. 제공된 v4 노트북의 마지막 저장 로그는 CAP=10 비교 실험이므로 최종 채택 모델 증빙으로 사용하지 않는다.