



다중 에이전트 기반 광고 문구 준법 검수 · 생성 플랫폼

“광고 한 줄이 나가기 전, 근거와 함께 먼저 검수합니다.”

팀 오한빈 · 권소라 · 이서은 · 소성민 · 박수진

발표자 오한빈

발표 구성

PART 01 프로젝트 개요

시장/BM · 경쟁 실측 · 프로젝트 기능 · 기술 스택

PART 03 판정 · 생성 핵심 설계

공용 판정 코어 · 재검수 · 출력 게이트

PART 05 협업 · 진행 현황

협업 Tool · 팀원 분담 · 진행 현황 · WBS

PART 02 데이터 거버넌스 · 수집

거버넌스 게이트 · 데이터 수집 현황 · 증별 활용

PART 04 DB · VectorDB

ERD · 데이터/런타임 분리 · 검색 구조

PART 06 테스트 · 결과 목표

TEST 계획 · 예상 결과 목표 · 시연

PART 01

프로젝트 개요


PROJECT OVERVIEW

CopyLane

광고 문구 준법 검수 · 생성 플랫폼


이 광고 멘트, 위법일까요 아닐까요?

광고는 한 줄이지만 적용 법령과 위험은 카테고리·문맥·표현 방식에 따라 달라집니다.



'내돈내산' 리뷰인 줄...뒷광고 한 성형외과 딱 걸렸다

최승훈 기자 작성 2026.07.12 13:28 조회 661



Sources: 2026.07.23 식약처 발표 인용 보도 · 2026.07.24 식약처 점검 인용 보도 · 공정위 SNS 부당광고 모니터링(2024 실적 · 2025·

이 광고 멘트, 위법일까요 아닐까요?

광고는 한 줄이지만 적용 법령과 위험은 카테고리·문맥·표현 방식에 따라 달라집니다.

다이어트 식품

“문지르기만 해도 달라지는 변화.”

질병·의약품 오인 위험

미용

“발모 효과 탁월!”
“모근이 강화되어 머리가 빠지지 않습니다.”

의약품 오인 광고 위험

SNS 협찬

협찬받은 후기인데
#광고 표시는 없음

경제적 이해관계 미표시 위험

26개 업체

2026.07 다이어트식품 부당광고 적발

178건

2026.07 화장품 온라인 허위·과대광고

22,011건

2024 SNS 뒷광고 의심 게시물 모니터링

WHY NOW

규제 집행은 자동화되고, 광고 제작 속도는 빨라지고 있습니다. → 문제는 ‘올린 뒤 수정’이 아니라 ‘올리기 전 검수’입니다.

시장 조사 & BM 가설

경제성 + 규제 강도 + 반복 업무라는 세 가지 근거로 “사전 검수” 수요를 설명합니다.

경제성

전문 심의는
건별 비용 구조입니다.

3만원 ~ 16.5만원

건기식 표시·광고 심의 시작 구간기능성 표시식품 광고 1건

광고 카피는 출고 전 반복 수정됩니다.
→ “매번 사람 심의”만으로는 반복 검수에 비효율이 생깁니다.

규제

실수의 비용은
단순 반려가 아닙니다.

최대 10년

식품표시광고법 제26조
일부 부당 표시·광고의 형사처벌 구간

2026 식약처 추진계획:
온라인 부당광고에 “실시간 AI 감시” 등 신속 차단 강화

BM 가설

무료 검수 → 팀 업무 → 기업 구축

FREE

근거 조문 포함 1차 검수

TEAM

배치 검수 · 승인 문구 원장 · 재검증

ENTERPRISE

온프레미스 · 조직 정책 연동

※ 가격 미확정 · 확정된 것은 이중 에디션(기업 온프레미스 / 셀러 클라우드)과 과금 경계 = sLLM 사용 여부(D-69) · 3단은 가설, 지불의사 검증 후 확정

기존 도구는 “위암 치료”를 놓쳤습니다

같은 문구를 경쟁 도구에 넣어 실측했습니다 — 낱말은 잡고, 위법의 본체는 통과시켰습니다.

실측

텍스트 입력

위암 치료에 최고인 알파줄

글자 수: 14

전체 삭제

검사 결과

텍스트 복사

검사 요약

0
맞춤법

0
비속어

1
심의 위험

광고 심의 위험

수정하기

발견된 표현: "최고"

객관적 근거 없이 사용 시 과대광고로 판단
될 수 있습니다

추천 수정: "우수한"

그래서 CopyLane 은 넷을 다르게 합니다

- 다법령 라우팅**
 카테고리를 묻지 않고 제품이 판별 · 표시광고법·식품표시광고법·화장품법
- 근거 + 인용 검증**
 조문 스펠이 없으면 위험도를 올리지 않는다 · 인용은 검증 후 출력
- 생성물 재투입**
 대체 문구·카피·광고물이 같은 판정 코어를 다시 지난다
- 온프레미스**
 광고 문구를 외부 SaaS 로 보내지 않는다 · GPT 는 평가·비교 전용

프로젝트 기능



기술 스택

WEB / API

FastAPI · Jinja2 · HTMX · Alpine.js

SSR 기반 화면 + API

ORCHESTRATION

LangGraph 1.2.11 · Pydantic v2

재판정 루프 · Abstention · 상태 계약 · 체크포인트 TTL

JUDGMENT

KcBERT/KcELECTRA · Aho-Corasick

카테고리·위법 유형 분류 + 규칙 하한

RAG

BM25 + KURE-v1 + bge-reranker

법령·고시·유사 제재 사례 검색

GENERATION

Qwen3 4B · QLoRA · JSON Schema

대체 문구 · 카피 생성 · 출력 제약

DATA / INFRA

PostgreSQL 16 + pgvector 0.8.6 · Docker

캐스케이드 삭제 · 로컬 실행 · Python 3.11.9 · uv.lock — 5인 환경을 패치 버전까지 고정

설계 원칙

조문·등급·수치는 판정 객체에서 직접 렌더링하고, sLLM이 임의로 생성하지 못하도록 출력 스키마로 제한합니다.

데이터 거버넌스 게이트

등급 × 용도 매트릭스 하나가 규칙입니다 — 등재되지 않은 소스는 수집기가 실행되지 않습니다.

	U1 학습	U2 원문 색인	U3 화면 인용	U4 배포
G3 원문 자유	가능	가능	가능	가능
G2 사실만	가능	deny	deny	가능
G1 배제	deny	deny	deny	deny
G0 미확인	deny	deny	deny	deny

G2 의 U2-U3 deny 는 정책이 아니라 정의입니다 — 원문을 보관하지 않는 등급에 원문 색인을 열면 등급 표기가 거짓이 됩니다.
G0 는 확인 전까지 전부 닫히고(fail-closed), 2인 판정으로만 승격됩니다.

집행은 문서가 아니라 코드

47

소스 등재

37

2인 서명

13

미채택

registry.require()

미등록·G1·용도 deny·2인 미확인이면 수집기가 실행되지 않음

pytest -m gate 176

등급 ↔ 용도 상한 · raw 소비 금지 · 서명 ↔ 원장 일치

DB CHECK

decided_by ≠ reviewed_by · k·익명 · 토큰 상한

데이터 수집 현황 — “어디에 쓰는가”까지

출처가 아니라 “용도”로 분리하고, 각 데이터층이 판정·RAG·생성에서 맡는 역할을 명시합니다.

1층	판정 라벨	실제 위반 사례	학습·평가	10 sources
2층	적법 라벨	인정 가능성 문구	학습·생성	4 sources
3층	판단 규범	법률·시행령·고시	RAG·인용	3(+1) sources
4층	위험도	별표 제재 기준	코드 위험도 산정	1(+1) source
5층	코퍼스·반례	일반 광고·리뷰 정상 문장	학습 음성 표본	11 sources
6층	세그먼트	소비자 조사·통계	Phase 3 생성	9 sources
7층	광고 카피	카피 코퍼스	Phase 3 생성	2 sources

현재 파생물 실측

1,908	골든셋	학습 1,702 · 평가 206
2,207	조문	RAG/인용 원천
2,585	벡터	chunk = embedding 1:1
447	제품 사실	정본 축만 (09-11 축 분리)
243	별표 행	위험도 원천 · 적재 예정

용도 허용: U1 학습 35/47 · U2 RAG 24/47
U3 인용 25/47 · U4 배포 35/47

판정 및 생성 게이트 — “안전은 필터가 아니라 바닥이다”

모델은 위험도를 올릴 수만 있고, 근거 없이는 올리지 못합니다. 조문·숫자는 코드가 짭니다.



불변식 3

① 위험도 = max(코드 하한, 인코더) — 낮추는 장치 없음 ② 근거 스캔 없으면 상향 0 + 보류 ③ 미판정은 통과가 아니다 · 수정 시 즉시 미판정 → 생성·다운로드 잠금

생성 — 페르소나에서 지면까지 (B → C)

페르소나는 키워드를 제안할 뿐 평가하지 않습니다. 어휘를 먼저 자르고, 문장을 만들고, 같은 코어로 다시 판정한 뒤에야 지면에 있습니다.

B 준법 카피 생성

Phase 3 · 계약 + 고정 응답 2건 · 엔진 501

- ① **세그먼트 도출** 리뷰·VOC 임베딩 → 군집 · k-익명 ≥ 20 강제 (ck_segment_k_anon)
- ② **페르소나 팬아웃 3축** 인구통계 · 라이프스타일 · 목표/동기 → 좌절·pain point 축은 스키마에서 제거 (D-27)
- ③ **키워드 사전 선별** 허용 = 후보 - 금지 어휘 - 질병 인접 - 미인정 기능성. 문장보다 어휘를 먼저 자른다 (D-29)
- ④ **sLLM 생성 N=3 → 주장 원장** 신규 주장 = 생성 - (원문 ∪ 제품 사실) $\neq \emptyset$ 이면 거부 — 부탁이 아니라 연산 (D-30)
- ⑤ **자체 스크리닝 · 재생성 K=2** 같은 판정 코어가 채점 · 통과 = 확정 $\wedge R1$ 이하 · K 소진 시 「표현 탐색 실패」
- ⑥ **리스크-소구력 프론티어** 보수 / 균형 / 공격 3안 · 파레토 최적만 · y축은 전환율이 아니라 정보량 보존율 (D-31)
- ⑦ **채널별 각색** 코드가 「광고」 표시 문구를 먼저 넣고 → sLLM 은 본문만 → 코어가 재검증 (D-181)

C AI 광고 생성

Phase 3 · 고정 응답 3건

두 경로, 한 코어

B 의 각색본을 받거나 · 독립 진입(종류 → 내용) — 어느 쪽이든 판정 코어를 먼저 지난다

섹션 골격 + 슬롯

상세페이지 · 카드뉴스 · 배너 (템플릿 1종부터) · 판정 통과(confirmed) 문구만 슬롯에

프로파일이 바꾸는 것

길이 · 문장 수 · 문체 · 표시 배치 — 판정 기준 · 허용 어휘 · 근거 조문은 못 바꾼다 (D-93)

「광고」 표시는 구조적 강제 — 계약이 거부한다


표시 섹션 번호가 없으면 거부 · 번호만 있고 칸이 없어도 거부 · confirmed 아닌 문장이 슬롯에 차 있으면 거부

취약 세그먼트 가드레일

pain point 축 제거 → 고령·환자군·임산부·미성년 군집 자동 플래그 → 판정 임계 강화 · 질병 인접 어휘 전면 차단 → 「강화 검수 적용」 라벨 표기
페르소나는 키워드 제안까지 — 우리가 만든 페르소나가 우리 문구를 채점하면 순환 논증. 평가는 판정 코어 · 코드 · 사람 20~30명

DB / VectorDB ERD

DATA LAYER · 19 tables



VECTOR DB · hybrid search

E-03 VectorDB 구조

무엇을 벡터에 넣고 무엇을 안 넣는가

벡터에 넣는다 - 검색 대상 텍스트

법령 조문 본문

조 · 항 · 호 단위

고시 · 지침 본문

사례집 서술 문단

미확정 - 인용은 조문만 허용

벡터에 넣지 않는다 - 관계형

벌표 제재 기준

차수 × 제재 × 기간

과징금 부과기준을

벌칙 조항 상한

금지 · 적법 표현 사전

정확매칭이 하한을 만든다

질의

BM25

정확 조문번호

벡터 검색

KURE-v1 · 1024차원

리랭커

bge-reranker-v2-m3 · 512 상한

인용할 조문

출처표시 · 시행일 동반

벌표를 벡터에 넣지 않는 이유. 「1차 시정명령 / 2차 업무정지 15일 / 3차 업무정지 1개월」은 표 구조 자체가 의미다. 평문화해 임베딩하면 차수와 제재의 대응이 깨지고, 검색은 「비슷한 문장」을 돌려줄 뿐 어느 차수인지 보장하지 못한다.

핵심: 데이터층 ↔ 런타임층 FK 0 / 검색은 v_current_chunk + U2 허용 소스만 / chunk 삭제 시 embedding도 CASCADE 삭제

협업 Tool — “같은 계약, 같은 환경, 같은 로그”

5명이 병렬 개발해도 결과가 갈라지지 않도록 협업 도구의 역할을 분리합니다.

SCHEMA

Pydantic v2

API 계약의 단일 스키마

요청/응답 모델 · 상태 필드 · 고정 응답 14건

REPRO

launcher.py

명령 한 줄로 재현

collect / golden / load / setkey · .env 단일 진입

ENV

Docker Compose

개발 환경 통일

pgvector/pgvector:0.8.6-pg16 · 127.0.0.1 바인딩

COMMS

Discord

빠른 커뮤니케이션

일정 · 이슈 · 머지/테스트 결과 공유 채널

Git 협업 규칙

개인 브랜치 → 팀장이 ohb 로 흡수 → main PR 은 팀장만 · cherry-pick 금지(기여 기록 D-55) → 머지 직후 gate | 비밀은 .env · gitleaks 히스토리 검사

팀원 분담

공통 기반 + 사용자 에이전트 + 관리자 에이전트를 병렬로 진행하되 판정 코어 API는 단일 구현으로 유지합니다.

오한빈

팀장 · 공통 기반

전처리 · DB · 판정/생성 코어 · API · 배포



권소라

사용자 화면 · BFF

UI 정의 · 사용자 화면 · 임베딩 파인튜닝



이서은

사용자 화면 · BFF

UI 정의 · 사용자 화면 · LLM 파인튜닝



소성민

관리자 화면 · BFF

관리자 기능 · LangGraph 계약 테스트 · 리소스 발급
담당(RunPod · AWS)



박수진

관리자 화면 · BFF

UI 정의 · 관리자 화면 · DL



PART 05

진행 현황

PROGRESS & TROUBLESHOOTING

“되는 것 / 안 되는 것을 분리해 보고합니다.”

2주차 최종 산출물 기준 진행 현황

진행률보다 중요한 것은 “어디까지 실제로 동작하고, 어디서 막혀 있는가”입니다.

동작

수집 게이트

47 소스 등재 · 2인 확인

동작

데이터·적재

원장 20,008행 · 골든 1,908

동작

Vector 재료

chunk/embedding 2,585

스텝 동작

판정 그래프

노드 11 · 라우터 2

동작

진입점 계약

고정 응답 14건

현재 막힌 구간



① violation_article 0행

근거 조문 매핑



② sanction_rule 미적재

위험도 배지



③ /search 벡터 배선 남음

의미 검색



④ /judge-generate-compose = 501

실 엔진 연결

3주차 착수 순서


- 1 violation_article 적재
- 2 sanction_rule 적재
- 3 /search 벡터 검색 배선
- 4 판정 스텝에 판정기 A/B 연결
- 5 화면설계서 수정 8건 → 팀원 전달

모르는 것을 모른다고 냅니다

위법 유형 10종 중 문장 단위로 평가할 수 있는 것은 2종 — 30건 미만은 “측정 불가”로 적고, 엔진이 없으면 501 을 냅니다.

평가 표본

test_sentence 206 문구 · 유형별 평가 가능 하한 30건



30건 하한

2종 모두 ftc 단일 원천이라 원천 편향은 젤 수 없습니다(same_source). 사례집(중앙 5.3자)은 시험지가 아니라 사전으로 돌렸습니다(D-155). 라벨링 대기 273건(해설서 248 · 사례집 25) — 9/17 범위 확정에서 3택일: 의결서 추가 수집 · 유형 통폐합 · 측정 불가 유지

숨기지 않는 세 가지

501

/judge · /generate · /compose

엔진이 없는데 가짜 200 을 내지 않습니다 — 프론트가 두 번 고치지 않게

측정 불가

유형별 30건 미만

수가 아니라 단위가 문제입니다 — 낱말 시험지는 만들지 않습니다

F1 0.027

규칙 판정기 B 첫 실측 · 오탐 0%


낮은 것이 정상입니다 — 「기억력 개선」은 승인 건기식에선 적법. 그래서 모델이 필요합니다

WBS 기반 진행 현황

WBS v1.3 · 2026.09.09 갱신 기준 진행률 (09.10 Phase 0 충족분 재산정 예정) · 이슈·마일스톤은 09.11 기준

전체 진행률

40.6%



주요 마일스톤



이슈 & 트러블 슈팅

01

저작권 이슈로 인한
정상 광고 데이터 수집 불가 상황

02

'템플릿 = AI광고생성' 기능 추가

03

광고 문구 sample 마스킹 / 라벨링 이슈

TEST 계획

“지금 자동으로 막는 것 / 통합 시 검증할 것 / 배포 단계에서 붙일 것”을 분리합니다.

NOW

현재 / 바로 적용

- **pytest -m gate 176** : 거버넌스·계약·DB 제약
- **doctor** : 기기 검사 3축(있는가·웹손·최신) 동작 — 나머지 본문 미구현
- **Git 커밋/브랜치 제약** · **main** 직접 금지
- **gitleaks** : 비밀키·히스토리 검사

NEXT

엔진 연결 시

- **Pydantic** 계약 테스트
- 고정 응답 14건 → 실제 엔진 교체
- 판정 결과 ↔ DB 저장 검증
- 통합 테스트 범위는 연결 후 확정

CI/CD


배포 단계

- **PR**: lint → gate → schema/doctor → build
- **main merge** 후 회귀 테스트
- **AWS** 배포 경로 확정 뒤 **CD** 연결
- **E2E/브라우저** 테스트는 후속 결정

원칙: 통과하지 않은 상태를 “성공처럼 보이게” 만들지 않는다 — 엔진 미구현은 501, 표본 30건 미만은 “측정 불가”로 남긴다.

예상 결과 목표

최종 목표는 “합법을 단정하는 AI”가 아니라, 근거를 대고 모르면 보류하는 1차 스크리닝 도구입니다.



「보류」와 「합법화 불가(자격형·실증형·절대형)」는 실패가 아니라 정상 종착입니다 — 통과 = 확정 $\wedge$ 위험도 $\leq$ R1 (D-125 · D-59)

발표 지표 3

① 위법 유형별 Recall (질병 표방 단독 표기) ② 재판정 통과율 + 내용 보존율 (쌍) ③ 신규 주장 삽입률 — 목표 0

DEMO

시연

PROTOTYPE

시연 순서

- ① 문구 입력 (최대 5건)
- ② 카테고리 자동 판별 → 문장별 판정 · 위험도 · 근거 조문
- ③ 대체 문구 → 재판정 (보류 / 불가 종착 포함)
- ④ 카피 생성 B → 다시 판정 → 잠금 해제

“판정 결과는 고정 응답(픽스처 9건)입니다 — 엔진은 3주차부터 붙습니다.”

Q&A

Q&A

Ask me questions

핵심 메시지

CopyLane은 “잘 말하는 AI”보다 “근거 없이 말하지 않는 구조”를 먼저 만들고 있습니다.

Thank you



오한빈 · 권소라 · 이서은 · 소성민 · 박수진

발표자 오한빈

“광고 한 줄, 출시 전에 묻겠습니다.”