

SKN FINAL PROJECT · COPYLANE · 2주차 산출물 5/7

ERD 및 VectorDB 구조

데이터층 19표 + 런타임층 6표 · 벡터 사양

이 문서의 모든 수치는 2026-09-10 실측이다. 「설계상 있다」와 「지금 돈다」를 같은 글씨로 적지 않는다 — 동작 / 부분 / 미착수 를 구성요소마다 붙였다.

CopyLane ERD 및 VectorDB 구조

2주차 산출물 항목 4 · 8 · 2026-09-10 · 오한빈

기준: db/schema.sql (데이터층) · app/models.py (런타임층) · 마이그레이션 0007 까지 적용 (2026-09-10)

총 25표 · ENUM 14종 · 뷰 3종 — 데이터층 19표 + 런타임층 6표

발표 자료용 이미지: 이 문서의 도면은 도면_png/ 에 2배율 PNG 로 들어 있다. 슬라이드에 그대로 붙인다. 웹 도면판(전체 13장)은 별도 페이지에서 본다.


0. 왜 표가 두 층으로 나뉘는가

	데이터층 (DB/SCHEMA.SQL)	런타임층 (APP/MODELS.PY)
무엇이 들어가나	우리가 수집한 것 — 법령·고사·의결서·사례집	사용자가 쓴 것 — 광고 문구·판정 이력
키	텍스트 자연키 (law_id , chunk_id)	UUID
만드는 주체	배치 파이프라인	웹 요청
지우는 규칙	소스 삭제 시 CASCADE	동의 없으면 만료와 함께 지운다
학습에 쓰는가	등급×용도 게이트를 통과한 것만	제외 기본 금지 (consent_train 이 유일한 해제)


두 층 사이에 **FK 가 하나도 없다**. 이것이 「사용자가 쓴 문구가 학습 데이터에 섞이는 사고」를 구조적으로 막는 방법이다. 판정할 때 런타임층이 데이터층을 읽기만 한다.

1. 데이터층 ERD — 19표

(가) 거버넌스 축 — 등급이 정해지는 곳



(나) 원문 → 검색 축



(다) 판정 근거 · 골든셋 축

1-1. 표별 역할과 적재 현황

#	표	역할	적재
1	source	소스 원장 · 등급 · 2인 확인 서명	32

#	표	역할	적재
2	source_constraint	BY/NC/SA/PII/TOS/GATED 플래그	동작
3	source_use	소스 × 용도(U1~U4) 허용 여부	동작
4	fragment	등급이 실제로 걸리는 곳 — 소스 등급을 상속하지 않는다	11
5	collect_manifest	수집 1회 = 1행 (sha256-bytes-rows-event)	동작
6	document	법령·고사·의결서 단위 · 현행 여부	32
7	sentence	문장 + 원문 좌표 + 회피 표기 플래그	부분
8	chunk	RAG 검색 단위 (≤512 토큰)	부분
9	chunk_embedding	벡터 1024차원	 2,585행 — KURE-v1 이 실제로 1024를 내는 것을 실측 확인
10	sanction_rule	위반유형 × 차수 → 제재 · 위험도 R0~R4	적재기 없음
11	penalty_rule	과징금 부과기준율 · 가중·감경	적재기 없음
12	penal_clause	벌칙 조항 (징역·벌금 상한)	적재기 없음
13	dict_entry	금지·적법 표현 사전	536 (유형 430)
14	product_fact	인정 기능성 원료 — 자격형 판정의 근거	동작
15	golden_sample	골든셋 (학습·평가)	1,908
16	violation_article	라벨 ↔ 조문 대응	0행
17	transform_pair	실사례 시정 페어 (before → after)	부분
18	segment	대상고객 군집 (k≥20 강제)	Phase 3
19	dataset_manifest	재현성 — seed · counts · 측정 불가 유형 목록	부분

수치 출처: 2026-09-10 적재 로그. **갱신은 GET /health 한 곳에서만 읽는다** — 문서에 손으로 적은 수를 다시 인용하지 않는다.

1-2. 스키마가 강제하는 규칙 6개


제약	무엇을 막는가
ck_source_four_eyes grade_decided_by <> grade_reviewed_by	같은 사람이 판정하고 스스로 확인하는 것
ck_source_by_attr	출처표시 의무 소스를 attribution 없이 등재하는 것
ck_chunk_tokens token_count <= 512	리랭커 입력 상한 초과 체크.  0006 에서 token_count 를 NOT NULL 로 — 종전 식은 IS NULL OR ... 라 칸을 비우면 무제한이었다
ck_golden_injected_not_holdout	주입 데이터가 평가셋에 섞이는 것 (지표 부풀림)
ck_surface_pairing	표면 변형본이 원형 없이 홀로 존재하는 것 (델타 측정 불가)
uq_product_fact	두 번 적재하면 행이 두 배가 되는 것

1-3. 뷰 3종 — 「읽기 쉬운 필터」를 구조로 박았다

```
v_current_chunk -- superseded_at IS NULL AND fragment.excluded = false
v_publishable_golden -- redistributable = true
v_risk_lookup -- sanction_rule 중 현행만
```

검색 코드는 `chunk` 원표를 직접 보지 않고 반드시 `v_current_chunk` 를 통한다. 폐지된 조문으로 판정하는 사고를 뷰가 막는다.

2. 런타임층 ERD — 6표




2-1. 이 층의 설계 판단 다섯

판단	형태	왜
기본 미보관	<code>consent_store</code> 기본 <code>false</code> + <code>CHECK (consent_store OR expires_at IS NOT NULL)</code>	동의 없는 문서는 만료 시각을 반드시 갖는다 . 지울 키 없이는 지울 수 없다
판정은 다형 참조	<code>subject_type</code> + <code>subject_id</code>	지금은 문장에 없지만 규제 대상은 본래 「주장」이다. 주장 측은 9/17 이후 확정 → 그때 행만 추가된다

판단	형태	왜
법령 버전은 판정에 붙는다	<code>judgment.law_version</code>	문장에 박으면 재판정 시 덮어써서 「언제 무엇으로 판정했나」를 잃는다
집계는 원문과 분리	<code>batch_run.summary</code> (JSONB)	동의 없어 원문이 사라져도 위험도 추이는 남는다
업로드물 경로는 한 곳	<code>upload_blob.path</code> (UPLOAD_ROOT 아래)	학습·색인 코드가 이 경로를 <code>consent_train</code> 필터 없이 참조하면 게이트 테스트가 실패한다

3. VectorDB 구조 — 무엇을 벡터에 넣는가

3-1. 결론: 벡터에 넣는 것은 「검색 대상 텍스트」 뿐이고, 「판정 근거 수치」는 관계형 표에 둔다



별표를 벡터에 넣지 않는 이유: 「1차 위반 시정명령 / 2차 업무정지 15일 / 3차 업무정지 1개월」은 표 구조 자체가 의미다. 평문화해 임베딩하면 차수와 제재의 대응이 깨지고, 검색이 「비슷한 문장」을 돌려줄 뿐 어느 차수인지 보장하지 못한다. 준법 검수에서 그건 실격이다.

3-2. 사양

항목	값	근거
저장소	PostgreSQL 16 + pgvector (별도 벡터DB 없음)	청크 삭제 시 ON DELETE CASCADE 로 임베딩이 함께 사라진다. 두 저장소면 이 정합을 사람이 지켜야 한다
임베딩 모델	KURE-v1 (한국어) · 로컬 실행 2.27GB	원문을 외부 API 로 보내지 않는다
차원	vector(1024)	모델 실측 차원
청크 단위	조·항·호 — 문자 수가 아니라 법령 구조	조문 인용이 목적이므로 경계가 조문이어야 한다
청크 상한	512 토큰 (CHECK 강제)	리랭커 bge-reranker-v2-m3 입력 상한
검색 방식	하이브리드 — BM25(정확 조문번호) + 벡터(의미) → 리랭커	「식품표시광고법 제8조」 같은 정확 질의는 BM25 가 이긴다
인덱스	HNSW (vector_cosine_ops) — 행 수 확정 후 생성	조문 규모(수천)에서는 IVFFlat 보다 재현율이 안정적
필터	반드시 v_current_chunk 경유 + source_use.allowed (U2_rag)	폐지 조문·RAG 미허용 소스 배제
재색인 트리거	dataset_manifest.source_set_version 변경	법령 개정 시

3-3. 메타데이터 — 벡터와 함께 반드시 따라가는 것

검색 결과가 화면에 뜰 때 아래가 전부 있어야 인용이 성립한다.

필드	어디서	왜 필요한가
law_id · article · paragraph · item	chunk	조문 번호 표시
doc_type	chunk	법률/시행령/고시 구분 — 효력 위계
category[]	chunk	카테고리별 적용 법령 필터
effective_date · superseded_at	chunk	현행 여부
attribution · url	source	출처표시 의무 (BY 플래그)
source_use.allowed	source_use	RAG 용도 허용 여부

지금 /search 응답이 이 여섯을 모두 내고 있다 — 벡터로 바뀌도 이 계약은 그대로다.

3-4. 미확정 2건

미확정	선택지	언제
사례집·의결서 본문을 벡터에 넣을지	(가) 조문만 넣는다 (나) 사례 서술도 넣되 인용은 조문만 허용	3주차. 현재 기울기는 (나) — 「유사 사례」 화면이 필요로 한다
청크에 조 단위 요약물 덧붙일지	원문만 / 원문 + 요약 2벡터	검색 품질 측정 후

4. 두 층을 잇는 지점

판정 1회가 무엇을 읽고 무엇을 쓰는가:

