

SKN FINAL PROJECT · COPYLANE · 2주차 산출물 6/7

데이터 정의서

학습 · RAG · 업무활용 3분류 · 수집 필드 정의

이 문서의 모든 수치는 2026-09-10 실측이다. 「설계상 있다」와 「지금 돈다」를 같은 글씨로 적지 않는다 — 동작 / 부분 / 미착수 를 구성요소마다 붙였다.

CopyLane 데이터 정의서

2주차 산출물 항목 3 · 2026-09-10 · 오한빈

학습 · RAG · 업무활용 3분류 데이터 정의와 수집 필드 정의. 모든 수치는 실측이며 단위를 함께 적는다.

발표 자료용 이미지: 이 문서의 도면은 `도면_png/` 에 2배율 PNG 로 들어 있다. 슬라이드에 그대로 붙인다. 웹 도면판(전체 13장)은 별도 페이지에서 본다.

0. 데이터를 세 갈래로 나누는 기준

이 프로젝트는 데이터를 **출처**가 아니라 **용도**로 나눈다. 같은 소스라도 용도마다 허용 여부가 다르기 때문이다.

용도 코드	이름	무엇에 쓰나	허용 소스
U1	학습	모델 학습·평가 표본	35 / 47
U2	RAG	벡터 색인·검색 대상	24 / 47
U3	인용	사용자에게 원문을 보여줌	25 / 47
U4	배포	데이터셋 공개·재배포	35 / 47

예시: `mfds_casebook` (식약처 사례집)은 **U3 인용·U4 배포는 allow** 인데 **U1 학습·U2 RAG 는 deny** 다. 해설서를 학습에 넣으면 「해설서를 외우는 모델」이 된다. 반대로 `aihub_*` 코퍼스는 **U1 학습만 allow**, U2·U3 deny 다 — 광고 코퍼스는 반례 학습용이지 인용 근거가 아니다.

용도 판정은 `registry.require(source_id, use=)` 가 실행 시점에 집행한다. 코드가 잘못된 용도로 소스를 만지면 프로그램이 멈춘다.

0-1. 등급 — 「무엇을 쓸 수 있는가」의 상한

등급	뜻	건수
G3 자유	공공누리 1유형 · 공공저작물 · 제한 없음	34
G2 조건부	출처표시 · 비영리 · 약관 제약이 붙는다	10
G1 금지	저작권이 살아 있다 — 수집 자체를 하지 않는다	0
G0 판정 불가	조건을 확인하지 못했다 — 전부 보류	3

등급은 소스에서 끝나지 않는다. 의결서는 G3 이어도 그 안의 광고 캡처 이미지는 G1 이다 — `fragment` 가 개별로 다시 판정한다.

등급이 높아도 용도가 막힐 수 있다. 사례집은 G3 인데 U1·U2 가 deny 다. Meta 광고 라이브러리는 G2 인데 **전 용도 차단**이고 `status: manual` 로 남겼다 — 약관이 자동 수집을 금지하기 때문이다. 「볼 수는 있지만 쓸 수는 없다」를 기록한 자리다.

1. 데이터 층 — 무엇을 왜 모으는가

층	무엇	소스 수	용도
1층 판정라벨	「이 문구는 위법이다」의 근거가 된 실사례	10	학습·평가
2층 적법라벨	「이 표현은 써도 된다」 — 인정 가능성 문구	4	학습·생성
3층 판단규범	법률·시행령·고시 조문	3 (+1 겹)	RAG·인용
4층 위험도	벌표 제재 기준 · 과징금 부과기준	1 (+1 겹)	위험도 산정
5층 코퍼스·반례	일반 광고·리뷰 — 정상 문장	11	학습(음성 표본)
6층 세그먼트	소비자 조사·통계	9	생성(Phase 3)
7층 광고 카피	카피 코퍼스	2	생성(Phase 3)
기타	플랫폼 API 2 · 경제성 근거 2	4	참고

층이 왜 필요한가: 위법 사례만 모으면 모델이 「모든 문장은 위법」이라고 답해도 맞아 보인다. 2층(적법)과 5층(정상)이 있어야 오탐을 썰 수 있다.

2. 학습 데이터 (U1)

2-1. 골든셋 — 학습과 평가의 단일 출처

data/derived/golden/golden.jsonl · 1,908행

필드	타입	설명
id	string	ftc:10047#0 — 출처:문서:문장
text	string	문구 원문
labels	string[]	위반 유형 (없으면 [] = 적법·정상)
unit	문장 낱말	두 과제를 한 숫자로 평균하지 않기 위한 칸
origin	real injected approved	실사례 / 규칙 주입 / 인정 문구
provenance	string	소스 ID
redistributable	bool	공개 가능 여부
split	train test_sentence	학습 / 평가
rule_id	string	주입본만 — 변환 규칙 T1~T10

구성

ORIGIN	SPLIT	행	UNIT
real	train	684	문장 371 · 낱말 313
injected	train	784	문장
approved	train	234	문장

ORIGIN	SPLIT	행	UNIT
real	test_sentence	146	문장
approved	test_sentence	60	문장 (음성 표본)
합계		1,908	

2-2. 유형별 표본 — 평가 가능한 것은 2종

위반 유형	학습 (행)	평가 (행)	평가 (문서)	판정
거짓_과장	668	73	37	측정 가능
소비자_기만	94	67	39	측정 가능
질병_예방치료_표방	216	0	0	제외 측정 불가
의약품_오인	169	0	0	제외 측정 불가
후기_체험기_기만	112	0	0	제외 측정 불가
건강기능식품_오인	87	0	0	제외 측정 불가
비방광고	124	2	1	제외 30건 미만
부당_비교광고	113	4	2	제외 30건 미만
추천_보증_뒷광고	0	0	0	제외 표본 없음
실증책임_위반	0	0	0	제외 표본 없음

「측정 불가」는 결함이 아니라 보고 형식이다. 표본 30건 미만이면 정확도를 계산하지 않고 그렇게 적는다. 수치를 만들어 칸을 채우면 그 수가 원장으로 흘러간다.

단위를 함께 적어야 한다. 같은 유형이 「문서 37 / 문구 73」으로 다르게 세어진다. split_manifest.json 은 문서 단위, golden.jsonl 은 문구 단위다. 어느 쪽이 틀린 게 아니라 축이 다르다 — 보고할 때 반드시 단위를 붙인다.

2-3. 분할 규칙

data/derived/golden/split_manifest.json

항목	값	왜
seed	20260909	재현성
split_key	doc_id	문서 단위로 가른다 — 같은 의결서의 문구가 학습과 평가에 갈라지면 지표가 부풀려진다
min_measurable	30	이 미만은 측정 불가
eval_target	40 (문서)	유형당 평가 목표
neg_target	60	음성 표본
inputs	3파일 sha256 + bytes	입력이 바뀌면 멈춘다
excluded_from_eval	다중라벨 문서 44건	의결서가 두 호를 함께 걸면 인용 문구가 어느 호인지 안 적혀 있다
same_source	ftc_decisions_body	학습과 평가가 같은 기관 — 원천 편향은 못詹다고 명시

분할표와 물질화 결과가 어긋난다. `split_manifest.json` 의 `sizes.test_sentence` 는 「문서 143 · 문구 214」 인데, 물질화된 `golden.jsonl` 의 `test_sentence` 는 **문서 139 · 문구 206** 이다 (문서 4 · 문구 8 차이). 정규화 중복 제거로 줄었을 가능성이 크지만 **확인되지 않았다**. 두 수를 같은 자리에서 인용하면 안 되고, 보고에 쓰는 값은 물질화된 `golden.jsonl` 쪽이다. 3주차에 원인을 확인한다.

`inputs` 지문이 이 프로젝트의 재현성 장치다. 입력 파일이 한 바이트라도 바뀌면 `verify_inputs` 가 `SystemExit` 을 낸다 — 「옛날 분할표로 새 데이터를 평가하는」 사고를 막는다.

2-4. 주입 데이터 (`origin = injected`)

`data/derived/injected_golden.jsonl` · **901행**

적법 문구에 변환 규칙 T1~T10 을 걸어 위법 문구를 만든 것.

필드	설명
<code>src</code>	원본 문서 ID
문구 · <code>원본</code>	변환 후 / 변환 전
라벨 · <code>rule_id</code> · <code>규칙</code>	불은 유형과 적용 규칙
핵심주장	변환된 주장 스펙

주입본은 평가셋에 들어갈 수 없다. `CHECK (NOT (origin='injected' AND split IN ('test_sentence', 'test_holdout')))` — 규칙으로 만든 문장을 규칙으로 평가하면 100% 가 나온다.

3. RAG 데이터 (U2 · U3)

3-1. 조문

`data/derived/law_article.jsonl` · **2,207행**

필드	설명
키	조문 식별자
조 · <code>가지</code> · <code>항</code>	조 · 조의N · 항
제목 · <code>본문</code>	조 제목 / 본문
법령 · <code>파일</code>	법령명 / 원본 파일
층	3층 판단규범
<code>provenance</code> · <code>redistributable</code>	출처 / 재배포 가능

3-2. 별표 (위험도 원천 — 아직 DB 미적재)

`data/derived/law_annex/*.jsonl` · **별표 243행** (5개 법령 · 서식 제외)

🔄 2026-09-10 — 화장품법 시행령(005668) 별표 둘이 통째로 빠져 있어 **213 → 243행**이 됐다. 감사가 처음부터 「5법령 243행」을 전제하고 있었다 (D-98).

필드	설명
law_id · annex_no · annex_branch	법령 · 별표 번호 · 가지
violation	위반 유형
article · article_inherited	조문 · 상속된 조문
sanctions	차수별 제재 — sanction_rule 의 원천
marker · fragments	표 마커 / 조각
needs_review	사람 확인이 필요한 행

이 파일은 있는데 **sanction_rule** 로 적재하는 코드가 없다. 위험도 배지가 안 나오는 원인이 바로 여기서. 🔄 **2026-09-10 — 적재 범위가 정해졌다** (D-182 · D-183). 별표7 71행 중 광고에 걸리는 것은 **4행**이고, 행정 위반 67행과 과태료 10행은 적재하지 않는다. 과징금 **금액**도 계산하지 않는다 — 매출 기반 2단계 계산이라 사업자 매출을 알아야 하는데 우리는 묻지 않는다.

data/derived/law_norm/*.jsonl · **300행** — 별표 정규화 (조·항·호 경로 · 문자수)

3-3. 청킹 · 벡터 사양

항목	값
청크 단위	조 · 항 · 호 (문자 수가 아니다)
상한	512 토큰 — CHECK 로 강제
임베딩	KURE-v1 · vector(1024) · 로컬 실행
검색	BM25 + 코사인 하이브리드 → 리랭커 bge-reranker-v2-m3
필터	v_current_chunk (현행만) + source_use.allowed(U2_rag)
상태	✅ 2,585행 적재 — KURE-v1 · 1024차원 실측 확인 (2026-09-10)

3-4. 인용 시 반드시 함께 나가는 필드

필드	출처	왜
law_id · article · paragraph · item	chunk	조문 번호
doc_type	chunk	법률/시행령/고시 — 효력 위계
effective_date · superseded_at	chunk	현행 여부
attribution	source	출처표시 의무 (BY 플러그)
url	source	원문 확인 경로

4. 업무활용 데이터

사용자가 서비스를 쓰면서 만드는 데이터. 수집 데이터와 물리적으로 다른 표에 있고, 두 층 사이에 FK 가 없다.

4-1. 표와 필드

표	핵심 필드	수명
work_doc	consent_store · consent_train (둘 다 기본 false) · owner_id · session_id · expires_at	동의 없으면 만료와 함께 삭제
copy_sentence	raw (표시) · norm (매칭) · offset_map · origin · external_ref · approved_at	문서와 함께
judgment	verdict · hold_reason · product_category · violation_type · evidence · evidence_span · risk_floor · risk_final · law_version · attempt	문서와 함께 · 새 행을 쌓는다
batch_run	total · done · state · summary (원문 없이 집계만)	문서와 함께
upload_blob	kind · path (UPLOAD_ROOT 아래) · sha256	판정 후 원문 파기
slot_assignment	template · slot · position · sentence_id · unreviewed_note	문서와 함께

4-2. 보관 정책 — 기본값이 「저장 안 함」 인 이유

규칙	구조적 형태
동의 없으면 저장하지 않는다	consent_store 기본 false
지울 키가 있어야 지운다	CHECK (consent_store OR expires_at IS NOT NULL) — 동의 없는 문서는 만료 시각을 반드시 갖는다
학습 활용은 별도 동의	consent_train — 이 플래그가 학습·색인 차단의 유일한 해제
업로드물은 학습에 못 들어간다	경로가 upload_blob.path 한 곳뿐이고, 학습 코드가 그 경로를 consent_train 필터 없이 참조하면 게이트 테스트가 실패한다
관리자도 원문을 못 본다	관리자 API 는 집계값만 반환한다
집계는 원문 없이 남는다	batch_run.summary — 원문이 사라져도 위험도 추이는 남는다

5. 수집 현황 (실측)

5-1. 레지스트리

항목	값
등재	47
등급	G3 34 · G2 10 · G0 3
상태	수집 대상 30 · 보류 14 · 수동 3
2인 서명 완료	37 / 47
채택하지 않음 (not_adopted)	13 — 뺀 것을 적는다

항목	값
robots 확인 기록	HTML 수집 3소스

5-2. 파생물

파일	행	무엇
law_article.jsonl	2,207	조문
law_annex/*.jsonl	392	별표 (제재 기준)
law_norm/*.jsonl	300	별표 정규화
banned_terms.jsonl	536	사전 (금지·적법 표현)
golden/golden.jsonl	1,908	골든셋
injected_golden.jsonl	901	주입본
ftc_layer1_phrases.json	283	의결서 인용 문구
ftc_stage.jsonl	8,253	의결서 스테이징
mfds_casebook_labels.jsonl	190	사례집 라벨
mfds_guide_labels.jsonl	2,728	해설서 라벨
mfds_hf_labels.jsonl	465	인정 기능성 원료
mfds_press/mfds_press_index.jsonl	4,349	보도자료 색인

라벨링 대기: `mfds_guide_labelsheet.jsonl` 248행 + `mfds_casebook_labelsheet.jsonl` 25행 — 팀원 4인 분배 완료

5-3. 수집 원장

항목	값
원장 행	20,008 (2026-09-10)
고유 경로	10,032
원천 종류	13

5-4. 어떻게 수집했는가 — 방식별

수집 방식	등재	수집 중	이 방식이 지켜야 하는 것
API — 공식 오픈API · 인증키	13	10	키는 <code>.env</code> 단일 진입점. 셸 인자·대화예 넣지 않는다. 호출량 상한과 증분 갱신 키를 원장에 남긴다
파일 다운로드 — 공식 배포본	17	11	배포처가 공식인지, 판(版)이 최신인지 확인. 받은 파일의 sha256 을 원장에 남겨 같은 파일인지 판별
스크레이핑 — 게시판 HTML	3	2	robots 확인 기록이 없으면 게이트가 실패한다. 요청 간격 · 목록/본문 분리 · 조용한 중복과 offset 페이지징 검사
신청 · 승인 — AI Hub 등	6	5	이용약관 범위 안에서만. 그래서 U2 RAG · U3 인용이 deny 다

수집 방식	등재	수집 종	이 방식이 지켜야 하는 것
수기 — 사람이 직접	3	1	자동 수집이 약관 위반이거나 robots 가 막은 소스. 자동화 코드를 만들지 않는다
자체 산출 — 우리 파이프라인	1	1	이미 수집한 데이터에서 계산. 원천의 등급·용도를 그대로 물려받는다
미확인 — 방식 미정	4	0	전부 보류. 어떻게 받을지 정해져야 지켜야 할 것도 정해진다

스크레이핑 3종 중 **2종은 robots 확인 기록이 있고 1종은 없어 보류**다. 기록이 없으면 게이트 테스트가 실패하므로 수집이 시작되지 않는다.

5-5. 어디에 쓰였는가 — 소스 → 파생물 → 용도 계보

원천	방식	파생물 (실측)	DB 표	어디에 쓰이나
공정위 의결서 본문 ftc_decisions_body	API	ftc_layer1_phrases 283 · ftc_stage 8,253	golden_sample	학습 · 평가 — 거짓_과장 · 소비자_기만
법제처 법령 API law_go_kr	API	law_article 2,207 · law_annex 392 · law_norm 300	chunk · document (sanction_rule 예정)	근거 조문 검색 · 인용 · 위험도
건기식 원료별 정보 mfds_hf_ingredient_board	스크레이핑	mfds_hf_labels 465	product_fact · golden_sample(approved)	적법 문구 · 음성 표본
특수용도식품 해설서 mfds_special_use_guide	파일	mfds_guide_labels 2,728 (라벨링 대기 248)	dict_entry	사전 — 위험도 하한 · 생성 차단 키워드
부당광고 사례집 mfds_casebook	수기 전사	mfds_casebook_labels 190 (대기 25)	dict_entry	사전 · 인용만 — U1·U2 deny
부당광고 보도자료 mfds_press	스크레이핑	mfds_press_index 4,349	—	유사 제재 사례 표시 — U1·U2 deny
AI Hub 코퍼스 4종 aihub_*	신청	— (Phase 1 반입)	golden_sample 음성 표본	정상 문장 — 오탐 측정 · U2·U3 deny
과징금 부과기준 foodsafety_penalty_std	API	— (수집 대기)	penalty_rule	과징금 산정 —

원천	방식	파생물 (실측)	DB 표	어디에 쓰이나
식약처 행정처분 mfds_sanctions	API	—	sanction_rule	위험도 배지 · 제재 수치 — 적재기 없음

이 표가 답하는 질문은 「데이터를 어디서 구했느냐」가 아니라 「**그 데이터가 지금 무엇을 하고 있느냐**」다. 사례집과 보도자료가 U1·U2 deny 인데도 수집한 이유는 **인용**이다 — 사용자에게 「비슷한 제재 사례」를 보여줄 때 쓴다. 학습에 넣지 않는 데이터를 왜 모으는지가 문서로 답해진다.

6. 수집 시 반드시 남기는 필드

수집 1회 = collect_manifest 1행.

필드	왜
source_id	어느 소스인가
fetched_at	언제
url	어디서
sha256	무엇을 — 같은 파일인지 판별
bytes · rows	크기 · 건수
event	fetch / skip / delete — 안 받은 것도 기록한다

그리고 등급이 갈리는 자리마다 fragment 행을 만든다.

필드	왜
frag_type	법리서술 / 광고문구 / 캡처이미지 / 업체명
grade	소스 등급을 상속하지 않는다 — 의결서는 G3 이어도 그 안의 광고 캡처 이미지는 G1
masking	always / none — 업체명·대표자명·주소는 즉시 마스킹
excluded	제외 여부

7. 이 문서가 확정하지 않은 것

미확정	선택지	언제
사례집·의결서 본문을 벡터에 넣을지	조문만 / 사례 서술도 (인용은 조문만)	3주차
평가셋 8종을 채우는 방법	의결서 추가 수집 / 유형 통폐합 / 「측정 불가」 유지	9/17 범위 확정
업로드물 보관 기간 상한		3주차

미확정	선택지	언제
6·7층 (세그먼트·카피) 수집 시점		Phase 3